

个人信息

姓名：Erric 王

地址：闵行 浦江镇

邮箱：17051275749@163.com

电话：19373447250(微信同号)


求职意向：分布式软件框架工程师

毕业院校：电子科技大学

学历：硕士研究生

专业：计算机技术

出生年月：1994.03



教育背景

2017.9-2020.6	电子科技大学	计算机学院/计算机技术	硕士
2012.9-2016.7	湖北师范大学	计算机学院/通信工程	本科

工作经历

2022.5.20 — 至今	壁仞科技	分布式框架工程师
2021.8.15 — 2022.4.22	美团	算法工程师
2020.8.17 — 2021.7.22	云从科技	算法工程师

项目经历

壁仞科技

分布式框架工程师

2022.5.20 - 至今

- 1、项目描述：Pytorch 适配；
- a) 个人职责：在 BIREN 软件栈上适配 Pytorch DDP 功能，支持传统 RN50/YOLO v5 等小模型单机多卡训练；
- 2、项目描述：公司内部构建千卡集群，基于 Megatron-LM 进行 StepV1 130B + Llama3 405B 进行预训练，在精度达标的要求下，实现极致的性能优化；
- i. 针对大规模训练的性能瓶颈定位难问题，制定相关需求文档，推进 Profiling 工具的实现；功能包括：TP Group 内部通信快慢卡定位、PP Group 不同 Stage 计算负载均匀性、通信计算 Overlap 情况、GPU 算子耗时排名、CPU 耗时排名、通信带宽情况；

ii. 针对大规模训练显存占用过多问题，设计基于 Yaml + Hook 的 Activation Offload 功能，实现显存优化；对比重计算而言，通过 Async Offload Overlap，实现端到端 ~22% 收益；

iii. 针对大模型通信慢问题，设计并实现 Tensor Pool 功能，实现 Megatron 侧在调用相关通信接口时 Tensor 复用，底层可以实现通信的 Naïve Mode，最终端到端 7%收益；

iv. Chunk Optimizer;通过 H2D/D2H Overlap 实现 Loss 计算时峰值显存导致的 OOM 问题；
- 3、项目描述：作为微调方向 Owner，组织组内成员打通 DeepSpeed 及 Megatron 实现 7B ~ 72B 的微调能力；支持 alpaca、sharedgpt 等多种数据集格式，标准化产品能力关键客户交付的模型 15+，在精度达标的情况下平均性能 ~0.65 A100；
- a) Deepspeed 微调；

i. 使用 zero2/3 进行训练时，引入 Partition tensor 逻辑完全消除 BR 卡上的 Reorder 端到端 21%收益；ChatGLM2/3 6B 性能接近 0.75 A100

ii. 引入 Third Stream Overlap 反向计算累加操作和下一个 MB 的前向计算 Overlap 5%收益；

iii. 基于 Pytorch Hook 实现 Accuracy Dump Tool，便于相关同事用于精度比对；

b) Megatron 微调；

-
- i. 实现 CCLOR 功能, 在 MLP 等计算 Lora 计算时, 通信和计算的 overlap 提升 7.5%性能; (Qwen2 72B)
 - ii. 实现全参微调功能, 32B 及以上规模的微调能力; 复现 DeepSeek R1 32B distill 结果, MATH500 指标与 NV 完全一致;
- 4、**项目描述:** 作为后训练方向框架 Owner, 在 BIREN 卡上实现后训练落地 给予基础软件迭代反馈;
- a) 后训练关键架构摸底; 整理当前后训练的共卡/非共卡的技术架构的关键问题, 共卡场景的长尾问题、单控制节点的数据瓶颈问题、超大规模权重同步慢等;
 - b) veRL 框架适配;
 - i. 共卡: R1 Zero Qwen2.5 7B/32B GRPO 精度复现;
 - ii. 异步: R1 Zero Qwen2.5 7B DAPO 精度复现;
 - iii. 针对 veRL 在大规模训练时, 控制节点命令下发慢问题进行了优化; 数据节点与控制节点解耦, 支持样本级数据 Push/Get
 - iv. 优化 veRL 权重同步逻辑, 原始 Qwen2.5 7B 7s $\rightarrow$ 1.5s;

美团打车安全

算法工程师

2021.8.15 - 2022.4.22

项目背景: 在打车场景建立预警系统对订单进行跟踪, 识别行程中、行程后危险 及时干预保证司乘安全;

项目职责:

- 1、三级漏斗策略; 根据历史数据 + 实时轨迹流, 构建干预系统, 对行程中的订单识别危险程度, 低危弹窗、中危短信、高危客服介入; 历史数据包括: 乘客画像、司机画像、起点 POI 类别、终点 POI 类别;
- 2、高危场景建模; 针对提前完单、终点停留、完单未分离等高危场景制定策略提高危订单召回略; 81.2% $\rightarrow$ 97%; 准确率: 85% $\rightarrow$ 70%;

分布式人脸人体关联聚类

算法工程师

2020.8 - 2021.7.20

项目描述: 使用自研聚类算法, 实现对公安部门掌握的 摄像头抓拍数据, 进行聚类, 相同人的抓拍形成一个档案, 不同人的抓拍形成不同的档案。小规模接入时, 每天新增的抓拍 500w。

职责描述:

- 1. 优化搜索效率, 解决亿级底库情况下, 多机搜索能力;
- 2. 实现带注册照的人脸 (人体关联) 聚类的功能。
- 3. 实现簇评估功能; 实现聚类相关档案的修正功能。
- 4. 提升召回率:
 - a) 针对低质量抓拍问题, 使用明细搜明细和明细搜 embedding, 在准确率为 95.2%的前提下, 召回有 1.5 个点提升, 到达 86.2%。
 - b) 尝试使用多代表投票, + 多代表进行特征融合。测试集上 recall 提升 1.9 个点, 精度不变。

技能介绍 (Skills introduction)

-
- 具有较强的编程能力, 熟悉 Python, C++;
 - 熟悉预训练、后训练的相关内容, 了解相关框架如 Megatron LM、DeepSpeed、AREAL、veRL 等;
 - 熟悉 Profiling 工具, 包括显存分析、CPU 侧瓶颈分析、通信瓶颈分析待;
 - 源码阅读能力较强, 在分布式场景能定位并解决部分问题提升端到端系统性能;
 - 有较强的组织和领导能力, 在微调和后训练方向能制定合理的目标, 并带领同事取得一定的成果;