

个人信息

姓名: Sam
性别: 男
居住地: 北京
出生年月: 1999
github: <https://github.com/sleepcoo>

教育经历

2016-09–2020-07 长春大学
计算机科学与技术
本科

开源经历:

SGLang core dev

1、完成 DeepSeek-V3 (EP) 模块的从 0 到 1 开发。深度参与 [SGLang大规模分布式 EP](#) 的演进, 推动了高性能 MoE 推理方案的成熟与落地。

SpecForge project leader

- 1、主导投机采样 (Speculative Decoding) 训练框架。提供从 Draft Model 训练到推理部署的端到端解决方案。
- 2、发布 SpecBundle 为业界主流模型提供 draft model, 其中 Llama4、Qwen3 吞吐提升近 2 倍。 [blog 链接](#)

工作经历

2021-09 – 至今 美团
职位: 机器学习推理工程师 (L8)

工作职责:

美团 AI-Search 大模型推理优化

项目介绍: 负责美团 AI-Search 场景的在线 LLM Serving 架构演进。协调多团队完成从推理引擎选型到线上高可用部署的全链路构建。

项目职责:

- 1、大模型推理工程化落地: 主导 200B 参数级超大模型上线, 构建了涵盖离线高压演练、线上容量精准评估及全链路监控的可靠性保障体系, 确保大规模模型平稳服务。
- 2、高性能推理优化: 实现 PD 分离 By Layer 传输, 降低端到端耗时; 实现 EAGLE3 全图 CUDA Graph 化; 并且结合 Per-channel 量化, 在精度无损前提下大幅降低显存占用, 单实例吞吐提升 50%+。
- 3、投机采样(Spec-Decoding)全链路建设: 搭建 EAGLE3 训练流程, 基于业务数据迭代 Draft Model, 已在美团 AI-Search 场景全量部署, 带来 30%+ 的吞吐收益。

推荐场景模型 GPU 优化

项目职责:

- 1、稀疏模型 GPU 高性能部署: 基于 TVM 深度优化 CTR 模型算子, 完成外卖精排模型从 CPU 到 GPU 的迁移; 通过混合精度 (FP16) 优化, 推理吞吐提升 30%+。
- 2、计算图优化: 针对 User-Item 特征交叉场景, 重构计算图实现 User 特征的 Batch 级复用, 减少冗余计算, 单机吞吐大幅提升 50%。
- 3、ODL 全链路建设: 搭建从模型编译、监控到自动回滚的高可用链路, 保障了 ODL 模型更新的时效性与稳定性。

特征服务重构

项目职责:

-
- 1、基于模型推理服务完成特征计算服务的开发，支持特征计算图化、本地模型推理以及特征计算和模型推理的计算图合并等能力。相比原特征计算服务在同硬件平台上有超过 50% 的吞吐收益。
 - 2、梳理旧有特征算子并进行抽象和规范，完成特征计算算子开发，并提供特征计算 SDK 交付离线特征生产使用，实现了离在线特征计算的一致性。

2020-09 – 2021-09

腾讯

职位：后台开发工程师

工作职责：

- 1、参与腾讯云点播 CDN 服务器开发，承载视频云点播数十 T 带宽；负责某国内 top 短视频应用业务，完成业务需求、质量调优、成本优化；负责团队超大规模基于 QUIC 协议的视频传输和性能优化。