


于志航

AI Infra Engineer

✉ zhihangyu30@gmail.com | ☎ 17806275502 | 📍 上海 | 📞 [yu1150922636](tel:150922636)



简介/ Highlight

- core experience for this job: 2年多 AI Infra 工作经验(大模型预训练方向), 美团longcat团队
- past-output: 基于Megatron, 从0到1构建原生多模态训练框架, profiling分析优化性能卡点, 节省公司算力。

教育背景/ Education

复旦大学	计算机硕士 • 校一等奖学金
2.5年, GPA: 3.39 /4.0	上海 • 2021.9 - 2024.2
青岛大学	软件工程本科 • 校一等奖学金
4年, GPA: 3.78 /4.0	青岛 • 2015-2019

工作经历/ Experience

美团	上海
AI Infra 工程师 (longcat团队, Senior Engineer, 相当于L6-L7)	2024.1.30 - 至今
1.原生多模态预训练框架 (V1, 前期探索, 1.5k 卡, 1T数据)	
- S: 2024年初公司最早提出原生多模态方向 (text + visual + audio), 支持原生多模态训练框架设计; - T: 基于megatron, 设计并实现原生多模态训练框架, 包括数据预处理逻辑, 整体训练流程设计, 并行划分设计, 支持在线和离线数据训练, 支持算法同学快速探索新的算法feature; 支持pretrain 及 sft生产任务; - A: 设计了基于小根堆的splicing数据拼接流程, 可快速拓展多种模态, 支持在线数据及离线数据拼接; 设计了processor -> to_embedding -> LLM -> loss的训练架构; 生产前对模型profile, 设计并实现多模态统一多头交叉熵算法, 加速了loss计算, 从而加速了模型训练(MFU 13% -> 17.5%); - R: 基于moe-6B LLM 顺利训练产出第一版原生多模态模型, 实现了基本的各模态互转能力; 后又参与了基于lm-deploy的多模态推理框架的建设, 做了一定的推理工作。	
2.原生多模态预训练框架 (V2, 开源版本Longcat-Next, 3k卡, 2T数据)	
- S: 原生多模态继续迭代, megatron需从非core架构迁移至core架构, 由GPU训练迁移至NPU训练, LLM 主干由moe6b 转为使用longcat flash3b, 并且引入了Over-embedding、image-bridge、Depth-Transformer等新feature, 模态token处理也发生了变化, 训练框架需要适配这些新的feature。 - T: 将megatron迁移至文本主线的core架构, 并做一些NPU的适配, 比如FA算子的替换等等, 以及NPU的精度验证。开发适配新feature, 并且在引入新feature的情况下需要尽可能的提高训练效率。(人力因素前期绝大部分工作均由个人独自完成) - A: 基于profile对各个模块的分析, 设计并实现了基于v-half的pp架构, 针对ImageHead/ AudioHead做了cp切分, 实现了较为均衡的pp切分; 因为适配新的LLM主干, 前期配合算法基于deepspeed快速开发一版, 后期megatron与之对齐, 做了大量精度验证工作。 - R: 顺利完成训练框架及精度验证, 稳定的完成了生产任务, MFU 20%, 按预期开源出Longcat-Next。	
3. Longcat-Flash基座预训练 (万卡集群)	
另外参与LLM基座相关feature开发, 模型训练中, 暂未开源, 简历中不做详细介绍。	

专业技能/ Skills

熟练: Python, C/C++, Java; 训练框架: Megatron、DeepSpeed; 大模型并行训练, 大模型训练优化;
熟悉: Cuda算子编程、NPU 算子编程; 推理引擎如Sglong、lm-deploy、vllm; 强化学习框架: ares、verl;

技术报告/ Open Sources Technical Report

