

何磊

17310188675 | z1pitt1027@163.com



教育经历

中国科学技术大学
本科

2015.09-2019.08

工作经历

百度

2023.12-至今

AI Infra 高级专家

1. 完成大模型推理框架XuanYuan的开发与模型吞吐优化

- 推理框架的耗时trace工具开发，大模型计算图layer层瓶颈分析工具开发
- 无需训练的Sparse Mask 预测算子开发，关联token之间的相似性，通过在线softmax全局最大值和局部最大值之间的差异选择性压缩块来构建sparse mask，实现框架部署模型整体吞吐提升1-2倍
- 模型量化开发，主要是QAT int4开发与PTQ int4开发，集成和开发相关triton的kernel并且开发相关量化校准
- EP并行，PD分离，Tilelang等开源推理框架的新特性集成到自研推理框架，实现吞吐提升2-3倍
- Qwen3, Ernie等MoE模型的投机解码开发，主要是选取容易被激活的MoE参数组成参数量较小的dense模型，并针对性的做知识蒸馏，从而构建预测准确率75%以上的draft model，提升吞吐1-2倍

2. 完成训推一体调度开发

- 使用k8s搭建分机房分标签的GPU集群，主要分为训推混合集群与在线推理集群，训推混合集群通过将离线跑批任务与训练任务混合部署。支持断点续训且通过连续异步checkpoint实现，通过内存实现备份同步系统，实现无需占用通信带宽的方式即可完成多任务频繁保存checkpoint。通过volcano等高级调度器实现gpu机器的自动弹性伸缩与潮汐部署，可以在不同集群之间对于空闲机器算力的最大化应用。
- 推理服务治理，主要是通过智能router开发构建对于超高流量并发的负载均衡，并且通过中心化的kv cache池实现PD分离节点的最大吞吐优化。通过QoS队列与优先级调度，保障时延优先队列有着低延时的同时最大化批任务的吞吐处理，并且通过GPU虚拟化实现多个小模型共享同一张推理卡实现算力的最大应用。
- 全链路稳定性开发，实现Precheck与周期巡检。并对调用栈实现python torch CUDA全链路的监控。并通过Grafana等工具在线实时监控以上数据并对故障实时报警。

Momenta

2020.12-2023.11

AI infra 专家

1. 算法工程化与infra开发

- 完成感知模块在新的自动驾驶新平台的工程化开发，需要对新平台的融合实际工程效果负责
- AI量化工具链开发，校准数据集与算法开发，精度对齐，训练时量化等工具开发

2. 感知端到端大模型推理和部署优化

- 负责在orinx上部署感知端到端大模型，包括DSVT, sparse4D, bevformer等模型
- 负责模型量化开发，例如做int8量化时的校准数据集开发，精度对齐和算力验证开发，当模型精度下降时需要debug模型并找到相对应的layer并做优化例如混合精度优化，和算子融合优化。
- 负责模型的算子开发和优化，如一些自定义的cuda算子开发和所需的plugin开发，例如变种DFA算子等

3. 带领小组负责整体工程的performance，主要包括完成部署相关工程开发和设计端到端时延优化方案

- 通过各种工具profiling 定位来自CPU,内存,GPU,IO的瓶颈，并和各算法模块进行合作，定位到的性能瓶颈。
- 通过 优化异构系统下的协同调度和内存，优化CPU，GPU的推理资源的抢占，具体热点的访存优化 等方式，对感知规划模块近20个性能热点将进行优化。

快手科技

2019.08-2020.10

特效图形算法开发工程师

- 参与了快手内部平台特效编辑器的开发工作，参与了快手内部Gan算法的开发工作(可灵大模型前身)