

周培风 | 深度学习系统工程师

电话: 18800165085 邮箱: laipaang@gmail.com

个人简介

AI Infra / 深度学习系统工程师, 7 年大规模机器学习系统研发经验。现就职于百度商业广告核心技术团队 (凤巢), 长期负责百度商业模型分布式训练与推理基础设施建设。

期间主导构建千亿 sMoE 语言模型、生成式推荐模型与万亿稀疏推荐模型训练系统, 支撑商业核心业务模型迭代与指标增长。曾获 2024 年百度最高奖 (百万美金)。

工作经历

百度 | 商业研发部/模型训练组 | 2018 ~ 至今 (绩效 5 次 M+)

I) 千亿 sMoE 语言模型训练框架 (创意/智能体)

— 项目成果:

- 训练性能累计提升 3x, 百度商业收入核心指标累计提升 8%+

— 技术挑战:

- 如何从百亿 Backbone 构建千亿参数模型?
- 千亿参数规模带来的存储与计算瓶颈
- sMoE 训练中的通信开销与专家负载不均衡问题

— 实现方案:

- 建模方案:
 - Transformers 中 FFN 升级为通过 Gate 控制的 Multi-Experts-FFN (sMoE)
 - 48 层百亿 Backbone 每 3 层 FFN 扩展 24 个专家, 选择 Top1-2 个专家
- 训练优化:
 - 路由策略: 路由策略由 GShard Top2 升级到 Switch Top1, 降低通信与计算开销;
 - 通信优化: 根据数据业务属性, 硬限专家选择, 避免跨机通信
 - 负载均衡: 引入负载均衡 loss, 随机探索机制, 提升均衡性
 - 并行策略: 数据并行 + 张量并行 + 专家并行
 - 计算优化: 融合算子 (FusedMHA / FFN) + GroupGEMM 提升吞吐

II) 生成式推荐模型训练框架 (搜推广告模型)

— 项目成果:

- 训练性能累计提升 5x, 百度商业收入核心指标累计提升 15%+
- 生成式搜索广告荣获 2024 百度最高奖 (模型训练负责人)

— 技术挑战:

- 生成式推荐处于范式探索阶段, 缺乏成熟工程路径
- 百亿级模型训练面临存储、计算与通信瓶颈
- 长序列建模带来严重 padding 冗余与负载不均问题

— 实现方案:

- 建模范式:
 - 搜索/推荐广告统一语义建模 (Query / 行为序列 → 语义 ID)
 - 先粗粒度生成 ID 再细粒度向量召回, NTP + NCE Loss
 - 引入 DPO / GRPO 强化学习对齐下游业务信号, 实现端到端训练范式
- 系统优化:

- 计算优化：融合算子与混合精度训练加速计算
- 显存优化：ZeroDP 并行参数分片 + 细粒度重计算降低激活显存占用
- 通信优化：计算与通信重叠隐层耗时，参数分组聚合提升通信效率
- 数据优化：序列 packing 显著降低 padding 带来的计算和存储的冗余，全局负载均衡降低卡间等待
- 策略能力：设计跨设备全局负采样算子，提升模型效果
- 平台能力：
 - 构建学习平台，实现任务例行：多阶段训练、评估、量化、验证与发布等

III) 生成式模型离线推理系统（高吞吐优化）

— 项目成果：

- 推理优化带来离线吞吐提升 10×
- 弹性调度带来集群 GPU 利用提升 20%+，潮汐资源利用率 75%+

— 技术挑战：

- 推荐系统 100ms 级低延迟要求限制 10B+ 大模型在线部署推理
- 推荐系统场景多/样本量大，需大量推理资源
- 生成式推荐不同于语言模型：生成结果需来自候选集合

— 实现方案：

- 推理加速：
 - 计算加速：算子 / kernel 融合（transformer、多种惩罚算子）减少调度，加速计算；解码中 TopK 规约改为 K 次的 Top1 计算，减少 Branch Divergence；KV Cache、Remove Padding 避免冗余计算
 - 流程优化：样本解析、GPU 计算异步化，隐藏耗时；Pinned Memory 加速数据拷贝
 - 框架升级：Paddle 到 TensorRT-LLM，复用社区已有能力，如：Paged Attn 节省 KV 显存、连续批处理加速变长推理
 - 模型量化：SmoothQuant INT8 量化降低权重显存占用，同时加速访存与计算
- 策略能力：
 - 字典树实现限定生成，确保生成结果来自候选集
 - 生成度量一体推理，生成结果的同时得到度量打分
 - BeamSearch 解码中实现长度惩罚、分组多样性能力提升效果
- 在线加速：Medusa 投机解码、Wanda 稀疏剪枝等微调环境，为在线加速提供组件
- 弹性调度：构建弹性推理资源调度系统，利用训练碎片资源、在线潮汐资源，提升集群 GPU 资源利用率

IV) 万亿稀疏推荐模型训练框架（参数服务器架构）

— 项目成果：

- 1-2 台 GPU 机器替换几百台 MPI 机器，训练成本节省 3× 以上
- 系统稳定性大幅提升，同时 GPU 算力为策略打开探索空间

— 技术挑战：

- 存储：万亿规模参数 GPU 存储面临挑战
- 通信：稀疏参数为多机多卡通信带来巨大挑战
- 计算：推荐系统每天有 10 亿+ 的样本，面临样本解析和训练算力压力

— 实现方案：

- 训练架构：深度学习框架 Paddle + 参数服务器 Ps；Paddle 管理稠密参数，Ps 管理万亿稀疏参数
- 参数服务器：考虑到硬件存储/带宽/价格以及推荐稀疏参数冷热分明的特性，设计 SSD(20T，全量参数)、MEM(1T，热参数)、HBM(80G，一个轮次参数)三层参数服务器。HBM 是卡间分片，SSD 和 MEM 机器间分片
- 系统优化：
 - 异步设计：一天的样本切分多个轮次，对于每个轮次数据分三阶段：样本解析、参数由 SSD 向 MEM 拉取、Batch 训练，之间异步形成流水线，硬件资源效率最大化，同时实现耗时隐藏
 - 通信优化：Key 在机器内去重加速通信
 - IO 优化：异步 IO 加速 SSD 读写

- 流水线加速 HBM table 构建；NUMA 亲和性绑定提升缓存命中率
- 策略能力：稀疏特征重要度评估、行业模型稀疏参数融合、负样本降采样训练

教育信息

北京科技大学 | 计算机科学与技术/硕士 | 2015 ~ 2018 (推免)

北京科技大学 | 计算机科学与技术/本科 | 2011 ~ 2015

荣誉与成果

荣誉奖项：

- 2024 百度最高奖 (百万美金, 模型训练负责人)
- 2023 总 TC 技术创新奖 (公司级唯一项目, 核心成员)
- 2023 百度骄傲最佳团队奖《扬楫》
- 2025 Q3 季度之星
- 2023 / 2022 优秀个人奖

论文与专利：

- One-step Reach: LLM-based Keyword Generation for Sponsored Search Advertising
- 授权发明专利 4 项 (生成式广告 / 大规模训练方向)