

朱雪峰

18610990412 | snowpeakz@163.com | 北京 | 在职 | AI Infra

摘要

7 年分布式深度学习系统研发经验，专注大模型预训练与高性能训练框架。在 MoE 模型通算并行、显存优化、通信卸载等方面有深入实践，善于从硬件特性出发突破性能瓶颈。同时对训练效果无损对齐有系统性方法论，支持框架平滑升级与异构迁移。历年均获高于平均水平的绩效评定，曾于 Shopee 由 Senior Engineer 晋升为 Expert Engineer。

教育经历 (由近至远)

上海交通大学	电子与通信工程	硕士	2016.9 - 2019.3
西安交通大学	机械工程及自动化	本科	2012.9 - 2016.6

工作经历 (由近至远)

北京摩尔线程智能科技股份有限公司 | 2025.6 - 至今

负责大模型预训练性能优化，以及内部 Megatron 和 TransformerEngine 的定制与维护。

在 1000B 大规模 MoE 模型与训练性能优化的工作中，基于硬件特点，我重点从通算并行与显存优化两个方向突破，在不损失精度的条件下，显著提升训练效率。

SM-free EP 通信: 利用 Copy Engine 完成节点内 All-to-All 通信，实现通信对 GPU SM 的完全卸载，通信与计算高度重叠。基于 DeepEP 定制通信路径，通过 Top-K 索引大幅压缩传输数据量。进一步提升了 EP Overlap 的收益，端到端吞吐量提升 28%。

SM-free PP 通信: 使能 Mooncake 框架，由 CPU 侧驱动 RDMA 完成 PP 通信，释放 GPU 计算资源；深入优化控制面同步逻辑，将 PP 通信耗时降低 50%，有效压缩流水线气泡。

Activation Offload: 结合大 PP 策略的显存特点，对 MoE 层激活进行量化分析，将目标激活值卸载至 CPU 内存，完全消除对应重计算开销，相较重计算方案实现 15% 的训练性能提升。

北京虾皮信息科技有限公司(Shopee) | 2022.4 - 2025.5

主导搜索/广告/推荐场景下高维稀疏训练框架 EGO 的核心模块。

该框架承载了公司全量高维稀疏训练与推理任务，支持 PS-Worker 与 Aibox 两种运行模式。

设计并实现分布式 Embedding 预加载 KV-Cache 机制: 针对推荐场景全量 Embedding 远超 GPU 显存的瓶颈，提出跨 rank 特征感知的异步预取流水线。通过 batch 特征 ID 去重、分片分发及 KV-Cache 命中决策，实现 Host→GPU 的按需加载；通过异步流水线，有效隐藏数据搬移延迟。该设计解决了大规模稀疏特征分布式训练中的显存约束与通信开销难题，显著提升吞吐。

通过 GPU 加速 Pooling: 针对推荐模型中稀疏特征的 Pooling 操作 (均值/求和)，开发自定义 CUDA Kernel，将 Pooling 完全置于 GPU 内执行，消除 CPU 性能瓶颈。该优化使含有大量用户行为序列的模型训练吞吐提升 30%。

开发模型效果对齐工具: 支持不同训练框架及同一框架不同版本间的确定性对齐，通过计算图快照、数值容差分析和核心指标校验，建设项目 CI 流程，确保业务零效果回退。

支持业务关键特性: 负责特征重要性评估、数据预处理、参数不规则加载、特征工程库等需求开发，保障业务高效迭代。

北京达佳互联信息技术有限公司(快手) | 2020.6 - 2022.3

作为主要开发者参与 *PERSIA* 训练框架的研发。

PERSIA 基于 PyTorch 自动求导后端, 使用 Rust 实现高性能 Parameter Server, 已在 GitHub 开源, 相关成果发表于 KDD 2022。

Dense 参数通过 AllReduce 同步更新, Sparse 参数通过 Parameter Server 异步更新, 在保障训练效果的同时大幅提升效率。框架在海外推荐场景落地后, 业务指标显著提升。

主导 Parameter Server 核心模块, 负责 RPC 通信优化、内存布局调优与 Online Learning 机制。

设计并实现 Worker 端计算与通信 Pipeline, 最大化训练吞吐。

负责与 XDL、Paddle 等框架的效果对齐, 确保业务平滑迁移。

上海寻梦信息科技有限公司(拼多多) | 2019.4 - 2020.5

负责分布式 *TensorFlow* 训练性能优化, 覆盖高维稀疏、计算机视觉与自然语言处理等业务场景。

通信优化: 深入分析并优化 RPC 通信, 端到端训练效率提升 20%。

参数获取机制优化: 改进 Worker 获取参数的策略, 训练效率再提升 10%。