

李盼盼

个人信息

- 手机: 18801378981
- 邮箱: lipanpan_study@126.com
- Github账号: lipanpan03

教育背景

- 清华大学 2019.9-2022.6 软件工程专业-研究生
- 中南大学 2015.9-2019.6 软件工程专业-本科

工作经历

阿里集团 智能引擎事业部-搜索平台

2025年5月至今

1. 基于NV平台的ROLL RL训练框架和RTP推理引擎的训推一体架构演进

- 在多机多卡环境下, 支持在ROLL的Agentic和RLVR链路中根据并行度和资源自适应调度多实例RTP服务, 并实现异步在线采样功能, 支持num_beams等丰富采样参数, 提升系统动态采样效率和资源利用率
- 设计side car方案在train、infer节点和RTP引擎之间同步权重, 支持并优化megatron TP/EP/PP混合并行策略的权重收集和转换, 实现CUDAIPC和共享内存流式传输, 提升权重更新效率
- 协同开发RTP引擎KVCache虚拟显存池, 支持在采样前后动态加载和换出显存, 实现在RL链路中train和infer的共置部署
- 完成多尺寸、多任务、多资源的ROLL RTP训推一体架构, 支持Qwen2.5-0.5B Agentic、Qwen3-8B RLVR和Qwen3-30A3B RLVR的ROLL RTP链路, 在训练效果持平的前提下, 整体训练性能提升20%
- 承接淘宝闪购Qwen3-0.4B后训练商品推荐业务, train和infer混合部署节省一半显卡资源, 使用RTP替换VLLM支持高性能beam search功能, 采样和端到端训练性能提升10%

2. 基于AMD平台的ROLL RL训练框架和RTP推理引擎的训推一体架构演进

- 设计开发DinD方案在AMD上支持ROLL RTP训推一体架构, 在单机多推理架构上使用side car dump共享模型方式实现权重更新, 服务热重启实现显存动态管理以支持train和infer共置部署
- 支持Qwen2.5-0.5B agentic, Qwen3-8B RLVR和Qwen3-30A3B RLVR在多机多卡分布式环境的ROLL RTP链路, 与NV训练效果对齐; 支持checkpoint上传和分布式断点续训功能, 提升训练稳定性
- 基于Qwen3-30A3B RLVR训练链路调优megatron训练引擎并行策略, 2PP8VP2CP2EP相比1PP4CP4EP的baseline在训练效果不降的前提下性能提升54%
- 使用ROLL Head在k8s集群上用特权容器支持ROLL RTP训推一体架构, 提升弹内MI308X卡型的训推利用率

3. 基于多源推理引擎和异构卡型的模型支持与性能调优

- 在VLLM上开发BGE-M3 embedding模型, 支持生成稀疏和稠密embedding向量, 对齐RTP上BGE-M3模型能力
- 承接高德AI探索推理优化业务, 对Qwen3-30A3B的RTP模型服务采用attention后端换用flash infer、结构化输出的prompt engineering、重训练MTP模型和PD分离部署手段, 将服务延迟降低67%, 吞吐提升10倍; 对高德RAG Qwen3-32B模型服务使用FP8量化方案提升50%吞吐
- 联合中科院共建基于国产算力的推理引擎, 在海光芯片上构建面向多元模型、全尺度输入输出、多部署场景的海光算力立体评估矩阵, 得出海光在prefill-only场景下性能最优, 定位到海光和NV的差距主要在带宽和软件栈, 为推理引擎性能优化提供方向
- 在内源VLLM上支持GLM 4.7 Flash、MTP模型和工具调用功能, 解决模型服务复读机问题, 结合压测脚本和Nsight工具定位性能瓶颈, 调优请求重排序阈值解决batch中小chunk prefill存在导致部分decode请求误走prefill attention链路从而影响性能的bug, 最终在内源低版本VLLM上性能无损支持GLM 4.7 Flash系列模型

4. 支持智能体模型ROME的数据合成、评测与强化学习训练

- 调度千卡资源部署多个模型服务支持数据合成和模型评测任务, 解决服务乱码和文本超长问题, 保证服务稳定性
- 参与基于百万级轨迹数据的 ROME 模型异步RL训练全流程, 针对多类数据集调优迭代以提升模型性能; 最终训练的 ROME 模型在 Terminal-Bench 2.0 上达到 24.72% 的成功率, 在 SWE-bench Verified 上取得 57.40% 的任务完成率, 充分验证了基于语义块的 IPA 算法设计合理性与 ALE 全栈 agentic 学习基础设施的工程有效性

1. 蚂蚁自研图数据库 TuGraph 查询引擎开发

- 引入 geax 模块同步支持 Cypher 和 GQL 语言解析，统一 AST 层，重构查询计划生成、原生存储过程等功能，优化支持嵌套列表推导式等功能，同时支持 GQL-FinBench 和 Cypher-SNB 两个功能测试
- 优化 Cypher/GQL Optimizer CBO 框架建设，开发查询下推，PathChain 起点选择等功能，重构优化器实现，支持执行计划优化 case

2. 蚂蚁自研图数据库 TuGraph CS 架构开发

- 基于 raft 协议设计改进 TuGraph 高可用架构，开发生心跳机制维护集群信息，支持异步快照提升写入性能，开发定时快照降低系统负载，支持 witness 角色节省系统资源，并开发集群管理工具灵活上下线节点。在富滇银行和内部业务共计上千核上部署 TuGraph HA 模式，提升了业务稳定性
- 开发基于 rpc 的 CS 通信接口，并将 LDBC-SNB 的 29 个复杂读写查询算法实现为 TuGraph 内置 procedure，client 可直接通过 rpc 接口调用。使用该架构参加 LDBC 官方打榜，蝉联榜首并刷新世界记录，获得蚂蚁集团年度技术突破创新奖
- 开发 TuGraph 高可用 rpc client SDK，采用轮询方式支持读请求的负载均衡，支持多种连接模式和多种主流语言，服务内外部部署和可用集群的所有用户

论文与专利

- 李盼盼, 宋韶旭, 王建民。时间序列对称模式挖掘 [J/OL]. 软件学报, 2022, 33 (3): 968. DOI: 10.13328/j.cnki.jos.006453.
- 蚂蚁云创新数字科技有限公司。一种基于外排序的图数据库快速在线全量导入方法: CXANT1989822, 2024-01-03 [P].
- 清华大学。一种时间序列频繁对称模式挖掘方法及装置: CN110990463B, 2021-01-15 [P].

荣誉奖项

- 中国高校计算机大赛团体程序设计天梯赛华中赛区第二名（团队一等奖）
- 美国大学生数据建模大赛 M 奖
- 全国大学生交通科技大赛国家一等奖