

洪斌

籍贯: 浙江衢州
现居: 上海市

☎ (+86) 1373-222-1328
✉ hong7083@126.com

个人履历

- 2025.04 - 至今 携程集团, 技术中心 AI 研发部 AI Infra 组, 资深算法系统工程师
- 2019.10 - 2023.06 阿里巴巴达摩院, 城市大脑实验室, 算法工程师
- 2016.10 - 2017.10 美国密歇根大学 EECS 系, 联合培养博士生
- 2013.09 - 2019.09 浙江大学, 计算机学院 CAD & CG 实验室, 机器学习组, 博士研究生
- 2009.09 - 2013.07 浙江大学, 数学学院, 数学与应用数学本科 (4/60)

项目经历

- 2025.04 - 至今 Peta Training 分布式大模型后训练框架
 - 落地 ms-swift、veRL 开源框架, 支持集团大模型的百卡级分布式并行后训练, 涵盖主流的 SFT 和 RLHF 训练方式。
 - 针对 VLM 模型, 在 ms-swift 框架上开发 batching/packing 策略, 实现 SFT 加速比 1.5x-2x。
 - 通过流水线 P2P 通信优化、选择性重计算、算子优化 (Grouped GEMM, SonicMoE) 等技术, 实现 megatron 算力利用率 mfu 提升。
 - 针对 VLM 模型, 优化强化学习框架 veRL 多模态数据分发流程, 实现吞吐提升 (qwen2.5-vl 60%+)。
 - 移植优化版 peta megatron 至 veRL 框架的 RLHF 场景, 实现 mfu 提升 (qwen3-moe 10%+)。
- 2024.01 - 2024.09 基于注意力引导的快速图像生成算法
 - 结合相关性和区域约束的注意力引导图像生成算法: 通过相关性和区域约束改进图像生成质量, 并实现加速 1.8 倍。
- 2022.10 - 2023.06 视觉计算系统中的周期性计算任务调度
 - 智能优化算法方案: 城市大脑业务中视频计算任务具有相关性、周期性。为提高计算资源使用率, 以整数规划建模复杂周期任务调度问题, 并开发进化算法求解, 实现 15% 使用率提升。
 - 强化学习方案: 为适配在线调度场景, 开发深度强化学习方案解决周期任务规划问题。
- 2019.10 - 2022.09 城市级大规模人脸识别系统
 - 大规模人脸数据半自动采集系统: 城市级数据人工标注成本高昂。开发了半自动数据采集流程, 通过地理位置信息、基础模型交叉验证, 以少量人工标注实现大规模训练数据收集。
 - 亿级 ID 特征模型: 通过模型并行解决大规模 ID 训练的显存限制问题, 实现亿级 ID 人脸识别模型训练 (十亿级样本, 16x8 GPU)。模型在 2022 年公安部安防行业竞赛所有厂商中排行第一梯队 (top5)。
 - 提升特征模型稳定性: 极端光照、模糊、遮挡等情况下识别精度衰退。通过人脸特征分布分析提出可识别性判定算法, 提升模型稳定性。
- 2016.03 - 2018.02 基于筛选的稀疏优化加速算法
 - 稀疏支持向量机快速求解算法: 提出 SVM 优化问题压缩算法, 实现两个量级的求解提速, 发表于 ICML 2016, JMLR 2019。
 - 子模函数优化加速算法: 提出子模函数优化问题筛选算法, 实现加速约 30 倍, 发表于 ICML 2018。
- 2015.02 - 2015.05 基于截断核范数正则化的在线鲁棒性主成分分析算法
 - 在线鲁棒 PCA 算法: 基于截断核范数提出新的高效在线 RPCA 算法, 发表于 Neurocomputing。

论文发表

- » Apparel-invariant feature learning for person re-identification. *IEEE Trans on Multimedia*, 2021. (第三作者)
- » Scaling Up Sparse Support Vector Machine by Simultaneous Feature and Sample Reduction. *Journal of Machine Learning Research (JMLR)*, 2019. (Multi-class extension, 第一作者)
- » Safe Element Screening for Submodular Function Minimization. *ICML*, 2018. (第二作者)
- » Scaling Up Sparse Support Vector Machine by Simultaneous Feature and Sample Reduction. *ICML*, 2017. (第一作者)
- » Online Robust Principal Component Analysis via Truncated Nuclear Norm Regularization. *Neurocomputing*, 2016. (第一作者)
- » Non-Negative Matrix Factorization with Sinkhorn Distance. *IJCAI*, 2016. (第二作者)

技能

算法技术: 机器学习、优化算法、深度学习和强化学习算法
编程语言: C/C++, matlab, python

框架: pytorch, transformers, ms-swift, megatron-lm, veRL

外语: 熟练掌握学术英语的阅读、写作和口语交流