

# 王天

18362889815 | sihouzi21c@gmail.com | 北京  
微信: 18362889815

## 教育经历

|                        |                     |
|------------------------|---------------------|
| 清华大学                   | 2021年09月 - 2024年06月 |
| 电子信息-计算机技术 硕士 深圳国际研究生院 | 深圳                  |
| GPA:3.51/4             |                     |
| 江苏科技大学                 | 2017年09月 - 2021年06月 |
| 应用统计学 本科               | 镇江                  |
| • 江苏科技大学               |                     |

## 工作与实习经历

|                   |               |
|-------------------|---------------|
| 面壁智能科技有限责任公司      | 2024年07月 - 至今 |
| AI架构师 基础模型部 基础模型部 | 北京            |

### 一：训练框架维护

概述: 负责统一 Megatron-LM 框架的搭建与维护, 支持多模态、文本、强化学习等训练场景, 集成各团队共性 feature, 减少重复开发; 持续引入Infra 优化、定期 rebase 版本并跟进开源演进, 提升框架效率与可维护性。多模态训练框架迁移: 完成多模态任务从 DeepSpeed 到Megatron-LM 的迁移, 支持Qwen3、Qwen3.5 及MiniCPM 底座VLM/Omni 模型适配; 迁移后整体时间成本降低20%, 相同数据下风洞评测更优, 提升研发与迭代效率。

- **框架计算对齐与一致性验证:** 识别 DeepSpeed 与 Megatron-LM 的关键计算差异, 并将 Megatron-LM 侧替换为 DeepSpeed 对应实现来完成上述模型单case forward & backward 100% bitwise 对齐, 验证框架迁移正确性。
- **多模态模型并行策略适配:** 完成多模态模型在 TP、CP、PP 并行策略下的适配, TP 场景下单 case 训练 loss 误差控制在 0.1% 以内, PP 场景下单 case forward loss 实现二进制一致。
- **框架能力整合与开源版本升级:** 完成文本与多模态团队共性 feature 集成, 并将仓库 rebase 至 Megatron 0.16.0 release 版本; 两侧CI 验证均顺利通过, 确认了 feature 集成与版本迁移的正确性。

### 二：大模型量化

概述: 面向高通、MTK、Orin 等商业化平台, 开展 MiniCPM、Qwen 系列模型的计算图对齐、量化适配及端侧掉点恢复工作, 支撑商业化项目落地; 高精度地量化 MiniCPM 4.1、MiniCPM-SALA, 支持模型开源发布。

- **端云计算图模拟对齐:** 基于 MiniCPM 模型的端侧 ONNX 计算图, 解析量化节点并在云侧量化流程中复现对应计算逻辑, 提升云上量化对端侧推理的拟真度, 为后续云端参数灌入提供关键支撑。
- **端侧量化掉点修复:** 针对端侧部署中的量化掉点问题, 定位到首个 token 激活值显著离群导致云上量化激活范围过大; 通过引入 prefix-cache 技术, 将激活范围压缩至原来的10% 以内, 并将端侧量化损失由 12% 降至 5% 以内。
- **商业化量化流水线构建:** 搭建并封装精度可靠的端到端云侧量化流水线并交付商业化团队, 保障高通、MTK、Orin 各商业化项目的部署效果; 通过流程自动化与标准化, 显著降低人力投入和人为失误风险, 提升交付效率与稳定性。
- **开源模型量化优化与发布支持:** 针对 MiniCPM-4.1 与MiniCPM-SALA 在GPQA、LCB、AIME 等数据集上的量化掉点问题, 持续开展追踪与优化, 通过校准集调整、prefix-cache 长度优化及 OpenCompass 中 vLLM 推理配置对齐, 将量化损失控制在2% 以内, 支持开源模型发布。

### 三：大模型端侧高效部署

概述: 负责大模型在各类端侧设备上的 GPU/NPU 适配与部署, 主导 Orin、MTK 平台落地, 参与高通平台适配; 围绕 MiniCPM 文本/多模态模型及 Qwen 系列模型, 持续解决端侧部署中的关键掉点问题, 推动模型转换流程流水线化, 保障模型稳定落地, 支撑公司商业化项目推进与市场竞争。

- **MTK 适配、调优与量产支持:** 基于 NeuroPilot SDK, 完成 MiniCPM 与Qwen 系列模型在 MTK 多款芯片上的端侧部署; 打通云侧模型转换链路, 通过 ONNX 对照与精度对拍保障推理精度, 支撑首个 LLM 端侧量产车及后续 MTK 项目落地。
- **Orin 适配、调优与商业化支持:** 完成 MiniCPM、Qwen 系列模型在 Orin 多型号平台上的部署适配, 覆盖多种开源推理框架及 NVFP4、INT4 等量化方案; 调优多框架推理参数并开展横向性能评估, 沉淀最优部署策略, 支撑多个 Orin POC 项目推进。
- **商业化交付流水线搭建:** 搭建并封装模型自动转换流水线, 在转换过程中对各阶段中间产物开展自动化评测, 提升问题定位效率; 将商业化单次交付时长从 1 小时以上缩短至 10 分钟以内, 显著提升交付效率并增强规模化支撑能力。
- **Omni 模型端侧适配可行性分析:** 通过梳理整体推理流程、测算各环节落地耗时, 进一步计算得出 6993 芯片在单工、双工场景下满足落地的decode length 要求, 从而完成MiniCPM-4.5O 的端侧适配可行性评估。

## 公开成果

- TMPD-DM: Joint Reduction and Quantization Precision Selection for Efficient Diffusion Models [arxiv: 2404.09532, First Author]
- MiniCPM-SALA: Hybridizing Sparse and Linear Attention for Efficient Long-Context Modeling [arxiv: 2026.11761]