

田丰

✉ four1er@163.com · 📞 (+86) 188-5503-0958 ·

🎓 教育背景

北京邮电大学 硕士研究生，网络空间安全 2021 ~ 2024
西安电子科技大学 工学学士，信息安全 2017 ~ 2021

💼 工作经历

腾讯，WXG 基础产品部 (智能号业务)，大模型 *Infra* (推理、部署、调度、加速) 2024.12 ~ 至今
腾讯，WXG 基础产品部 (视频号业务)，推荐架构开发 2024.06 ~ 2024.12

⚙️ 技术栈

编程语言：

- 熟悉 C++，掌握基本的面向对象思想，熟悉 C++11 特性；
- 了解常见推理引擎如 *sglang*、*vllm* 等，熟悉常用并行方法、*Speculative decoding*、*PD 分离* 等常用加速方法原理
- 了解常见模型结构如：llama3、DeepseekV3、Qwen3 等。

👥 项目经历

端到端音频模型部署与性能优化 2025.04 ~ 2025.08
项目负责人, 贡献度 100%

- 项目背景：**微信内某业务场景探索基于 *FisherSpeech*、*Kimi-Audio* 等模型的服务化能力建设与推理加速。
- 项目贡献：**
 - 模型服务化与流式输出改造。音频首 *chunk* 耗时由数十秒降低至 3s，首 *token* 耗时单轮约 30ms，多轮约 150 ~ 900ms
 - CudaGraph* 推理加速。*Torch.profile* 分析耗时，发现 *cudaKernel launch* 之间存在很多气泡，使用 *cudaGraph* 优化，改造 *KV Cache*，使用预分配的静态 *KVCache* 适配 *CudaGraph*。由于不同模型在生成 *token* 阶段使用的 *kernel* 数不同，百 *token* 生成耗时降低 20 ~ 70ms。
 - 并发请求调度。引入 *Prefill-Chunking* 与 *Continuous Batching* 技术对请求做调度，优化并发场景下的请求调度，减少长序列带来的尾延迟和吞吐波动。
 - 多轮对话推理加速。使用 *PrefixCache* 优化多轮对话长历史的 *prefill* 计算开销。1. 将 *KV Cache* 按固定大小 (e.g., 16 tokens) 切分为 *Block* 进行存储，而非逐 *Token* 管理，减少管理开销。2. 基于 *Radix tree* 与链式哈希实现前缀 *block* 匹配。3. 使用基于 *LRU* 与引用计数的驱逐策略，驱逐过久且未使用的 *KV Cache*。优化后多轮对话首 *token* 耗时由 800ms 降低至 50ms。
- 成果：**
 - 端到端单轮对话耗时由 10s+ 下降至 0.8s，多轮对话端到端耗时降低至 1s

计算资源集群调度 2025.06 ~ 2025.09
项目负责人, 贡献度 100%

- 项目背景：**数万卡集群资源利用率 <50%；资源按业务划分，各业务用卡不均；调度单位为整机 8 卡。
- 项目贡献：**
 - 计算存储统一调度系统。基于有限状态机设计并实现了一套分布式的高低优任务调度系统；支持跨地域调度、异构资源协同调度；提供监控线程与补偿线程满足业务 *Quota* 管理。任务调度收敛在 1s 内，高优资源无超卖。

- 训推资源灵活调度。离线环境提供训练推理混合调度能力。训练低谷期将资源调度至数据生产任务，训练高峰期优先保证训练任务资源满足。调度策略插件化支持。
- 服务集群弹性扩缩容与潮汐调度。生产环境资源隔离，预留部分 **buffer** 池作为潮汐资源进行调度。主控服务根据线上服务设定的 **SLO**，从请求队列、资源利用率、**ttft**、请求总延迟等因子计算潮汐资源分配。

- 成果：

- 从 0 到 1 构建数万卡集群资源调度系统，为训练、离线评估、线上推理提供动态资源调度。整体资源利用率由 50% 优化至 75+%。
- 线上服务潮汐调度，在满足 **SLO** 的前提下，资源利用率维持在 70%。

模型能力平台化建设

2025.01 ~ 2025.06

项目负责人, 贡献度 75%+

- 项目背景：微信大模型项目立项，对模型部署与体验提出需求。挑战：计算资源地域不同、存储不互通、开源推理引擎不统一等问题。
- 项目贡献：

- 模型广场开发。系统专责模型文件全生命周期的规范化管理，旨在提升业务团队在大模型部署准备阶段的工作效率。提供 1. 新模型自动同步服务。2. 跨地域存储同步服务。
- 3. 基础模型管理。流水线式实现新模型 **Day 0** 支持。
- 分布式部署系统开发。1. 统一部署框架，主从式系统架构，**worker** 节点集成 **Transformer**、**vllm**、**sglang** 等多种推理引擎，基于基座模型实现配置化部署镜像与命令管理。2. **sidecar** 模式部署 **modelagent**，专职解决模型文件的下载管理，提供 **BitTorrent** 式模型下载方案。
- 3. 支持模型服务的扩缩容、服务变更等能力。
- 模型服务灾容机制建设。1. 服务节点提供自探活机制，外部通过巡检服务来双重保证节点的可用性。2. 异常节点自建，解决因硬件故障或母机异常等原因导致整个节点不可用问题。3. 请求入口统一收敛代理层，提供请求重试、错误兜底来保证服务可用性，请求失败、异常告警能力建设。
- 支持常见并行策略，包括 **TP**、**PP**、**DP**、**EP** 等；支持 **PD** 分离、投机采样等多种加速方式部署。
- 模型评测系统开发。实现多类评测、压测数据集管理；基于 **evalscope** 实现对 **LLM**、**VLM** 模型的一键式效果评估与性能评估，构建模型能力 **Rank** 榜单，方便业务进行模型选型。

- 成果：

- 从 0 到 1 构建模型广场、模型部署、模型评测等一站式平台。
- 平台覆盖本部门与相邻业务部门，日均模型部署次数超 200。部署成功率基本实现 100%

在线推荐系统开发与性能优化

2024 年 6 月 ~ 2024 年 12 月

项目开发

- 项目背景：视频号某新场景需支持图文与词推荐，**QPS** 约万级；图文推荐耗时要求 **p99** < 3 s，词推荐耗时要求 **p99** < 0.5 s，大盘稳定性指标要求 99.999 %。
- 项目贡献：

- 基于 **TaskFlow** 构建推荐链路的 **DAG** 图，细粒度拆分业务算子，实现业务算子并行化，消除重叠小算子耗时，集中优化大算子性能。
- 性能瓶颈优化：1. 在线用户画像特征拉取耗时过高：采用异步拉取与 **KV** 转存。效果：耗时从 900ms 优化至 100ms，仅缺失上次用户操作特征，经评估对核心指标影响可接受。2. 召回通路模型推理耗时优化：原 **RPC** 的路由方式存在负载不均问题，切换至随机路由后耗时显著降低。3. **item** 特征拉取耗时优化：用户特征预填充与多路 **RPC** 并行化改造。

- 成果：

- 图文推荐在线全链路耗时 **p99** 由接近 4 s 优化至 2 s，启用预加载后 **p99** 降至 750 ms，核心指标折损 < 0.5 %。词推荐全链路耗时 **p99** 稳定在约 200 ms，大盘稳定性指标超过 99.9995 %。