

申海

(+86)134-8265-8586 | 13482658586@163.com | [GitHub](#)

教育经历

上海交通大学 | 计算机科学与技术 硕士研究生

2020.09—2023.04

- 代表性成果：发表 ACM/IFIP Middleware、CSCloud 论文，获阿里云天池大赛季军。

工作经历

某某短视频公司 研发线 | 大模型引擎架构组

2025.02—至今

- 大模型推理优化**：负责 PD 分离、量化、KV Cache Offloading、调度及可观测体系的部署开发与上线，支撑内部大模型推理服务稳定上线与持续优化。
 - PD 分离部署**：首次在某某短视频公司上线 PD 分离方案，解决 KV Cache 传输慢、服务偶发启动失败、PD 分离后 Tokenizer 耗时上升及不同 rank 间负载不均衡等问题；分析算子 Profile，优化 Two-Batch Overlap 并调整算子发射顺序，使 Kimi 模型推理性能提升 **50%**。
 - 量化优化**：参与 W4A8 权重量化、FP8 KV Cache 及私有模型 FP8 权重量化方案的设计与开发；优化 KV Cache 写入链路，融合 FP8 量化与 paged KV 写入过程，减少 kernel launch 与中间访存开销，使 FP8 KV Cache 端到端提升 **20%**；使用 TMA 优化 FP8 Fused MoE Kernel，使 FP8 权重量化相较 BF16 端到端提升 **40%**。
 - KV Cache Offloading**：主导内存与分布式 KV Cache 的开发部署，修复社区 Offloading 过程中 pinned memory 导致的内存膨胀、缓存一致性协议读到脏数据引发的 Illegal memory access 及同步导致的 Hang 等问题，相关修复已合并 SGLang 上游社区；搭建基于线上流量的缓存命中率实时模拟平台，优化后命中率接近理论极限。
 - 调度优化**：针对长 Context 实现 Chunk-size-aware 的 PD 分时调度方案，在每次 Chunked Prefill 后优先调度满足 TTFT 约束的 Decode 请求，在满足 SLO 的前提下使吞吐提升 **30%**。
 - 可观测平台搭建**：搭建推理引擎常态化可观测指标体系，覆盖 TTFT、TPOT、MTP 接受率、专家负载均衡、Tokenizer 执行时间及服务健康状态，辅助定位潜在优化点并在服务崩溃时及时告警。
- Agentic RL 训练优化**：开发维护 KRL（内部强化学习训练框架），支持多脚手架适配，并支撑 235B 模型在百卡集群上的稳定训练。
 - 吞吐优化**：在 235B 模型上完成算子调优、轨迹粘滞调度优化、sequence packing 及 KRL 多进程优化等开发适配，在 SWE-Agent/Claude Code 脚手架上相较 Base 吞吐提升 **2.8 倍**。
 - 训推一致性优化**：通过多组消融实验对比不同配置下训练引擎与推理引擎的 DKL 差异，开发 token-in-token-out 机制解决 Token Drift 带来的扰动，并实现 Agentic 场景下的 Rollout routing replay，使训推 DKL 从 **0.015** 降低至 **0.007**。
 - MTP 训练支持**：在 KRL 中支持 MTP 层在训练过程中的热更新，让 MTP 层和主模型采用不同的 Loss 计算方式，在训练过程中主模型和 MTP 层分别更新，在不影响模型效果的前提下，rollout 阶段性能提升 **35%**。
 - 稳定性排查**：重点支持 AI Coding 场景百卡集群 RL 训练稳定性，解决 SGLang Router 转发异常、沙箱启动失败、Reward 打分偏低及性能抖动等问题，保障 KAT V2 模型顺利发版。

某某短视频公司 研发线 | 系统诊断组

2023.04—2025.02

- 推荐框架与系统性能优化**：从 CPU/GPU 微架构视角定位瓶颈，推动推荐框架、内存分配器及 THP 能力规模化上线，累计贡献数千万元级业务收益。
 - NUMA-aware jemalloc 内存分配器**：缓解跨 NUMA 节点内存访问带来的 CPU 消耗，优化线程独占内存与 gRPC 全局内存分布，避免单节点带宽瓶颈，推荐策略场景吞吐提升 **10%**，获公司洛子峰项目奖。
 - Embedding Batching 优化**：针对预估服务设计并实现 Embedding 即时拷贝方案，实现 Batching 等待与 GPU 拷贝时间重叠，降低 GPU 拷贝对端到端链路的阻塞，商业化预估典型场景吞吐提升 **10%**。
 - 推荐算子优化**：通过 Nsys 分析典型预估服务，编写 TensorRT Plugin 融合特定算子；策略性引入无效 op 破坏 Myelin 低效融合，解决高版本 TensorRT 性能劣化问题，电商预估场景推理速度提升 **15%**。
 - THP 优化与规模化推广**：主导解决 THP 内存膨胀、GPU 兼容性、混部兼容及运行时可用性抖动等问题，在不影响服务稳定性的前提下于某某短视频公司 300 万 CPU 核心上线 THP，吞吐提升 **10%**。
 - 微架构优化**：应用 Top-down Microarchitecture Analysis 定位热点函数瓶颈，重构代码以提升 CPU 乱序执行效率，并结合软件预取降低访存停顿，吞吐提升 **10%**，相关优化 Pattern 已集成至 LLVM 编译器实现自动预取。

实习经历

字节跳动科技有限公司 DataAILab | 查询优化工程师

2022.06—2022.10

- 优化分布式计划中连续窗口函数执行顺序并消除冗余 Partition，查询效率提升 **15%**；设计 setInput 统一接口支持计划动态自适应调整。