

胡敬玉

1993 年 11 月 | 博士 | (+86)181-017-98126 | jyhu@mail.ecust.edu.cn

主要工作方向：大语言模型推理优化、RL 训推优化

GitHub: <https://github.com/hjyai94> 个人博客: <http://hjyai94.cn>

技能

- 熟练语言: Python
- 熟悉语言: C/C++
- 熟悉技能: Ubuntu、CentOS、Bash Shell、Git、Docker
- 熟悉框架: Pytorch、Triton、Verl、SGLang、VLLM

教育背景

- | | | | |
|----------|-----------|------|-----------------|
| - 华东理工大学 | 控制科学与工程 | 硕博连读 | 2017.09-2023.06 |
| - 江苏科技大学 | 电气工程及其自动化 | 本科 | 2013.09-2017.06 |

工作项目经历

蚂蚁集团（高级算法工程师）

2024.4-至今

岗位职责：负责百灵模型训练推理优化，包括推理框架开发以及强化学习训练推理优化。

- **Flood 推理框架开发**，Flood 框架是一个离线推理框架，旨在提高离线推理的吞吐量。

<https://github.com/alipay/PainlessInferenceAcceleration/tree/main/flood>

1. **减少通讯量**，只采用流水线并行。
2. **减少调度开销**：张量并行框架一般采用同步并行，调度期间没有任务执行。
3. **避免张量切分困难**，只采用流水线并行避免了 KV Head 不能完全被张量并行整除的问题。
4. **Segment Attention**，优化 KV Cache，提高 KV Cache 的连续性。
5. **Chunked Prefill**，利用 Chunked Prefill 实现 Prefilling 和 Decoding 阶段的计算 token 数量一致，减少流水线并行空泡。
6. **动静态 FP8 和 INT8 模型支持**，投机解码支持，多模态模型支持，PPL 优化计算。

- **FP8 RL 训练推理一体优化**

1. **RL FP8 训练推理落地**：将模型训练吞吐提升 38%，通过使用相同实验思路的训练和推理算子，降低 FP8 训练推理差异。
2. **性能定位与优化**：通过 profile 工具和日志指标定位算子的性能瓶颈，定位到更新量化权重算子多次申明显存问题，将训练吞吐从负优化到 22% 的加速。
3. **精度定位与优化**：通过单测算子，线上比较测试算子精度，对比训练推理 rollout 差异，查看算子精度问题。
4. **工程化与可复现**：输出修改的 verl，sglang 和 megatron，支持一键构建配置，将训练复现实践多 1 天到 1 个小时。

上海体素信息科技有限公司（算法工程师）

2023.4-2024.4

岗位职责：负责医疗健康大模型算法优化，实现大模型健康医疗领域知识对齐，包括预训练，有监督微调，强化学习训练；负责大模型的应用算法开发。负责眼科诊断模型的开发、优化和迭代。

基于大模型的健康医疗多模态问答系统

- **背景**：中国的慢性病发病人数近 3 亿，大多数慢性病病人并不知道自己患有慢性病。本项目旨在利用对齐的健康医疗大模型，结合多模态的数据（文本，CT，MRI，图片等），实现个性化的健康医疗问答，达到预警慢性病的目的，以及提供科学合理且具有人性化的饮食、生活习惯建议。
- **数据**：构建了完整的大模型数据收集生成及清洗流程，包括增量预训练数据收集清洗，有监

督微调数据生成，人类偏好数据标注，眼科知识水平测试数据集。

- **训练技术:** 1. 增量预训练，基于收集的医学健康书籍、微信公众号文章，增加医疗健康领域知识。2. 有监督微调，利用问答数据实现 Lora、部分参数、全参数微调。3. 训练奖励模型，学习医疗健康领域人类偏好。4. 采用强化学习对齐医疗健康领域人类偏好。
- **应用技术:** 利用检索增强生成实现个性化的病人私有历史问答选择，实现获得病人历史对话，并摘要历史信息。
- **工具调用:** 实现了大语言模型工具调用功能，调用体素眼科诊断模型，实现了眼底图像视杯视盘分割、血管分割、青光眼检测、年龄相关性黄斑病变检测等功能。
- **项目结果:** 在体素眼科知识水平测试数据中，Five-shot 结果和 Zero-shot 的结果相比于 chatglm3-6b 分别提升了 2.30 %和 1.59 %。

论文和专利

- **Mixture of Calibrated Networks for Domain Generalization in Brain Tumor Segmentation.** Knowledge-Based Systems. (一作, SCI, 一区)
- **Active Consistency Network for Multi-Source Domain Generalization in Brain Tumor Segmentation,** Biomedical Signal Processing and Control. (一作, SCI, 二区)
- **Mutual Ensemble Learning for Brain Tumor Segmentation,** Neurocomputing. (一作, SCI, 二区)
- **Dual-pathway DenseNets with Fully Lateral Connections for Multimodal Brain Tumor Segmentation ,** International Journal of Imaging System Technology. (一作, SCI)
- **Ensemble Anomaly Score for Video Anomaly Detection Using Denoise Diffusion Model and Motion Filters,** Neurocomputing. (三作, SCI, 二区)
- **RoI Uncertainty for RGB-Thermal Image Segmentation,** International Conference on Machine Learning and Machine Intelligence. (一作, EI)
- 基于条件扩散模型的眼底图像质量增强方法及系统 (专利, 初审阶段)
- Flood: A throughput-oriented Inference Framework for Large Language Model with pipeline parallelism and segmentable cache.