

薛晗

☎ 188-1020-6990 ✉ xuehancs@gmail.com 📍 北京市

个人简介

博士学历，毕业于中国科学院计算技术研究所，研究兴趣包括RL训练框架、RDMA网络、分布式系统。目前在华为担任高级工程师，主导slime-ascend RL 训练框架的从零构建与特性演进，曾深度参与verl框架权重同步模块设计和开发，RL训推一致性研究以及RDMA协议可扩展性研究。在RL权重同步通信优化及大规模RDMA网络扩展性研究上取得行业领先成果，曾获华为“创新与关键技术突破”奖，申请两篇潜高专利。博士实习主导华为区块链分布式系统性能优化，性能获信通院打榜22年度第一。

工作经历

华为技术有限公司-2012实验室中央软件院	高级工程师A	2023.09 - 至今
负责强化学习训练框架效率优化、RDMA协议可扩展性优化研究。		
华为技术有限公司-2012实验室中央软件院	实习生	2021.07 - 2023.03
负责华为区块链系统性能优化，包括高效一致性、隔离性校验和分片等技术		

项目经历

强化学习Slime框架昇腾亲和性构建与优化 2025.12 - 至今

slime是GLM系列模型的原生RL训练框架，以其极简设计、高度灵活性在业内引起广泛关注，而slime框架本身对昇腾npu不支持，因此构建slime-ascend项目以支撑华为客户对slime框架诉求。

- 作为slime-ascend官方仓的maintainer，从零完成slime在昇腾npu上部署适配，负责slime-ascend的能力构建和技术规划。支撑Qwen、GLM系列主流模型适配和bitwise级训推一致性、Agentic RL、OPD等竞争力特性构建。当前正在对Agentic RL长序列场景进行调度优化，目标消除长尾rollout带来的性能影响。
- 已支撑slime-ascend在浦江、电信等主要客户面的交付，获得客户好评。

RL训推一致性研究 2025.12 - 2026.05

训推一致性关系到RL训练的稳定性，尤其是MoE模型训练，针对华为多家客户诉求，展开昇腾npu训推一致性研究以期达成比特级训推一致。

- 算子和框架对齐：识别batch不变性相关算子，完成训推引擎的算子替换和对齐；针对框架层差异，如混精计算、融合算子拆解等完成每个模块的对齐。
- 确定性通信：提供确定性AllReduce和ReduceScatter原语，保证规约序和batch不变性，合入HCCL。
- 针对verl框架，完成vllm和megatron的Qwen3-8B和Qwen3-30B MoE模型的比特级训推一致；针对slime-ascend框架，使能sglang和FSDP的Qwen3-8B的比特级对齐。已分别交付字节和电信客户。

RL框架权重同步机制优化研究 2024.12 - 2025.11

作为部门最早投身强化学习领域的研究人员，以网络通信视角对RL训练框架的通信过程进行优化。撰写洞察报告被推荐至内部网站首页，浏览量破5k，受三层部长关注设立专项优化RL权重同步。

- 提出ring broadcast+零冗余细粒度通信编排方案，针对many to many通信模式抽象成优化问题，并基于随机化算法解决，达成权重同步时延理论最优，获得华为“创新与关键技术突破”奖。
- 参与verl社区engine化重构设计，提出ckpt engine作为框架核心模块之一，主要设计方案已被采纳。
- 主导verl ckpt engine昇腾亲和接入设计与实现，面向高性能和弹性场景，分别支持集合通信和p2p两种通信模式，基于桶粒度传输和数控分离设计实现高效传输，30B模型达成秒级同步。完成对开源组件kimi ckpt engine完成深度改造，使其支持昇腾设备和stateless集合通信，相关修改已合入社区，并接入verl。

- 提出RDMA QP虚拟化技术，时分复用可编程网卡有限资源构建虚拟QP。通过虚拟QP上下文随WQE携带，结合可编程网卡内轻量轮转保证传输可靠性。
- 方案兼容标准RoCE协议，十万级连接规模下有效带宽达到标准99.7%，技术落地计算产品线，申请两篇高价值专利。

教育经历

中国科学院计算技术研究所	计算机系统结构	博士	2019.09 - 2023.06
● 研究方向：区块链、分布式系统			
中国科学院计算技术研究所	计算机系统结构	硕士	2016.09 - 2019.06
● 研究方向：区块链、分布式系统			
● 荣誉奖项：国科大一等奖学金、国科大三好学生、先进计算机系统研究中心优秀学生			
中国地质大学（武汉）	信息工程	本科	2012.09 - 2016.06
● 专业排名：2/57 GPA：4.04/5.0（加权平均分90.4）			
● 荣誉奖项：国家奖学金、国家励志奖学金、全国高校 GIS 大赛二次开发二等奖、全国创新创业大赛湖北省二等奖			

论文发表

- Xue Han, Qun Huang, and Yungang Bao. "EPA-route: Routing payment channel network with high success rate and low payment fees." 2021 IEEE 41st International Conference on Distributed Computing Systems (ICDCS). IEEE, 2021.（分布式领域顶级会议，接收率19%）
- 薛晗,包云岗.面向EOV联盟链的高效隔离性校验方法[J].高技术通讯, 2024, 34(11):1142-1152.