

郝祥宇

(+86) 18613826919
18613826919@163.com

工作经历

阿里巴巴智能引擎事业部 — XDL训练框架 算法工程师

2021 年 3 月 - 2022年6月

主要工作: 开发分布式训练框架**XDL**, 支撑阿里妈妈搜推广业务

业务支撑: 提高**Lazada**业务的搜推广模型的训练性能, 成倍提高模型交付效率。

性能优化: 优化**PS**架构通信带宽; 优化**TensorFlow** OP调度。

AMD — AI编译器 高级软件工程师

2022 年 6 月 - 2025年6月

主要工作: 参与芯片架构**XDNA**的**AI**解决方案

算子开发: 在**NPU**上开发、优化**GEMM**、**Flash Attention**等算子。

蚂蚁金服 — 预训练算法工程师

2025 年 6 月 - 至今

主要工作: 基于**Megatron-LM**训练多模态大模型

和语言大模型相比, 多模态大模型训练有以下两个难点:

1、数据异质性: 多模态大模型输入数据包含图片、文本、音频、视频多个模态, 不同模态单条样本在模型中计算的长尾效应显著, 单样本长尾导致单个**batch**训练时常存在长尾, 单**batch**长尾导致训练在各种并行策略分组中长尾更加严重。

2、模型异质性: 多模态大模型结构为**Encoder+LLM+Gennerator**, 各部分的模型计算访存比差异巨大, 而**Megatron**设计的初衷是为了处理计算访存比相近的模型结构, 导致实际训练时**MFU**较纯语言低**40%**。

为了解决以上两个难点, 我在工作过程中主导以下两部分工作:**1.**针对数据异质性: 重构**dataloder**的**sequence pakcing**, 让单**batch**计算耗时相近, 基本消除数据长尾。

2.针对模型异质性: 实现**Encoder decoupling**, 不同部分模型在不同的集群上异步训练、采用不同的并行策略。以上两点使得**LLM**经过大量消融实验验证过的并行策略可以在多模态大模型训练过程中被复用, 最终**MFU**相比原生**Megatron**提升**30%**, 达到**LLM**的**90%**。

教育背景

北京交通大学 — 本科 软件工程

2014 年 9 月 - 2018 年 6 月

北京航空航天大学 — 研究生 集成电路工程 **AI**硬件设计

2018 年 9 月 - 2020 年 12 月

技能

C++

Linux

Tofel 101分

TensorFlow

CUDA

LLVM

TVM

Megatron-LM

项目经历

MyPEViewer项目: 快速分析Windows下PE文件的header, 便于逆向分析
<https://github.com/GUESO/MyPEViewer>

FireWatch系统: 在多线程场景下使用**OpenCV**和**OpenPose**提取加油站中监控器摄取的人物姿态, 并分析人物姿态可能代表的危险动作以防引起火灾。

论文: 参与论文《**Time-Domain Computing in Memory with Spintronic for Energy-Efficient Convolutional Neural Networks**》计算性能分析。