

Alex

联系方式：15024436975 | lucianhao@qq.com
大模型推理引擎技术负责人 | 8年系统优化经验 | 带队10人

专业技能与核心优势

1.极致性能优化能力：构建了从编译器（LLVM/XLA）、运行时到AI框架（SGlang/TensorRT-LLM）的全栈优化技术栈，深度适配NV/AMD/ARM及国产芯片。**从0-1组建团队并主导了大模型端到端分布式推理系统的架构设计**，在保证99.9%以上可用性的前提下，**将自研Diffusion模型推理性能提升至领先TensorRT的5倍以上、开源模型LLM/VLM领先SGlang社区5~11倍**。使得多个核心业务（自研Diffusion模型、DeepSeek、Qwen-VL、腾讯会议等）**性能达到业界领先甚至第一**；

2.技术战略与前瞻规划能力：通过对行业推理引擎架构选型、技术演进路线的深度分析，结合全链路深度的性能剖析，在FP8/FP4量化、KVCache、推理调度优化、算子优化、图优化、编译优化、资源调度等多个方面取得技术突破，不仅解决当下性能瓶颈，更为未来2-3年的业务扩展和硬件演进预留架构空间，确保技术投资的长期回报；

3.驱动顶级商业结果的能力：始终以商业价值为导向，将技术优势转化为核心竞争壁垒与营收增长。通过优化实现百万Token成本对比阿里云/火山引擎低12%~56%（同模型同机型），为大模型业务建立关键竞争优势，带来数十亿级年化成本节省，支持每周数万亿Token调用(可用性99.95%)，端到端服务10+外部商业化客户（智谱、MiniMax等），**助力年营收增加数亿**；

4.平台化与规模化的思维与实践：致力于将点状技术突破产品化为可复用的系统性能力。将高性能优化能力标准化，实现“零人工干预”下模型性能提升60%-200%，并赋能业务团队自主优化，成功支持**50+个业务场景的成本优化目标**，实现技术能力的规模化输出与商业变现。

5.全链路端到端交付能力：具备从技术规划到端到端交付的全链路能力。负责10人技术团队的管理，主导技术规划、架构评审与人才梯队建设。擅长复杂跨团队协作，主导的多个公司级项目均实现如期超额交付，并培养出多名可独立负责重大项目的技术骨干，形成了可复用的协同流程与管理范式。

工作经历

一、快手-大模型训推优化工程师(E10)

2024.05-至今

【项目一】 LLM/VLM推理优化

2024.12~至今

作为推理引擎方向负责人，围绕 DeepSeek、Qwen 等模型在 H200/B300 平台上的推理性能与成本优化，负责关键路线规划、方案选型与专项落地，持续推动推理引擎能力从单点优化走向平台化复制。

➤ **从技术追赶到技术突破：**通过在H200/B300上全链路细致的性能分析和定制优化，在快手场景下实现了全链路的优化，除深度整合业界、高校、硬件厂商(Nvidia等)先进优化技术外，**自研了多项优化：**

■ 主导机内时分 PD 分离架构设计与核心实现：

◆ **问题定位：**通过对 H200 集群全链路 profiling，定位到核心矛盾：离线场景请求呈现 Prefill/Decode 严重不对称，社区 SGLang 混合调度下卡间同步等待导致 CUDA Graph 无法启用，GPU 空转损耗成为首要瓶颈。

◆ **架构决策：**判断机内时分 PD 分离相比跨机方案 ROI 更高（无额外网络开销）；主导从 0 设计并实现：
① 重构全局调度器，时分动态编排 P/D 批次，消除同步互等，Kernel 间隙减少 50%，GPU 利用率提升 30%；
② 重新设计 DeepEP Mode 决策逻辑，根据 Batch 类型自动切换 Normal/Low-Latency 模式，重构 Dispatcher 支持双模运行时；
③ 引入 Decode 优先策略，维持大 Batch 并行度。

◆ **成果：**在相同硬件配置下对比 SGLang 社区最新版，Qwen/DeepSeek 等模型离线场景单 Decode 吞吐提升 10 倍+。

■ **主导小集群场景的调度策略重构：**面向垂直领域私有化部署和低干扰流量场景，重构 Prefill/Decode 调度逻辑，基于实时 SLO 状态动态编排 P/D 资源，在保障服务目标前提下，使 Qwen、MiniMax 等模型在小规模部署场景中实现 3~5 倍吞吐提升，形成区别于标准 PD 分离方案的场景化优化能力。

- **带领团队推进量化与核心算子专项落地：**针对社区 KV Cache 方案在 Decode 阶段存在明显性能损失且精度难以满足业务要求的问题，负责 FP8 KV Cache、FP8 FlashMLA、Per-tensor 量化、Fused_qkCat 等专项的路线规划、方案评审与效果验收，推动相关能力在 DeepSeek R1 等模型中落地，在典型离线场景下取得 50%+ 性能收益。
- **牵头推进 VLM 全链路推理优化：**围绕多模态请求链路中的数据下载、跨进程传输、显存管理与连续 Decode 等瓶颈，推动多媒体全异步下载、CUDA IPC、SHM 加速传输、显存可控 GPU 加速等 10+ 项专项优化落地，在不同 VLM 场景下带来 70%~1000% 的吞吐与利用率提升。
- **负责大规模分布式推理方向的优化规划与推进：**面向 DeepSeek V3.2、GLM-4.7、Qwen-3.5 等千亿级模型在复杂流量和长输入输出场景下的推理问题，带领团队分阶段落地 PD Post Alloc、NVFP4、FP8 KV Cache、Fused MoE/MoE Gate 等算子优化，以及 QoS 感知与自动弹性能力；对比社区 SGLang，多款模型实现 300%~650% 的吞吐提升。
- **从技术专项到平台化复制：**构建自动化调优流水线与QoS感知调度，将量化、算子优化等能力转化为标准化、平台化能力，在10+款模型实现“零人工干预”性能提升60%-200%，成功支持快手50+个业务场景(通过框架易用性建设，使得业务可自行落地并做性能调优)及10+外部商业化客户（智谱、小米、月之暗面、MiniMax等）。
- **业务与商业结果：**实现DS/Qwen/自研模型推理性能11倍于SGLang社区，百万Token成本低于头部云厂商12%-56%，驱动数十亿年化成本节省；**支撑50+业务场景及10+外部客户，实现P80+模型盈利，助力数亿元高毛利外部营收**，在万亿Token/周调用下实现可用性99.95%；为快手MaaS业务建立了性能壁垒，使得性能(低成本)成为了平台的关键竞争优势之一；

【项目二】 Diffusion大模型推理优化

2024.05~2024.11

负责快手音视频 LPM 系列图像增强模型（DiT架构）的推理优化专项。该系列模型线上占用过万张GPU，围绕“图优化 + 量化 + GPU 利用率提升 + 编译优化 + 算子优化”五个方向推进系统性优化，推动自研 Diffusion 推理能力形成对 TensorRT 的显著优势：

- **计算图优化：**（1）MLP层：将Gelu Plugin拆分为Elementwise+Activation组合引导Myelin完成更优整体融合（1.11x）；（2）MLP-LayerNorm层：手动分割图结构实现混合精度差异化融合，兼顾FP16/FP32精度与融合效率（1.30x）。
- **自研混合精度量化：**针对四个子模型（DiT/VAE/RRDBNet/CLIP）设计差异化量化策略（DiT用FP8/VAE用INT8），结合Pytorch Quantization+TensorRT Q/DQ layer API构建量化Pipeline，通过权重Min-Max+激活值Entropy差异化校准+精度敏感层保护，延迟降低40%~81%，精度损失较常规方案下降两个数量级，性能领先NV Modelopt 15%~47%。
- **GPU利用率极致优化：**时分：推理与后处理隔帧并行，GPU Util 72%→97.79%；空分：MPS+基于Kernel亲和关系的GPU内部资源调度，SM利用率92%→98%，累计工程侧再提升30%+吞吐。
- **AI编译优化：**改进LLVM中NV/AMD GPU代码生成的LSV/SCEV等Pass向量化分析能力，解决预加载寄存器属性缺失与算子融合参数超限等问题，实现跨平台向量化能力对齐，多个算子性能提升4.6x。
- **算子优化：**适配FPSA（Fused Permuted Self Attention）、SageAttention等，提升超过20%性能。
- **成果：**累计性能提升5.35x~6.99x，精度无损通过四项画质评估，年化节省机器成本数亿元。

【项目三】基础大模型训练优化

2025.4~至今

- **可灵视频生成模型训练算子研发：**针对可灵MMDiT多模态训练中的性能瓶颈，规划并主导研发多项Triton训练算子：Sequence Permute、Fused Varlen RoPE、JVP Flash Attention、将大量slice/cat/repeat操作融合为单一kernel，消除反向传播中的empty+fill+d2d冗余算子；助力可灵训练MFU提升。
- **代码生成大模型Agentic RL训练优化：**规划KRL训练框架全链路优化方案，推动多个脚手架适配（Claude Code/SWEagent等，成功率95%+）、Megatron Fused Attention适配Blackwell、Sequence Packing降低PP空泡、RolloutManager多进程重构，机内时分PD分离+调度优化，端到端训练吞吐提升2.8x。

核心成就：作为核心技术 owner 之一，负责腾讯云数据库、腾讯会议等重点业务的编译优化与性能攻坚，推动编译器反馈优化、向量化优化、图优化与量化方案在大规模线上场景落地，支撑业务性能达到业界领先，并累计带来数十亿级年化成本收益。

1. 腾讯云线上多架构多种大型业务编译优化/推理优化落地

1.1 推理优化

- GPU推理优化：社区基于TensorRT原生API可实现全局性能最优，通过手写算子可以做到局部最优，但无法二者兼得；我基于TensorRT原生API重构Transformer模型，通过编译优化+图优化技术（MLP/LayerNorm结构重组）兼顾全局最优与局部最优、叠加混合精度量化，实现优于NV TensorRT 3倍吞吐；
- CPU推理优化：通过INT8量化和混合精度计算方案，探索了Cortex-X2/A710/A510 等一系列处理器扩展指令级在 INT8 矩阵乘上的应用。使得带宽瓶颈的算子加速比达8.3X，矩阵乘和卷积等计算瓶颈的算子加速比达4.7X，在ResNet50/VGG16上性能领先竞品一倍。

1.2 编译优化

- 主导腾讯云数据库及腾讯会议的全栈性能优化，通过编译器反馈优化（解决业界AutoFDO与Bolt/Propeller无法叠加的难题）、向量化优化(多个向量化Pass改进)、软硬协同调优及高性能计算库优化增强等关键技术，实现性能、能效、成本的多维突破：
 - 数据库类产品：4款数据库产品平均获得性能提升10%~40%，助力TDSQL在权威评测中性能业界第一，平均核数节省25%，月均节省成本数千万元；
 - 腾讯会议：研发6项优化，助力3个关键媒体模块性能提升30%-50%，整体CPU使用率下降约35%，月成本节省达数千万级，助力腾讯会议性能达到业界第一。
- 跨团队协同与交付：牵头推动跨 BG 多团队协作，统筹性能分析、方案拆解、任务分工、压测部署与效果评估，完成重点项目的端到端交付；沉淀出可复用的协同流程与推进机制，支撑复杂优化项目的规模化复制。
- 输出行业级技术影响力与平台化资产：成果获腾讯2021年、2022年度技术突破奖及业务突破奖，获腾讯云与集团官网专题报道；与Intel联合发布白皮书，于双方官网公开，形成行业技术标准参考。并将优化方法论与工具链沉淀至公司性能平台与编译器基础设施，推动优化能力工具化、平台化、规模化；

2.腾讯信创迁移平台及性能分析优化系统

主导腾讯核心产品在国产芯片上的全栈适配，带领6人小组基于编译器实现100+条迁移与性能规则，落地多个云产品获得30%+性能提升，助力腾讯云获取多个行业信创订单。 [报告1](#)、[报告2](#)。

核心工作：为多款国产ARM、RISC-V芯片深度优化编译器(GCC/LLVM)，通过深度分析芯片微架构特性，在中端IR实现多种代码优化如Reorder、Butterfly、Outline，在编译器后端针对指令选择、指令调度、指令生成实现了多项优化，助力多个场景性能提升10%。

教育经历

2018.09 - 2021.06	硕士 中国科学院大学	计算技术研究所/人工智能学院	计算机技术
2014.09 - 2018.06	本科 河北师范大学	数学与信息科学学院	计算机类

论文-专利

1. Alex, etc. "SegQuant: A Semantics-Aware and Generalizable Quantization Framework for Diffusion Models", CVPR 2026（负责研究方向规划与技术指导）
- 2.Alex, etc. " Referee: a Pattern-Guided Approach for Auto Design in Compiler-Based Analyzers", (SANER 2020)(CCF-B);扩展版被推荐至期刊Empirical Software Engineering(CCF-B)
3. Alex等. 用于编译器代码检测的规则扩充方法， 专利号：ZL201910608055.3
4. Alex等，一种程序更新方法、装置、设备及存储介质, 专利号: ZL 202211166575.1