

## James

技术负责人

电话：153-6179-0852 | 邮箱：xgs1951@hotmail.com

## 个人简介

具备 15 年以上后端平台与 AI 基础设施建设经验的资深技术负责人，长期负责数据密集型、平台型业务中的大模型工程化落地。擅长以“后训练+推理优化+Agent 编排”为核心，将大模型能力沉淀为可复用的平台能力（LLMOps/MLOps、检索增强、在线推理、监控与治理），在强合规（GDPR 等）与高可靠性约束下实现规模化交付。强调以业务指标驱动平台演进，兼顾成本效率、稳定性与长期可维护性。

## 工作经历

### 字节跳动 / TikTok — 技术 leader (2024.03 - 至今)

- 作为公司级后端与 AI 治理基础设施平台负责人，在严格监管与高可靠性要求下负责整体架构设计与规模化落地。
- 主导大模型“后训练 + 工程化”体系建设（微调、强化学习、评估与灰度发布），将模型能力稳定注入内容理解、推荐安全与策略执行等核心链路。
- 设计并落地端到端 MLOps / LLMOps 平台，覆盖实验、训练、发布、在线推理与运行期监控，实现模型全生命周期治理。
- 构建基于 Transformers、vLLM 与 Agent 框架的 LLM 应用基础设施，支撑多步骤任务编排与自动化决策工作流。
- 以隐私合规为前置约束（数据最小化、访问控制、可审计与运行期治理），通过统一 Serving 架构与容量治理，在保持严格 SLO 的前提下将整体成本降低约 30%，并支撑中、美、欧多区域重大上线，保持零关键事故。

### Seeking AI, 深圳 — 联合 CEO / COO (2023.07 - 2024.03)

- 负责工业 AI 产品的 AI 平台与后端基础设施整体规划，统一算法、数据与工程交付路径，推动产品从原型验证走向规模化落地。
- 落地预测分析与计算机视觉质检系统，构建数据采集、训练、在线推理与反馈闭环，支撑工业场景下的长期稳定运行。

- 构建基于大模型的 AIGC 与 LLM 辅助研发平台，覆盖代码生成、测试辅助与知识检索等场景，探索 LLM 在工程效率与平台治理中的落地方式，使整体研发效率提升 20% 以上。

#### 腾讯，深圳 — 技术总监 (2018.07 - 2023.07)

- 作为平台与基础设施负责人，长期负责后端、数据平台、DevOps 与 AI 辅助工程体系建设，支撑亿级用户内容与算法驱动业务在高并发、高变更环境下的稳定运行。
- 主导算法工程化与 MLOps 平台建设，统一数据准备、实验、训练、发布与监控流程，使算法能力能够持续、可控地规模化服务业务。
- 构建面向算法团队的数据与特征支撑体系，打通数据采集、特征加工、模型训练与线上推理链路，显著缩短模型验证与业务决策周期。
- 负责推荐、排序、内容理解等核心算法系统的工程支撑，其技术范式与招聘领域的人岗匹配、推荐与搜索平台高度同构。
- 建立平台化 CI/CD 与实验治理机制，推动平台能力在多团队间复用，使实验与发布周期整体下降 40% 以上，并持续提升整体交付效率与系统稳定性。

#### Snap Inc., 洛杉矶 — 工程经理 (2015.01 - 2018.03)

- 作为早期平台负责人之一，在公司高速增长阶段主导后端与 AI 基础设施建设，基于 AWS/GCP 混合云架构，支撑高并发、快速演进的业务场景。
- 设计并运营高可靠、可弹性伸缩的后端与自动化体系（EC2/S3/EKS/ELB/Auto Scaling 等），在性能、成本与稳定性之间实现长期平衡。
- 推动多云架构评估与平台可移植实践，沉淀可复用的工程基线与平台能力。
- 构建算法工程化支撑体系（实验、训练、发布、监控），通过平台化 CI/CD 治理与实验规范化，使算法实验与发布周期整体缩短 40% 以上，并提升业务决策效率。

#### 微软，西雅图 — 高级软件开发工程师 (2007.06 - 2015.01)

- 作为 Active Directory 与 Azure AD 的核心工程师，负责超百亿对象规模的系统架构与可扩展性优化。
- 主导面向百亿级目录对象规模的系统架构与可扩展性治理，保障系统长期稳定运行。

## 教育背景

迈阿密大学 — 电气与计算机工程硕士，2007（GPA 4.0/4.0，全额奖学金）

东南大学 — 自动化学士，2003

## 认证

Google Professional Cloud Architect（谷歌专业云架构师）

## 论文与专利

40+项授权专利，9+篇论文，覆盖 AI 基础设施、后端平台、MLOps、可靠性工程与自动化等方向。