

Karl

工作经历

小红书 | 机器学习系统负责人 | 2025年8月-迄今 (8个月) | 现场办公

1. 广告、搜索&推荐推理优化

- 主导广告/搜索/推荐推理基础设施端到端转型, 完成TensorFlow到PyTorch迁移, 通过智能内核生成、ML编译器创新和底层内核优化实现推理延迟降低~20%
- 推动AI编译技术融入特征提取流水线, 实现平均吞吐量提升~1.4倍, 推理延迟进一步降低~20%

2. 大语言模型 (LLM) 方向

- 创立并领导AI基础设施团队, 设计并落地RedMegatron、RedveRL、RedSGLang——业内首个支持扩散LLM的预训练/后训练/推理统一框架
- 2026年1月基准测试显示, 预训练吞吐量较SOTA方案Lightning SMDM提升高达~11倍, 后训练和强化学习阶段提升高达~20倍
- 实现块扩散LLM推理优化并集成至SGLang, 在GPU/PPU硬件上较官方SGLang (commit 53609e5) 延迟降低~80%、吞吐量提升~5倍

3. AIGC方向

- 主导视频超分与修复 (VSR) 方案推理性能优化, 通过混合精度调优和超大内核优化, 在GPU/NPU/PPU多平台实现吞吐量较TensorRT基线提升~43% (2025.12数据)

腾讯 | 深度学习框架高级专家/PCG C++委员会成员 | 2020年5月-2025年8月 (5年4个月) | 深圳 现场办公

1. 大语言模型 (LLM) 领域

- 开源LLM推理引擎Ksana(一念)创始人及核心贡献者 (<https://github.com/Tencent/KsanaLLM>), 2025.06.13测试中, 在DeepSeek V3/R1上为ima.copilot、QQ AI Agents等提供服务, 吞吐量较SOTA框架SGLang/VLLM提升45%
- 腾讯混元大模型AI基础设施开发者, 聚焦NVIDIA GPU、华为昇腾NPU、燧原/紫霄GCU硬件适配

2. 计算机视觉 (CV) 推理领域

- Venus AI绘画引擎核心创始人之一, 聚焦VLM/扩散模型 (视频/图像生成) 推理加速, 支撑腾讯智影、王者荣耀/和平精英等游戏资产美术生成

3. 推荐模型训练&推理领域

- 腾讯PCG异构机器学习平台Numerous(无量)核心创始人之一, 支撑QQ/腾讯视频/QQ音乐大规模推荐模型训练推理, 日处理查询超100亿次
- GameLoop国际联邦学习框架主架构师 (<https://www.gameloop.com/>)
- NVIDIA HugeCTR核心贡献者, 与NVIDIA团队合作开发, 打破2020/2021 MLPerf训练框架性能世界纪录

4. 公共技术贡献

- 参与腾讯工程师晋升评审, 规划AI/ML领域技术蓝图, 为公司级基础设施贡献核心代码

5. 奖项与专利

- 奖项: 2024腾讯PCG H1 CVP技术创新奖、2024腾讯技术突破奖铜奖; 2020-2023连续四年腾讯优秀员工; 2020腾讯研发卓越奖、开源协作奖; 2021-2023腾讯开源协作项目优秀贡献者
- 专利: CN118446316A

阿里巴巴集团 | 深度学习平台工程师 | 2018年10月-2020年5月 (1年8个月) | 杭州
现场办公

阿里达摩院自动驾驶实验室-自动驾驶物流车项目

1. 训练领域

- 图优化与神经网络剪枝、深度压缩与量化算法、知识蒸馏方法研究
- 基于AutoML-Keras实现硬件感知的神经架构搜索 (NAS)

2. 推理领域

- 基于TVM的算子调优与优化, 为NVIDIA GPU/华为NPU开发定制化算子
- 负责小蛮驴自动驾驶边缘推理引擎开发

NVIDIA | 深度学习软件工程师 | 2016年5月-2018年10月 (2年6个月) | 上海

1. TensorRT项目

- 参与TensorRT 4.0+核心功能开发、5.0+候选版本研发, 基于Python/C++在DrivePX2/Jetson TX2/TX1平台完成多模型推理性能调优与GPU优化
- 实现INT8/INT4权重量化与校准方案

2. cuDNN项目

- 基于Python/C++在DrivePX2/Jetson TX2/TX1平台完成cuDNN性能调优

3. 自动化项目

- 参与GFE、GFN、COSMOS自动化项目研发

教育经历

上海大学 | 高性能计算与并行计算 | 硕士学位 | 2013年-2016年 | 成绩: First honour

- 荣誉: 2015年国家研究生奖学金、2014年全国研究生数学建模竞赛二等奖
- 实习/项目: 2014.06-2015.08

英特尔上海研发中心DCG-PVL分布式自动化测试系统实习生; 2014.12-2015.01 参与Ksudi Android App开发

广州大学 | 信息安全 | 学士学位 | 2009年-2013年 | 成绩: 3.75

- 荣誉: 2011年全国信息应用技术竞赛二等奖、2011年广东省AFC挑战赛金奖、广州大学AFC挑战赛奖项

专业技能

1. 框架/平台: PyTorch、TensorFlow、TensorRT、cuDNN、HugeCTR、KsanaLLM、Numerous(无量)、SGLang、VLLM
2. 硬件适配: NVIDIA GPU、华为昇腾NPU、燧原/紫霄GCU、PPU、DrivePX2、Jetson TX2/TX1
3. 核心技术: LLM推理/训练优化、AIGC/VSR性能调优、推荐系统训推、CV扩散模型加速、AI编译、内核优化、混合精度调优、量化压缩、联邦学习
4. 编程语言: C++、Python、CUDA、TVM、AutoML-Keras
5. 其他: 分布式系统、异构计算、容器云GPU资源管理、MLPerf性能优化、专利研发、开源项目主导