

李思源

手机：15300857513 · 邮箱：sjtultj@outlook.com · 年龄：35

教育背景

上海交通大学，计算机科学与工程系，博士 2013 - 2018

- 论文: 在 ASPLOS、TCAD、DAC、DATE、ICCD、ICCAD 等主流会议期刊发表十几篇论文

西安交通大学，计算机科学与工程系，学士 2009 - 2013

职业经历

字节跳动，系统研发工程师 2024-至今

- 工作职责：负责高性能推理系统研和训练框架研发

商汤科技，高性能计算与推理部-云端计算部门负责人 2023-2024

- 工作职责：负责 PPL 云端计算的技术研发、整体负责 PPL.LLM、PPL.SD Pipeline、PPL.NN 的研发以及 PPL 的国产化适配

商汤科技，高级系统研究员, PPL GPU 技术负责人 2018-2023

- 工作职责：负责 OpenPPL 的技术研发、PPL 的业务推广、PPL GPU 的技术研究

项目经历

大规模强化学习基础设施建设与算法加速优化 2025.01 - 至今

工作职责：负责团队的分布式 RL 框架底座建设和核心组件优化

- 统一分布式训练底座：主导开发 Ver1 为 Core 的 ATuner 后训练框架，解耦业务代码与 verl 代码，统一 Code 和多模态算法团队的代码仓库合实验流程，成功支持 Qwen 系列/Qwen-Coder/QwenVL/GLM 等模型的 RL 和 SFT 训练, 大幅提升团队研发效率。
- 全异步架构与核心模块优化
 - 全异步架构: 设计实现 Fully Async RL 训练架构，在 Tool-use 及 Multi-turn 场景训练性能提升 1.5X。
 - 模块优化: 分析训练流程瓶颈，实现异步 Checkpoint 存储，实现基于 Ray Remote 的异步 Reward 机制（5min 降至 20s 内）。实现 Reward Cache，大幅度降低 Reward 的开销。
 - 通信与存储: 针对多模态训练，设计使用 Object Store 源数据存储方案，降低 head 节点存储压力；在 Worker 内部实现源数据展开，成倍降低冗余数据传输，保障了系统的高可扩展性。
- 前沿算法加速探索
 - 无模型投机采样: 深入剖析 RL Rollout 轨迹相似性，设计实现 History 信息的投机采样方案（无需 Draft Model），将 Rollout 推理吞吐提升 50%。核心代码集成至 verl 仓库，成果已被系统顶会 ASPLOS 2026 接收。
 - 低精度训练 (FP8): 与 NVIDIA 联合攻关 Low Precision RL 训练，成功应用 FP8 精度，模型训练端到端性能提升 30%。
- 训练可复现性与稳定性研究
 - 训练可复现性: 全面排查并解决 RL 训练的可复现性问题，分析各个阶段可能引入的随机性问题，实现算法可稳定复现，提升了研发效率和算法可靠性。
 - 训练稳定性: 配合算法研究完成 RL 训练稳定性的研究；针对 MoE 模型的训练稳定性问题，实现 RouterReplay 和 Rollout Router Replay，并贡献到 Megatron 和 verl 的代码仓库。(相关 PR: [4101](#)、[3694](#)、[2101](#)、[2693](#))

多模态模型训练和推理系统 2024 - 2025

工作职责：负责多模态大模型的底层训练 Pipeline 搭建及推理架构设计

- 训练 Pipeline: 实现基于 FSDP 和 Megatron 作为 backend 的训练 pipeline。
 - 模型支持: 支持 Image/Video/Onevision 模型，支持 CLIP/SigLip/NaViT 等多种 encoder，支持 LLaMA、Qwen 等多种基座语言模型，7B-72B 模型尺寸。

- **核心功能**: 支持多阶段训练; 支持序列并行; 添加 FA3 支持, 并使用其核心算子优化 (RMSNorm、RoPE 等);
- **推理部署系统**: 实现基于 Ray Serve 的推理部署方案, 实现基于流量的动态扩容扩容功能, backend 支持 vLLM 和 TensorRT;
 - **推理性能优化**:
 - * 深入 Profiling vLLM Serving 吞吐瓶颈, 引入 GPU 替代 CPU 执行 CV 前后处理, 利用多线程重构 Vision 数据编解码模块, 模型吞吐提升 2-4 倍 (单卡 QPS 0.2->0.89)。
 - * 采用 TensorRT 加速 Vision Encoder + TensorRT-LLM 加速 LLM 模块的异构方案, 实现近 10 倍的性能提升 (单卡 QPS 0.2->2.19), 性能优于 vLLM 版本。
 - **vLLM 开源社区贡献**: 为 vLLM 框架添加 Video 模型底座支持, 定义 Video Serving 的接口标准, 并成功推广合并至 vLLM 社区。(核心 PR: 8486、8905、10020)

开源 OpenPPL 项目, OpenPPL 作者 & 核心开发者之一

2020 - 2022

工作职责: 负责开源推理引擎的开发设计, 底层核心算子优化和图优化

- **算子与架构突破**: 负责 NVIDIA GPU 平台卷积、GEMM 等核心算子研发, 综合运用微架构指令优化与代码生成 (Code Gen) 技术, 核心算子性能超越官方 cuDNN 库。配合图优化, 相比 TensorRT 推理性能提升 15%-30%;
- **显存优化**: 设计动态内存池和多种内存管理算法, 利用 CUDA 提供的 Virtual Memory 管理接口, 相比 TensorRT 显存占用下降 30%;
- **Runtime 轻量化**: 实现推理引擎运行时编译 (JIT) 机制, OpenPPL CUDA 在 JIT 模式下 Package 体积低于 60M, 大幅度提升部署的可行性。
- **项目地址**: <https://github.com/openppl-public/ppl.nn>

PPL.LLM 大模型推理系统

2023 - 2024

工作职责: 主导自研大语言模型推理引擎开发, 攻克算子与显存墙瓶颈

- **系统架构设计 (System)**: 针对 LLM 推理特性, 完整设计并实现 Continuous Batching、KV Cache Manager、Memory Allocator、PagedAttention 及 Async Serving 等前沿调度机制。
- **核心算子突破 (Kernel)**: 研发 INT8 KV Cache、Fused Decoding Attention 及 W8A8/W4A16 GEMM 核心算子。算子延迟低于 FasterTransformer, 模型静态推理性能领先 TensorRT 10%-80% 之间。
- **极致显存优化**: PPL 推理系统结合 GPU Virtual Memory 接口深度优化显存分配, 集成 PagedAttention、Quantized KV Cache 与 Group Attention 技术, 完美解决超大显存碎片化与 OOM 问题, 大幅度降低显存占用。
- **项目地址**: <https://github.com/openppl-public/ppl.nn.llm>

PPL.SD 推理优化及业务支持, 核心开发 & 技术负责人

2023 - 2024

工作职责

- **全栈部署管线 (Pipeline)**: 针对 Stable Diffusion 相关模型, 设计 Torch->ONNX->PMX->PPL 的生产级部署方案, 全面兼容 SD1.X、SD2.X、SDXL 等多个版本的文生图模型。
- **算子与图优化 (Optimizer)**: 攻坚 SD 模型推理的核心算子优化 (Conv, LN, Attention 等), 定制化的图优化 (GELU、GN、Transpose 消除、算子融合等) 策略, 深度集成 CUDA Graph 功能, 最大化提升推理性能; 相比 TensorRT 有 20% 的性能提升;
- **显存优化与高级特性**: PPL 推理系统利用 GPU 提供的 Virtual Memory 接口实现高效的内存管理机制, 大幅度降低显存占用, 支持更高的分辨率生成; 开发灵活高效的 Refit 接口, 支持多种风格 LoRA 模型混合使用。
- **业务落地**: 支持商汤秒画业务线的文生图部署, 支持基础模型、自定义模型和 LoRA 模型的服务优化。