

李恭政-简历

李恭政(GongZheng Li)

微信 / 手机: 18667908119

邮箱: ligongzhengfor2019@gmail.com

生日: 1991.12

所在地: 杭州

求职意向: VLM推理优化工程师



教育经历

中国科学技术大学	软件工程设计	2014.09 - 2017.6
安徽工业大学	网络工程	2010.09 - 2014.6

工作经历

字节跳动 2023.12-至今

- Seed VLM基模优化
 - 主导 SeedVL、Seed-Omni 系列多模态大模型在 NVIDIA GPU 上的推理优化工作, 面向字节跳动 C 端及海外核心业务场景 (Agent / Seedream 4.x / Seedance 2.0), 线上部署规模达千卡以上。基于 TensorRT-LLM 开源框架深度定制, 系统性落地结构适配、模型量化、投机解码、PD 分离、Radix Attention、Vision Encoder 优化等关键技术, 在同等硬件条件下, 吞吐性能相较火山引擎、xLLM 等公司内部主流推理方案提升约 **2x**, 成为 C 端与海外业务首选的推理服务方案。
- 开源VLM模型优化
 - 面向剪映、抖音、可颂、小云雀等多条高并发 C 端产品线, 在业务形态、代码栈、模型架构高度多样化的背景下, 为部门从零到一搭建了 LLM 异步高性能推理服务的完整链路, 系统化解决 LLM 服务场景中的各类极端问题 (如自定义采样、格式化输出、重复采样等), 在保障在线延迟的同时, 显著降低了多业务线的 GPU 资源使用成本。
- GRPO训练优化

- 针对大模型 GRPO 训练中推理阶段（Generate）效率瓶颈，基于 TensorRT-LLM 深度改造，实现训练-推理引擎间的零拷贝权重同步与高效数据并行，封装为训练框架无关的通用 Generate 组件。接入内部 Seed 训练框架 Mariana 后，在单机 A800 80G 上即可完成 14B 模型的 GRPO 全流程训练，相比原生 PyTorch 方案训练速度提升 **9.3x**，大幅降低强化学习阶段的算力开销。

G42 - DFO

2023.07-2023.12

- Ray Dalio虚拟人
 - 开发虚拟人Ray应用，负责模型后训练、业务开发、部署优化相关工作。

OPPO - oppo研究院

2022.10-2023.07

- 大模型预训练
 - 在Llama/Bloom等模型上，基于meta的metaseq训练框架进行大模型预训练。

网易 - 伏羲实验室

2018.05-2022.10

- GPT引擎开发
 - 开发并开源了easy and efficient transformer推理引擎，提供GPT-2的模型推理能力，突破当时业界无大模型推理能力的开源困境，在单张3090上可装载11B模型，百字生成时间在2s左右，为网易获得2021年的浙江省尖兵项目提供主要技术支持和创新点。

北京的卢深视

2017.06-2018.05

- 人脸识别相关算法模型的落地

论文

- Easy and Efficient Transformer: Scalable Inference Solution For Large NLP model, 一作，Naccl 2022