

向宏毅

Phone: (+86)15652581208 E-mail: 402502064@qq.com

工作经历

- 美团，算法策略 2023 年 11 月 - 至今
训练效率优化 | 训练工具建设
- 商汤科技，算法工程师 2020 年 7 月 - 2023 年 8 月
模型转换与部署 | 算法 SDK 开发

项目经历

- 感知模型训练效率优化 2024 年 5 月 - 至今
 - ▷ 通过治理低效实现 (算子/计算逻辑重写、避免 D2H/H2D 拷贝、增强假设)/引入混合精度训练/去除 syncBN/引入 torch compile/batch 化 loss 计算/优化训练策略等大幅提升模型计算效率
 - ▷ 通过等效替换低效实现/to_device 与训练进程并行/dataloader 跨进程数据传输优化/内存 & CPU 亲和性设置/引入分布式 dataloader 等手段大幅提升数据加载效率，解除数据加载对训练效率上限的 block
 - ▷ 整体将感知模型训练 MFU 从 0.5% 提升至 5.0%，模型算力提升 4 倍的情况下每百万帧训练数据消耗卡时仅增加 33%，有效保障了研发效率
- 训练工具建设 2023 年 11 月 - 2025 年 1 月
 - ▷ 开发轻量级 torch module profiler；以极小的 overhead 实现对整个训练周期 (包括 torch module 的 fwd & bwd) 的 profiling，支持导出 trace，方便分析训练瓶颈
 - ▷ 开发及维护轨迹预测训练矢量图可视化工具；支持可视化交通参与者、历史轨迹、预测轨迹、真值、各种 plot 等，支持图层开关，整合进 tensorboard，方便算法同学查看训练效果
 - ▷ 开发及维护感知 3D 可视化工具；支持可视化 3D 点云、3D 检测结果、track、speed、OCC 等，支持鼠标拖拽 & 缩放改变视角，支持按条件筛选结果，支持不同实验之间对比，整合进 breakdown 页面，方便算法同学分析训练 diff
 - ▷ 开发自动数据筛选 & 累积 pipeline，持续积累高质量训练数据 (2000h→30000h)，助力感知 & 轨迹预测模型性能提升
- 模型转换与部署: 2020 年 7 月 - 2023 年 8 月
 - ▷ 独立负责团队内所有业务模型从训练框架到产品端的部署全流程，确保团队的算法产出
 - ▷ 开发及维护模型转换工具，通过新增算子、算子融合/展开、运行时重写模型 forward 代码等方式，支持各类算法模型向多个不同版本的不同推理后端的转换，并保证模型转换各流程 (Pytorch, ONNX, Caffe, TensorRT 等) 精度对齐

▷ 随着团队业务拓展不断扩展模型转换支持范围，主要支持 open-mmlab 系列算法框架产出的业务模型部署 (mmdet, mmseg, mmocr, mmdet/mmpretrain)，支持 30+ 模型结构，年均发布 200+ 业务模型

- 算法 SDK 开发:

2020 年 7 月 - 2023 年 8 月

▷ 负责团队内多个业务方向算法 SDK 的开发及维护，确保算法的实际落地

▷ 主要负责适配 open-mmlab 系列算法的 SDK 基础插件开发及维护，随团队算法更新不断拓展 SDK 支持算法模型范围

▷ 独立负责团队某工业质检标杆项目的算法 SDK 开发及维护工作，在时间紧、任务重、客户要求苛刻的情况下与算法研究员紧密协作，快速迭代算法，确保每次算法更新能在极短时间之内落地；同时通过将大量运算在 GPU 上实现，确保在算法流程不断膨胀的情况下 SDK 速度仍能满足产线节拍要求，整体提速约 55%；项目最终实现了客户首批 AI 取代人力质检产线的落地

教育背景

- 工学学士 北京航空航天大学，计算机科学与技术系 2016 年 9 月 - 2020 年 6 月

竞赛获奖经历

- 2018 年 CCPC 吉林区域赛金牌 (16 名) 2018 年 9 月
- 2018 年 ICPC 徐州区域赛银牌 2018 年 10 月
- 2018 年 ICPC 青岛区域赛银牌 2018 年 11 月

工具及技能

C/C++, Python, Pytorch, ONNX, Caffe, TensorRT, CUDA