

唐丁

个人信息

电话: 18890453252 | 邮箱: chrysantd@gmail.com | 地点: 上海

个人总结

- 高考省排名 191, 本科就读于香港中文大学计算机专业, 研究型硕士 (M.Phil) 就读于香港科技大学计算机与工程系。
- 专业技能: 专注深度学习训练框架加速及异构计算优化。深入理解 PyTorch 内部机制 (Dispatch, Compile)、分布式并行优化策略 (3D Parallelism, ZeRO, Checkpointing 等) 及 GPU 底层架构。精通 C++/Python; 熟悉 Triton 算子开发与编译链路优化。

教育经历

香港科技大学, 计算机科学与工程, M.Phil, 2022

香港中文大学, 计算机科学, 学士, 2018

工作经历

- Momenta. AI Infra SDE. 2025.07-至今
- 上海人工智能实验室. AI 框架工程师. 2022.09-2025.07
- 字节跳动. FPGA 实习生. 2021

工作项目

Momenta | AI Infra SDE | 2025.07 – 至今

核心职责: 负责自动驾驶端到端大模型的训练性能优化及数据流架构升级。

- 含强化学习的端到端模型训练优化
 - 计算优化: 支持模型迭代, 优化模型的 transformer 基础模块, 解决历史遗留的 layout 问题导致的计算效率问题。基于 Triton 开发优化算子, 以及结合 Torch Compile 和 CUDA Graph 等技术栈, 大幅提升模型训练计算效率, 解决动态 Shape 导致的图捕获失败问题, 并减少 Kernel Launch 等开销。
 - 管线剪枝与加速: 开发数据 Pipeline 依赖分析工具, 自动识别并剔除无用计算节点; 针对几何计算密集的 Pipeline, 利用向量化及 Numba JIT 编译技术重构代码, 显著提升数据预处理吞吐。
- Backbone Feature 缓存与量化加速
 - 计算解耦: 针对模型迭代特性, 设计“Backbone Freeze”训练方案, 将特征提取与功能头网络解耦, 避免重复计算。
 - 存储和 IO 优化: 通过分析 Feature 数值分布, 设计并实现 Int8 的多范围量化压缩方案。在保证精度的前提下, 减少了 40%+ 的特征存储空间占用及 IO 传输带宽。
- 读训分离架构 (Disaggregated Data Loading)
 - IO 负载均衡: 设计并实现数据读取与训练计算分离架构。部署独立的数据 Server 集群, 维护动态滑动数据窗口, 实现“一组 Server 支撑多组训练任务”的复用机制, 基于 RDMA 高速传输数据, 有效解决训练中的 IO 瓶颈问题。

上海人工智能实验室 | AI 框架工程师 | 2022.09 – 2025.07

核心职责: 负责国产异构芯片的大模型训练框架建设以及算子库开发。

- 万卡级异构集群混训项目 (核心技术)
 - 架构设计: 主导基于 5 种异构芯片 (含国产芯)、双集群 (10000+ 卡) 的 100B 模型训练架构设计。提出集合 DiLoCo 的跨集群异步训练与集群内异构流水线混训方案。

- **并行策略搜索**: 独立设计并实现自动 DFS 异构并行策略搜索算法, 结合通信拓扑优化, 解决了超大规模异构环境下的负载均衡难题。
 - **容错与运维**: 设计集群容错机制, 保障了 4T Tokens 数据量的稳定训练。
- **多芯片统一 Triton 接入 (dIBLAS)**
 - **编译后端适配**: 设计 Triton 多层级接入方案, 成功接入沐曦、寒武纪芯片。
 - **NPU 深度优化**: 负责华为 Ascend 接入方案 (Linalg IR -> NPU Dialect -> AscendC)。设计 Vector/Reduce/Matmul 计算逻辑, 精细化管理 Pipe、Double Buffer 及尾块处理, 降低算子开发成本。
- **ZeroPP: 流水并行与 Zero3 结合优化**
 - **算法创新**: 提出 ZeroPP 算法, 通过拆分参数与梯度的反向计算, 消除传统 Pipeline Parallelism 的气泡, 并解决与 Zero3 结合时的频繁通信问题。
 - **工程实现**: 基于 PyTorch FSDP 进行深度修改与适配, 实验证明在显存占用与训练速度上均优于传统基线。
- **设备无关算子接口 (DIOPI)**
 - **标准制定与落地**: 定义框架与芯片间的统一标准接口, 解耦上层框架 (PyTorch) 与底层硬件 (NVIDIA, Ascend, Cambricon)。
 - **一致性保障**: 开发自动化一致性测试工具与单 Iteration 精度对齐工具, 快速定位并修复了显存溢出及算子精度异常问题。

字节跳动 | FPGA 实习生 | 2021

- **Embedding 检索加速**: 参与推荐系统核心组件 EBR 的硬件加速研究。负责 GPU 基线版本的实现与性能对比分析, 辅助 FPGA 方案实现高吞吐、低延迟检索 (成果发表于 OSDI '22)。

奖项

上海人工智能实验室 2025 第一季度最佳项目奖

全国挑战杯一等奖, 获奖项目: 基于动作捕捉和表情识别的手语教学系统

论文

FAERY: An FPGA-accelerated Embedding-based Retrieval System. OSDI 22.

Enabling Efficient 100B LLM Training on Hyper-Heterogeneous Cluster over 1,000 Chips. Arxiv.

ZeroPP: Unleashing Exceptional Parallelism Efficiency through Tensor-Parallelism-Free Methodology. Arxiv.

Towards efficient pre-training: Exploring fp4 precision in large language models. ICML 2025 Workshop ES-FoMo-III.

语言技能

托福: 阅读 24, 口语 22, 写作 28, 听力 28.