



张一凡

13772198558 zhang_yifan@smail.nju.edu.cn

教育背景

南京大学 硕士 电子信息	硕士英才奖学金（一等）	2021年09月 - 2024年06月
南京大学 本科 集成电路设计与集成系统	人民奖学金	2017年09月 - 2021年06月

工作经历

美团总部-核心本地商业-Efficient	算法工程师（大模型推理优化）	2024年06月 - 至今
- 负责LongCat龙猫系列大模型的轻量化部署 - 负责GRPO、PPO强化训练过程中模型量化及KVCache压缩的设计及验证，并针对国产卡调优 - 负责稀疏Attention结构的联合设计以及与模型量化结合的业务上线 - 负责美团 MTPQ 量化工具的开发与升级 - 负责 Wow AI社区等业务的post training分析和量化部署 - 设计千亿级模型单卡量化推理框架 - 设计多维度量化模型精度指标 - 负责大模型 INT4 通信量化推理建模及精度交付		

实习经历

美团总部-基础研发平台-大模型架构组	算法实习生（大模型压缩）	2023年05月 - 2023年09月
- 负责SmoothQuant, GPTQ, AWQ等LLM量化算法在Llama, Baichuan, Bloom等模型上落地 - 在W8A8, W4A16, W2&W4-mix等不同精度需求下保证业务精度 - 开发美团MTPQ-LLM工具, 将GPTQ, AWQ等LLM量化算法融入, 打通一键式量化部署测试流程 - 进行大模型混合精度量化算法研究, 结合美团智能助手、点点助手等业务精度进行定向调优		
AMD Beijing - Xilinx Technology	算法实习生（剪枝/量化）	2023年03月 - 2023年05月
- 基于Pytorch和Vitis-AI后端的神经网络量化工具包NNDCT开发 - 进行SmoothQuant等LLM量化算法的调研, 并在不同数据集(如Lambada, wikitext2等)和模型(Llama, OPT)上复现 - 通过引入Bias Correction, 对LLM量化算法进行改进, 实现W8A8下超过SmoothQuant精度		
上海人工智能实验室-OpenMMLab-MMRazor	算法实习生（模型压缩）	2022年12月 - 2023年02月
- 对OpenMMLab算法框架不同仓库(如mmdet, mmyolo等)的大部分主流网络(如ResNet, Yolo, RTMDet等)进行PTQ、QAT量化 - 结合MMDeploy框架对量化后的网络进行转换和部署精度对齐（部署在OpenVINO后端）		

项目经历

UC Berkeley：基于BEVFormer的模型量化感知蒸馏	2022年07月 - 2022年11月
- 将MMDetection3D框架与HAWQ-v3框架融合 - 对网络进行离线量化及渐进式量化感知训练 - 用Feature-based蒸馏提升量化模型的精度	
航天772所：N900芯片-基于硬件延迟的检测模型混合精度量化	2022年04月 - 2022年05月
- 对DETR和YOLO网络进行权重低比特量化训练 - 基于硬件延迟的YOLO-v3网络4/6/8bit混合精度量化 - Target 6bit的混合精度YOLO-v3网络在COCO数据集上达到堪比全精度效果	

学术论文

ICCV 2023 QD-BEV : Quantization-aware View-guided Distillation for Multi-view 3D Object Detection(Y Zhang*, Z Dong*, H Yang, M Lu, CC Tseng, Y Du, K Keutzer, L Du, S Zhang)

Arxiv 2023 FPTQ: Fine-grained Post-Training Quantization for Large Language Models(Q Li*, Y Zhang*, L Li, P Yao, B Zhang, X Chu, Y Sun, L Du, Y Xie)

Arxiv 2024 Flash Communication: Reducing Tensor Parallelization Bottleneck for Fast Large Language Model Inference(Q Li, B Zhang, L Ye, **Y Zhang**, W Wu, Y Sun, L Ma, Y Xie)

Arxiv 2025 Longcat-flash technical report(**MLC Team**)