

高剑飞

(+86)159-9572-4893 | gjf_mail@126.com | github.com/ppppppm

教育经历

东南大学 软件工程 硕士	2015.09—2019.01
天津工业大学 软件工程 学士	2010.09—2014.06

工作经历

上海人工智能实验室 书生系列大模型训练框架负责人/模型结构设计	2021.05—至今
-----------------------------------	------------

- 负责书生全系模型全流程训练基建, 通过自研的训练框架 XTuner V1(非 Megatron 多维并行技术路线), 稳定支撑 InternLM/InternVL/InternS1 的 Pretraining/SFT/RL 超大规模训练。
- 负责硬件-软件-算法协同的效率优化, 针对不同模型结构, 在不同硬件条件及目标场景下设计训推方案, 或在不同场景下反向设计模型结构 (InternLM3 和正在研发中的 InternS2)。
- 多次从 0 到 1 进行“技术创业”, 主动挖掘实验室内部技术短板, 协调各类资源, 从无到有组建团队完成技术攻坚, 并实现从 1 到 N 的迭代, 代表作: MMRazor/XTuner/LMDeploy 等开源项目。
- 开源项目运营维护, 作为 OpenMMLab、InternLM 核心成员, 负责的开源项目多次登上 Github Trending。

上海眼控科技股份有限公司 模型压缩算法研究员	2020.02—2021.05
--------------------------	-----------------

- 负责智能车检系统的轻量化, 系统整体吞吐提升 4 倍, 在多地车管所上线。

地平线机器人 (南京人工智能高等研究院) 模型压缩算法研究员	2018.12—2019.12
----------------------------------	-----------------

- 自动驾驶场景的模型压缩预研, 主要负责目标检测模型的知识蒸馏。

项目经历

XTuner V1: 面向超大 MoE 的新一代训练引擎 技术负责人	2023.08 —至今
--------------------------------------	-------------

- 开源社区中唯一可复现 DeepSeek V3 训练吞吐 (fp8 tgs 1500) 的项目, 在 1024*H800 上 fp8 tgs 达到 **1600+**
- 基于 Pytorch FSDP 研发, 非 Megatron 技术路线, 整体吞吐超越 Megatron 最优配置 **30%** 以上
- 业界最大规模的 Pytorch FSDP 实践, 解决了若干 FSDP 在超大规模下的短板和 Bug
- 支持多种模态及多种算法的混合训练, 支持**万卡规模 2T 参数量**模型训练
- 更适合主流训练场景, 在不借助序列并行的情况下支持 DeepSeek V3 **32k 序列**训练
- 计算算子、通信算子、并行方案、计算通信掩盖和低比特量化等多技术栈协同优化
- 支持国产硬件, 业界首次在 Ascend 910C 上大规模训练效率超越 NVIDIA H800

书生系列大模型的持续迭代 核心成员	2023.08 —至今
---------------------	-------------

- 保障项目交付期间的稳定训练, 协调多方人员保证集群稳定性和工具链顺畅性, 不断完善自动化监控工具等
- InternLM3 的模型结构设计, 核心思路为加大模型层数, 减少每层的 MLP 参数量, 以增加 Attention 部分计算占比 (后续 Qwen3 全系列模型均采用了类似的设计)
- InternS1 的基础模型结构选型, 围绕“单节点可部署”“RL 训练效率高”“评测分数尽可能高”等目标, 最终选择 Qwen3-235B 作为起点模型
- InternS2 的模型结构设计, 针对 MoE 有概率出现专家负载不均衡而影响 EP 时训推效率的问题, 设计了一种路由算法, 可以保证在 EP 训推时专家路由的**绝对均衡**
- InternNext 模型结构设计, 保证纯 Sliding Window 模型长上下文能力, RL 训练吞吐提升数倍

LMDeploy: 大模型推理框架 模型量化技术负责人	2023.03 —2023.08
-------------------------------	------------------

- 整体量化方案的设计, 包括量化算法 (w4a16/w8a8)、高效计算 kernel 和自动化量化工具等部分
- turbomind 中的 w4a16 相关 kernel 为目前开源社区速度最快的实现

MMRazor: 面向 OpenMMLab 的模型压缩工具箱 技术负责人	2021.05 —2023.03
--	------------------

- 支持模型结构搜索、模型结构剪枝、知识蒸馏和模型量化等四类任务
- 零代码侵入解耦式设计, 支持对 mmdetection、mmyolo、mmpose、mmpretrain 等项目的自动化模型压缩
- 从项目维护过程中的实际问题出发, 解决了多个限制模型压缩在工业界落地的问题, 如: 为了解决异构目标检测模型的蒸馏而提出的算法 PKD, 为了解决 Yolo 系列模型无法进一步压缩而提出的剪枝算法 Differentiable TopK 等

科研经历

个人主要研究方向涉及：模型压缩、模型结构和 AI Infra 三个领域，期望能够通过端到端优化，降低大模型研发和应用成本；除此以外，积极参与实验室多项算法创新相关工作，提供 Infra 视角的建议以及训练支撑，追踪最新研究热点以明确后续训练框架的迭代方向。

Google Scholar

<https://scholar.google.com/citations?user=COUqsT4AAAAAJhl=zh-CN&oi=ao>

模型压缩

- Channel-wise knowledge distillation for dense prediction, ICCV 2021
- Pkd: General distillation framework for object detectors via pearson correlation coefficient, NeuralPS 2022 Spotlight
- Differentiable model scaling using differentiable topk, ICML 2024

模型结构

- Scaling up the state size of RNN LLMs for long-context scenarios, ACL 2025
- (ICLR 在投) Smooth reading: Bridging the gap of recurrent llm to self-attention llm on long-context tasks
- (ICLR 在投) Sliding Window Attention for Reinforced Reasoning

AI Infra

- (在投) XTuner V1: A Next-Generation Training Engine Built for Ultra-Large MoE Models
- TMA-Adaptive FP8 Grouped GEMM: Eliminating Padding Requirements in Low-Precision Training and Inference on Hopper, ICML 2025 Workshop

算法创新 | 训练支撑

- Semi-off-Policy Reinforcement Learning for Vision-Language Slow-Thinking Reasoning, NeurIPS 2025
- Exploring the limit of outcome reward for learning mathematical reasoning, COLM 2025
- Intern-s1: A scientific multimodal foundation model
- Internvl3. 5: Advancing open-source multimodal models in versatility, reasoning, and efficiency
- Internvideo2. 5: Empowering video mllms with long and rich context modeling
- (CVPR 在投) Exploring Visual Pretraining for Learning Language Intelligence
- (ICLR 在投) RIG: Synergizing Reasoning and Imagination in End-to-End Generalist Policy
- (ICLR 在投) LONG-HORIZON REASONING AGENT FOR OLYMPIAD- LEVEL MATHEMATICAL PROBLEM SOLVING
- (ICLR 在投) VideoChat-Flash: Hierarchical Compression for Long-Context Video Modeling

自我评价

- 具有大模型全栈能力 (模型结构、算法调优、训推框架) 和大模型研发的全局视角，擅长多维度协同优化。
- 自驱力强、学习力强、执行力强，多次从 0 基础达到业界第一梯队水平。
- 管理能力强，管理 10+ 人团队，团队成员绩效佳，凝聚力强。