

张力起

1994年



基本信息

联系电话: 19921275773 邮箱: 2672926561@qq.com

教育经历

同济大学	应用地球物理学	免试直博博士(全日制)	2017年9月 - 2023年6月
同济大学	应用地球物理学	本科(理学学士)	2013年9月 - 2017年6月
• GPA: 4.3 / 5.0 (专业前5%) 荣誉/奖项: 一等奖学金 (2013-2016) 国家励志奖学金 (2014-2016)			

个人技能

- 熟悉深度学习训练相关 (SFT、RL) 和推理 (cuda kernel优化、模型量化等) ;
- 熟练使用C/C++ (类模板, 标准库等), Python等编程语言; 熟悉CUDA/Tensor Core编程、tensorrt优化, 以及MPI、OpenMP等并行计算; 熟练使用Linux开发环境以及Shell脚本编程等; 熟悉数据结构与算法, 操作系统;
- 熟悉数字信号处理, 现代信号处理, 数字图像处理, 概率论, 应用统计, 矩阵论, 凸优化等数学信号方面知识;

工作经验

昆仑万维: 推理优化工程师

2024 年 2 月 ~ 2026年1月

推理方面:

- 对模型 (LLM、DIT等) 进行量化 (W4A16、W8A8等), 耗时减少30%左右, 内存占用减少50%以上;
 - LLM量化: FP8 per-token/per-channel、W4A16 per-token/per-group
对高敏感Linear算子 (Q/K projection、FFN up-proj、LM head等) 进行精度回退 (fp16)、平滑、weight clipping或引入旋转矩阵 (SpinQuant) 等处理来提高量化精度。
 - DIT量化: SVDQuant (int4+fp16 gemm)、FP8 (Tensorrt Model Optimization)
对高敏感算子 (time embedding、cross-attention、AdaLN等) 保持FP16、避免diffusion step相关outlier放大量化误差;
- 基于 TensorRT 对 DiT、VAE-GAN 进行端到端推理优化:
 - 使用 Multi-Profile、Multi-Context 等处理 dynamic dimension 情况;
 - 使用CUDA Graph进行优化;
 - 通过二分法或者对精度敏感层 (matmul、norm等) 添加输出节点, 进行输出误差检测, 并设置为tf32精度, 最终在保证数值精度前提下, 使得整体推理耗时降低 50%-70%。
- 利用 torch.compile/cuda_graph等对模型进行优化, 耗时减少 30% 左右;
- 基于 vLLM 封装 LLM 推理服务:
 - 解决 CFG (Classifier-Free Guidance) 带来的调度 (将cond/uncond绑定为一个logical request) 问题, 优化KV Cache 连续性等;
 - 通过分析动画/视频数据预处理瓶颈, 引入 vLLM + decord-GPU等方案对Qwen3-vl加速, 显著降低端到端延迟;
- Cuda kernel:
 - 系统性研究 GEMM 性能模型 (wave equation、合并对齐等)、GPU L1/L2 缓存使用策略;
 - 掌握 Hopper (SM90) 架构特性, 为推理 batch / KV Cache 布局、量化策略和连续批调度提供指导。

训练方面:

- 基于 LLaMA Factory 进行 LLM SFT 微调
- 熟悉 强化学习理论基础, 使用 OpenRLHF 进行 GRPO 训练
- 熟悉大模型并行训练方法:
 - DP / TP / PP / SP (computed across hidden dimension) / CP (Zig-Zag Ring Attention) ;
 - 正在探索并实践 FP8 训练;
- 大模型与深度学习相关课程:

李沐《动手学深度学习》、李宏毅《深度学习》、CS336: Language Modeling from Scratch、The Ultra-Scale Playbook: Training LLMs on GPU Clusters

同花顺：大模型推理优化算法工程师

2023年8月~2024年1月

- 熟悉llama模型及相关的推理优化加速方法（flash attention系列、vllm以及相关的GEMM\GEMV优化）；熟悉docker、nsight system/compute、cuda-gdb等的使用；掌握cutlass、NCCL、PTX汇编等的使用。
- 对vllm中attention的cuda核函数进行优化（基于attention sink设计unify max value, block size等），在延迟方面有10%以上的提升；针对扁平矩阵, 设计相应的矩阵乘积优化核函数（基于tensor core），在计算效率方面有5%以上的提升。