



求职意向

岗位：大模型 infra/AI 编译器专家



个人技能

1. AI 硬件：熟悉主流 GPU/NPU 芯片架构，含计算架构、存储架构、调度架构；熟悉结合芯片架构的业务优化；
2. AI 算法：熟悉 CNN 和 Transformer 模型结构和主流加速方法；
3. AI 软件：熟悉 TRT/vllm 的推理框架，了解 TVM/MLIR/Triton AI 编译框架；通用软件：熟悉操作系统、用户内核驱动和固件；熟练使用 c++和 python 编程语言；
4. 管理能力：0-1 团队搭建经验，建立完备的项目、知识管理和软件编码体系；



个人信息

姓名：张宇翔

邮箱：geeke_zhang@outlook.com

年龄：32

工作经验：10 年

电话：15001921124

现住城市：上海市



教育背景

- 学校名称：华东师范大学
- 就读时间：2011.07-2015.06
- 所学专业：通信工程
- 学历学位：本科



工作经历

- 公司名称：蔚来汽车有限公司
- 自研 NPU Runtime 技术负责人
- 在职时间：2022.3-至今
- 关键词：Runtime 架构设计，版本发布，部署特性，联合性能优化、工具链、推理引擎支持
- 工作职责：1. 参与神玑 n93x 芯片 npu 架构项目，作为运行时软件（runtime、固件）的架构设计 owner，完成 npu 内、npu 与其他子系统间软硬件和交互流程设计；兼容 cuda 的内存、同步和线程模型，完成 sim/esl/fpga/emu 原型验证，发现多个 eco 问题；
- 2. 从零组建团队，持续发布高质量、稳定 runtime 版本，支撑 npu 团队无感跨平台验证，并支持在 es8, 2025 改款 et5, es6 多款车型上商用和量产，目前出货已超 xxw 片；
- 3. 提前规划部署方式&收集业务痛点，规划资源隔离，mps，零拷贝，动态 shape 运行时特性，支持业务团队从 nvidia orin 迁移到神玑自研 npu 平台；
- 4. 深度参与性能调优，含 benchmark 类调优、多 ota 版本自动驾驶业务调优；
- 5. 作为 debug、profiling 特性设计和关键组件交付 owner，在硬件机制不完备时，通过软硬结合、纯软方案完成 simt、simd 混合调度下的性能分析、异常现场留存、反标、超时检测；
- 5. 作为推理引擎、大模型推理引擎自研方案关键参与者，交付运行态全组件，并支持外部客户开发使用；

公司名称：腾讯技术有限公司

端侧 AI 推理部署专家

在职时间：2020.12-2022.3

关键词：

关键词：ai 能力封装、性能优化

工作职责：基于 TNN 与 HyperGann 框架，进行跨 ARM、OpenCL、Metal 的 AI 能力封装，提升模型性能在各档位机型上提升。

公司名称：上海华为技术有限公司

自研 NPU Runtime 技术负责人

在职时间：2015.6-2020.12

关键词：回片验证，ISP-NN 链路设计，自定义算子开发

工作职责：1.作为 ai runtime/driver 技术负责人，参与麒麟 8x0/9x0 第一代自研 NPU BringUp，并在 FPGA/Zebu/UDP 上进行原型验证，并解决稳定性问题，满足和支持后续百万片级商用交付；

2.参与设计微核 NPU 链路方案，支持在线 ISP-NN demosaic 处理；

3.开发自定义算子进行性能调优；支持车端点云和语义分割模型上线；

项目经验 1

- 项目名称: 车端大模型推理引擎 所在公司: 蔚来汽车 项目角色: 技术负责人 项目时间: 2025.05-至今

- 目标&挑战: 在内存带宽、内存容量和算力大小受限场景下, 实现 VLM 智驾场景下用户模型的低时延、低波动;
关键词: 多级分离调度; 单模型性能优化; 内存优化; 调度优化;

项目职责: 1.单模型时延优化: 应用 embedding+sampling 下沉、多 decode 异步、cudaGraph 捕获、continuousBatching
2.调度优化: 分离大模型和非大模型的调度, 平衡关键链路上的低时延需求和大模型的不定长输出; 大模型为带缓存亲和的 PD 混合队列, 非大模型为绝对优化级队列; 零拷贝减少模型打断;
3.内存优化: 内存池化+时序复用保证初始化和运行性能; 跨模型抢占、快速碎片整理, 保证高并发;
4.算力充分运用: 实现 Tensor Parallel 和权重切分保证硬件算力使用;

项目业绩: 1 支持 10+模型混合部署, 引擎比手排方式高 xx%的算力利用率, 帧率提升 YY%; 2.支持书生、VIT、Qwen2.5 0.5~7B 模型部署, 支持量化浮点部署方式 3.部署 Qwen2.5 7B 模型, 推理性能 TTFT 112ms, decode 平均时延 49ms, 与 Orin 部署性能接近;

项目经验 2

- 项目名称: 智驾端侧部署性能优化 所在公司: 蔚来汽车 项目角色: 核心贡献者 项目时间: 2024.05-至今

- 目标&挑战: 支持内部客户进行车端模型高效部署; 对用户模型迁移自研 npu 后关键瓶颈点&性能优化; 含单跑, 混合执行和全链路执行;

项目职责:

1.开发 profiling 工具寻找性能瓶颈点, 并联合图和算优化: 如 cuda 算子数据映射微调, 带宽过大, 缓存管理失败, 负载不均衡, 错误调度依赖, 动态 shape 同步过多;
2.cuda&部署优化: ad 同步过多、媒体和锁页内存 cpu 开销、优先级倒置, cudaGraph 使能, 零散小算子, decode 模型复用; 公共技术和 pattern;
3.与 ad 联合调研设计部署方案, 根据不同模型算力带宽需求不同, 帧率不同, 功能级别不同等特点, 搜索不同部署和优先级组合, 进行混跑性能调优和调试, 发布最佳部署方案; 并总结性能调优指南; 为加速项目进展, 提出弱安全性软隔离方案到硬隔离的两段式方案; task flow

项目业绩: 在频繁的模式变更的情况下, 模型单跑性能最大提升 22%, cpu 开销降低 2+ core, 支撑该版本在自研 npu 上以最佳的性能部署版本上线, 帧率和稳定性经迭代均高于 orin 部署版本; 成功提前上线时间 1.5 月+; 方案沿用至后续 ota 版本模型部署;

项目经验 3

- 项目名称: 自研 npu 运行时设计 所在公司: 蔚来汽车 项目角色: 技术负责人 项目时间: 2022.03-2024.5
- 关键词: cuda 兼容、业务迁移、调度设计

目标&挑战: 合理设计交互流程和编程界面, 以尽可能小的业务迁移工作量, 支持芯片的性能释放;

项目职责: 1.业务场景和架构分析: 自动驾驶为数据驱动下的 CNN、具有数据依赖强、动态 shape、低时延和低波动特点, 模型做业务切图后生成 TensorRT 模型+自定义算子; 运行态通过 data flow + laser 模块进行模型驱动;
2.软硬件交互: 整体选用绝对优先级调度, 将标准算子组成子网下沉到 hw 调度, cuda 自定义算子则运行态生成; 基于上述需求调整 cuda 的 host-device 交互和任务下发的编程模型, 通过算子池化打包, 改造 stream 和 event 软件实现混合调度队列
3.跨组件数据共享: 优化无异步引擎下的双向传输带宽;

项目业绩: cuda 兼容, 用户可以较小工作量迁移大量存量代码; 此设计支持自研 npu 成功回片并商用到蔚来车型上, 在上线智驾网络上调度效率、传输带宽上高于 orin x 竞品;

—

└