

张雪峰

男 | 年龄：31岁 | 15510240576 | 389702232@qq.com
8年工作经验 | 求职意向：C/C++ | 期望城市：北京

教育经历

哈尔滨工业大学	硕士	通信工程	2016-2018
哈尔滨工业大学	本科	通信工程	2012-2016

工作经历

拼多多2023.09-至今

大模型训练框架0到1的搭建

- 大模型训练框架
 - 支持DP / TP / SP / MoE / FSDP 等模型并行策略。基于 IPC/NVShmem 设计并实现通信-计算 Overlap 融合算子，包括：AG_Gemm, Gemm_RS, AllToAll_Gemm, Gemm_AllToAll等。显著提升多卡通信效率与整体吞吐。
 - 调研并实现FP8混合精度的端到端训练流程。包括PerToken, PerBlock, PerTensor的缩放功能，参考DeepGemm实现FP8Gemm kernel, FSDP实现FP8的AllGather通信，加速模型训练。
- 自定义算子库。开发自定义算子实现模型加速。包括：FlashAttention, 自定义Mask+Attention, SiLU Attention, Multi-Token Attention, Linear Attention, SwiGLU, GroupGemm。
- GPU稀疏训练框架
 - 实现核心组件CudaHashTable, LRUCache, 显存/内存/SSD三级存储, sparse优化器, Sparse Checkpoint, 特征准入与淘汰, Pooling操作, 梯度累积和forward聚合。pipeline异步训练。C++实现高性能的dataloader。高性能特征工程。
- 熟练使用性能分析工具：熟练使用Nsight Systems (nsys), Nsight Compute (ncu), CUPTI等模型性能分析工具。深入分析Kernel 计算效率、访存效率、时延瓶颈及带宽利用率，针对性优化核心算子，实现系统级性能提升。

gpu训练平台的0到1搭建

- 设计并实现server服务，打通多机多卡分布式训练链路。适配主流多机训练框架(DeepSpeed, Megatron, Parameter Server (PS))。
- 设计并实现scheduler服务，主要功能为GPU分配调度逻辑，实现 抢占式调度, 动态资源调度, 离在线混部调度等。
- 设计并实现monitor服务。提供采样上报功能，集成wandb, TensorBoard 等可视化库。打通HDFS, ClickHouse, MySQL等数据库交互。提供机器状态监控，基于 NVIDIA DCGM 构建底层 GPU 采样监控系统，包括mfu, 访存效率, 带宽效率等硬件指标。
- 设计并实现机器hang检测，机器快慢卡检测。问题发生现场保存。

腾讯科技有限公司2021.05-2023.08

推荐系统模型预测服务

- 服务在线侧:提供特征抽取, 访问模型等功能，包括召回, 粗排, 精排, 打散模块通过此模块来访问模型。实现了推荐系统模型预测功能的收敛, 可配置化, 中台化。
- 在线使用DAG的图引擎设计实现特征配置化，设计秉承新增特征的最少改动原则，并实现离在线特征一致性。
 - 实现数据预取功能，一次请求链路所有服务只访问一次数据，并对数据做缓存。

- 数据访问模型的csr格式压缩(通过偏移压缩), rondacache实现模型server存储分离(ps架构), protobuf懒解析, 异步析构, 内存池对象池的实现和使用

服务离线侧:实现对数据的打标签, 离线抽取, 数据流处理, 训练模型的功能。保证离在线特征一致性, 数据的流处理

- 离线侧实现了数据的样本流改造, 所有模型一套离线样本, 修改特征无需在线全量, 新特征实验无需等待离线数据积累
- 基于flink, kafka实现对数据的打标聚合, 并将数据存储到hdfs, 再通过featurer_maker服务做特征抽取。提供模型训练使用

推荐系统精排服务

- 服务实现对文章视频的排序功能, 实现场景插件化处理, 解决了之前多场景多套代码维护问题。
- 服务使用协程实现减少了线程模型的切换的开销。
- 通过可配置化, 将算法修改全部使用conf文件配置, 减少算法对服务代码的修改

华为技术有限公司 C++

2018.08-2021.04

华为手机广告投放服务

- 实现广告选择和投放。包含广告检索、粗排、精排等功能模块
- 实现广告倒排正排表, 通过roarmap实现对稀疏倒排表的压缩

广告系统体验控制服务

- 对广告体验功能的筛选, 包括广告任务去重, 频控, 负反馈功能, 实现用户体验相关功能。

数据订阅模块

- 从数据库订阅在线服务所需数据, 来实现广告任务准实时更新, 并且生成数据使用的正倒排表,
- 实现对数据库的访问, 通过分布式集群的方式保证服务的可用性。