

曹 瑞

基本信息

性别	男	籍贯	山西
手机	150 2660 2919	出生年月	1989.04.18
电子邮箱	caorui_sjtu@163.com	求职意向	LLM 推理加速



教育背景

2013. 09-2016. 03	上海交通大学	电子信息与电气工程学院	自动化	硕士
• 主要奖励: 国家奖学金, 优秀毕业生, 国际顶级会议一篇(Google 引用:35)				
2008. 09-2012. 06	河北科技大学	电气工程学院	测控技术与仪器	学士

专业技能

- 具有 TensorRT/TensorRT-LLM/vLLM 等推理框架的开发与使用经验, 具有 TensorRT 推理的(ONNX)算子插件开发经验, 掌握 CUDA/C++/Python 等编程语言;
- 有 CUTLASS 加速库使用经验, 可以使用 Cute 开发 GEMM 算子, 掌握常用 PTX 指令, 了解 Tensor Core 结构, 有 CUDA Kernel 的调优经验(使用 PTX 调优);
- 熟悉常用的 LLM 模型结构, FlashAttention, KV Cache 优化, SmoothQuant/AWQ/WeightOnly 等量化算法, Speculative Decoding(EAGLE/MTP)等 LLM 解码加速算法;
- 具有 Ray 等分布式工具的使用经验;
- 算法团队管理经验, 算法库框架设计经验

工作经历

2020.11-至今	星环信息科技有限公司	基础算法组 TechLeader/资深算法工程师
2020.10-2020.10	德邦快递	高级算法工程师
2017.10-2020.05	湘宁资产管理有限公司	高级算法分析师
2016.09-2017.09	上海朴石投资有限公司	量化分析师

项目经验

2024. 10-2025. 07 TensorRT-LLM Kernel 优化
- 基于 CUTLASS 3.x API 开发适配 Hopper 架构 SmoothQuant 量化算法的(Tensor Core)算子, 使用 Custom EVT 接口实现 Epilogue 阶段的反量化操作;
 - 使用 CUTLASS Profiler 进行 Kernel 参数调优, 针对不同输入维度下, 选择算子 MainLoop 与 Epilogue 最佳的 Warp-Specialization 调度配置以及 TileShape/ClusterShape 等的最优配置;
 - 在维度为 m=2048, n=4096, k=8912 时, 在 H100 SXM5 GPU 测试性能达到 1364 TFLOPs/s, 相比 TensorRT-LLM 的 SmoothQuant 算子实现(性能测试为 872 TFLOPs/s)提升 56%;
 - 针对 TensorRT-LLM 框架中 SmoothQuant 算法的 Batched-GEMV(Cuda Core)算子进行多处优化, 包括使用 PTX 指令优化性能; 在 H100 SXM5 GPU 上进行性能测试(TFLOPs/s)相比 TensorRT-LLM 官方版本提升最多超过 30%, 在 4060Ti GPU 上性能测试提升最多超过 100%;
 - 例如维度为 m=4, n=3072, k=2560 时, 使用 NCU 在 H100 GPU 上分析 kernel, 性能从 11.2 TFLOPs/s 提升至 14.8 TFLOPs/s(提升 32%), L2 Cache hit rate 由 15%提升至 30%(提升 100%), L1 Cache hit rate 由 60.57%下降至 21.88%, 带宽利用率由 27.5%提升至 34.6%(提升 25.8%), 内存吞吐量由 0.915 TB/s 提升至 1.15 TB/s(提升 25.7%);
 - 使用 CUTLASS 实现 Weight Prefetch 版本的 Low Latency INT8 GEMM, 并进行性能测试;

- 针对 AWQ 量化算法的 Batched-GEMV(Cuda Core)算子进行优化;
- 上述工作内容由本人独立完成

2024. 04-2025. 01

语料平台模型推理加速

- 与后端团队 Leader 联合规划语料平台算法部分的开发计划, 包含: 去重算子的开发、语料合成算子开发、语料评估算子开发等;
- 从源码编译 TensorRT-LLM 推理框架, 制作 Docker 镜像, 对语料评估算子依赖的大模型 HF 文件 (Qwen2-0.5B/ Qwen2.5-3B-Instruct/Qwen2.5-13B-Instruct/Shield-LM-6B 等模型)进行 checkpoint 转换, 使用 SmoothQuant/AWQ/WeightOnly/FP8 等量化算法对模型进行量化压缩;
- 将量化后的模型构建为 TensorRT-LLM Engine 文件, build 时指定要开启的 Plugin, kv_cache 类型, tokens_per_block/max_tokens, 最大序列长度/BatchSize, 以及是否开启 gather context/generation token logits 等参数, 并基于 ModelRunnerCpp API 开发单 GPU 单模型实例加载的推理服务;
- 在 A100 GPU 上对各模型的不同量化算法与不同 BatchSize 模型服务进行性能测试(延迟,吞吐量), 测试各模型在不同 BatchSize 与序列长度下峰值显存占用;
- 基于 Ray-Serve 框架, 调用 TensorRT-LLM 的"LLM"接口搭建 AutoScaling 推理部署, 将多个模型以 ModelComposition 的方式进行部署, 实现不同任务模型推理的自动派发;
- 根据模型的大小设置 Ray Actor 的 GPU/CPU 资源分配, 同时对 Ray Serve 的 min/max_replicas, up/down_scale delay, on-going request 等参数进行设置, 并集成到公司内部的数据库中;
- 在 TensorRT-LLM 框架下, 为 Yayi-UIE 大模型开发 HF 模型文件的 checkpoint-convert 模块, 使用 AWQ 算法对该模型进行 W4A16 量化压缩, 使用 Ray-Sever 搭建推理服务;与后端同事联合开发 NLP 实体抽取推理服务, 部署在公司 LLMOps 平台;
- 基于 Ray 开发分布式去重算子(BloomFilter 与 MinHash);
- 对 TensorRT-LLM 进行版本升级, 构建 H100 GPU 模型 Engine 文件;
- 使用 vLLM 制作国产 GPU 的语料算子依赖模型的推理 Docker 镜像, 并搭建服务;
- 目前该平台已经应用在深交所与浦发银行等多个语料工程项目中;

2022. 11-2023. 12

TensorRT 推理加速工具开发

- 使用 C++开发 TensorRT 推理的 ONNX 模型文件 Builder 工具, 封装 OnnxParser, SerializeEngine, BuilderContext 等接口, 基于此开发支持设置 Int8 量化 Calibrator, Q/DQ 层设置, 自定义 Tensor Dynamic Range, 逐层精度设置, 逐层输出类型设置, 自定义 Optimization Level, 设置内存池大小, 是否开启 timing cache, 创建 Optimization Profile 等功能函数, 用于解析 ONNX 模型文件并转换为 TensorRT Plan/Engine 文件;
- 使用 Pybind 进行 Pytorch 接口封装, 并以 Docker 容器形式作为独立的 ONNX 模型文件解析与转换工具上架到公司的 Sophon Discover 平台;
- C++开发 TensorRT 的 Inference 工具用于时序模型推理加速, 支持多线程多流多上下文推理, 使用 Pybind 封装 Pytorch 接口, 支持直接将 torch.Tensor 作为输入数据;
- 作为推理加速工具上架到公司的 MLOps 平台, 与后端团队同事合作进行性能测试;
- 开发 GeLu, LayerNorm, Bernoulli, Multinomial, DynamicQuantizeLinear, NegativeLogLikelihoodLoss, MatMullInteger 等 TensorRT 未支持 ONNX 算子 CUDA Kernel, 并对 Kernel 进行独立测试; 其中 GeLu 算子相比 TensorRT 官方 GeLu 插件性能(GFLOPs/s)提升约 60%;
- 基于 IPluginV2DynamicExt 接口开发上述的算子 Plugin 以及 Creator 接口, 在 initLibNvInferPlugins 函数中添加每个算子插件的动态注册;
- 在 onnx-tensorrt 项目的 builtin_op_importers.cpp 文件中注册并实现上述算子的 ONNX 解析器;
- 基于第三方库 yaml-cpp, 开发 yaml 参数解析模块, 使用 yaml 文件独立配置 Model, Builder, System,

Inference 等模块的参数;

- 上述工作内容由本人独立完成。

2023. 07–2023. 11

验证 RLHF 微调

- 利用 DeepSpeed 训练框架, 基于 Llama2-7B 模型验证 RLHF 在 NL2SQL 的后训练微调效果;

2022. 03–2022. 12

时间序列算法库开发

- 主导并设计深度时序预测算法库的重构工作, 制作开发 RoadMap, 维护 Git/CI, 更新 CI 镜像, 负责 code review, 指导团队成员开发新模型;
- 基于 PytorchLightning 对算法库 pipeline 的参数配置、数据预处理、模型训练以及推理阶段分别进行重构;
- 添加 yaml 参数配置模块, 可针对数据, 模型, 训练器与优化器分别配置参数;
- 训练阶段: 解耦模型与训练接口, 基于 PL 重构模型训练阶段 API, 可以实现对训练过程细粒度的信息获取, 且可根据需求添加 Tensorboard, Profiler, LRMonitor 等不同的回调接口;
- 推理阶段: 所有模型支持 ONNX 文件序列化, 并集成 OnnxRuntime 推理加速;

2020. 11–2022. 12

Sophon 平台开发

- 对公司自有的机器学习平台 Sophon 进行算子开发与维护;

学术著作

- Stability analysis for networked control systems under denial-of-service attacks. 2015 54th IEEE Conference on Decision and Control(IEEE CDC). Rui Cao, Jing Wu, Chengnian Long, Shaoyuan Li
- 第一作者, Google 引用次数: 35