



求职意向

AI 训练推理加速（框架/算子）

工作经历

- 字节跳动，豆包，AI 异构计算优化工程师/专家-Seed** 2025.7-至今
核心算子开发及优化：CV 混合算子（Linear Attention, W4A8 gemm 等），Vector 算子的开发与性能调优
通算融合算子开发及优化：用于 DP/TP 转换的通算算子 AllGather-QMM, QMM-ReduceScatter，融合算子相对于多流并行实现加速比 $1.1x \sim 2.0x$
自动化 gemm 算子调优系统（Auto-Tuner）：结合线上真实数据分布构建 Tuner 采样机制，通过“离线全局搜索 + 在线动态匹配 + 默认参数兜底”的策略，实现 gemm 类算子性能提升 5%~17%
Bigop 端到端加速：实现 DeepSpeed 模型的 BigOp 融合架构，通过 C++ 底层算子接口直调与多流并发技术，显著降低 Kernel Launch 开销。在 MoE 模型下，实现 1k 序列端到端加速 1.46x，2k 序列加速 1.08x
长序列推理负载均衡：针对长序列分桶问题，计算理论最优 QLen，动态调整 Prefill Chunk 调度策略，消除计算节点间负载不均导致的 Pipeline Bubble，平均 TPS 提升 10%，长文本场景下提升 20%
模型级 CI 精度看护：搭建模型级别 CI，实现真实模型权重和激活值的自动化加载。将单算子 Golden 适配到分布式环境下，增强算子库在实际场景下的精度看护
编程技能：AscendC / Catlass / Shmem
- 中兴通讯，软算中心，智算团队（蓝剑）** 2023.8-2025.7
基于 RISC-V 的算子开发及效率优化（开发，小组负责人、需求接口人）
基于 C++ 的 RVV 算子开发，功能及精度对标 torch
算子优化：指令级别流水优化，根据硬件 latency 和 throughput 计算理论开销，帕拉丁实测实际效率
需求管理：对接框架提出的各种功能开发需求，评估算子组合方案，负责开发及交付排期
常用 AI 模型推理、训练方案评估及优化，trace 时序分析（预研，独立完成）
Transformer、CNN、conformer 结构模型，包括 QWen、bert、YOLO、wenet 等
切分方案：空间上，不同硬件间 DP、TP、PP 切分；时序上，L2、L1 循环切分
优化策略：正、反向算子融合；重计算。
基于矩阵乘加速器的卷积正反向硬件实现推导，硬件需求评估（预研，独立完成）
连续读取限制下，设计特征图、卷积核的数据摆放格式；伪指令模拟每一步计算；子图抽取、合并
编程技能：C/C++/C#，CUDA，Python（pytorch、tensorflow、keras 等深度学习框架），MATLAB

实习经历

- 微软 STCA AI platform, software engineering intern** 2022.6-9
基于图神经网络的股票预测；机器学习模型预测招聘人数
- 第四范式技术有限公司，算法实习生[pytorch]** 2022.3-6
计算创意生成和推荐系统相关算法研发，SOTA 模型复现
- 北京海鑫科金科技股份有限公司，算法实习生 [CUDA]** 2018
CUDA 并行计算开发，针对人脸识别特征比对过程中的张量运算，优化任务划分和数据传递提高计算效率

教育经历

2014-2018 清华大学自动化系，工学学士，校设学业优秀奖、文艺优秀奖
2018-2023 清华大学建筑学院建筑技术科学，工学博士，综合奖学金，导师：林波荣教授（杰青、长江）
2018-2021 清华大学大数据能力提升项目

英语技能: CET 6: 595, TOEFL iBT: **107/120** (Reading 30 Listening 27 Speaking 23 Writing 27)

GRE: **327/340 + 3.5/6** (Verbal Reasoning 157 Quantitative Reasoning 170)

学术研究

- **基于 CNN 和 GAN 的建筑室内采光性能预测, SCI (Q1) [tensorflow]**

基于 ResNet 和 pix2pix 分别预测建筑室内整体采光指标和照度空间分布, 预测精度最高的采光均匀度达到 R^2 0.959, MSE0.008, 照度分布图在测试集上 SSIM 达到 0.90, 满足方案初期实时设计反馈要求

- **住宅户型平面图识别和信息提取, INDOOR AIR 2020 (建筑科学技术领域顶级会议, oral) [python]**

与北京住宅总院合作, 房间、门、窗构件的识别率分别达到 96.5%、94.5%和 97.2%, 识别结果应用于 BN 推断
