

李尧

电话：18605164188 | 邮箱：liyaoxz@126.com
意向城市：上海 | 求职意向：大模型算法工程师

教育经历

约翰霍普金斯大学——电子与计算机工程 硕士	2017年08月 - 2019年05月
克莱姆森大学——电子工程 本科	2014年08月 - 2016年06月
北京航空航天大学——电子工程	2012年08月 - 2014年06月

工作经历

中国电信天翼云-研发专家	2025年05月 - 至今 上海
--------------	---------------------

- 针对昇腾推理框架的PD分离
 - 基于华为 LLM-Datadist kv 传输库，主导自研昇腾推理框架的 PD（计算 / 存储）分离架构落地：设计并实现推理调度器端异步 KV Cache 接收逻辑，搭建基于 ZMQ 的高可靠进程间通信机制，保障跨进程数据传输的低延迟与稳定性
 - 构建有状态代理服务器与调度体系：支持计算节点动态注册、弹性扩缩容、心跳检测机制，实现 KV Cache 全生命周期自动化管理（留存、使用中、释放）
- kv cache pool与异构硬件PD分离
 - 可充分利用不同硬件的算存特性，实现异构的PD分离（如Ascend-910B做prefill，H20做decoding），或者国产卡互相异构
 - 参考 LMCache 核心架构，实现支持 prefix cache、CPU Offload、多层级缓存召回的 KV Cache Pool；通过实现查询分发服务器，完成分布式 KV 存储与跨节点高效召回
 - 多种实现开发：
 - 兼容性：最低基于tcp网络实现kv传输，基本能够做到跨各种硬件快速实现pd分离（nvidia、昇腾等国产硬件），使用 socket\zmq流水以及ucxx等充分利用tcp网络带宽
 - 速度\兼容：实现基于cpu memory的RDMA kv传输，可利用cpu 内存的开发一致性与RDMA的高速传输达成较低的传输延迟
 - 通过算传overlap掩盖传输overhead

Minimax-上海稀宇科技有限公司——推理优化算法工程师	2023年11月 - 2025年03月 上海
-------------------------------	---------------------------

- 线上模型的推理速度优化
 - 针对对话模型（星野、Talkie）的有状态推理（kv cache cpu offload）的模拟与开发：先通过实时用户数据模拟请求压力，预判有状态收益（吞吐翻倍），再针对线上推理框架进行开发
 - 针对所有线上推理卡/模型的排列组合分析MFU、MBU。对kernel进行benchmark和tuning，从而提升推理速度，Linear Decoding Kernel优化
 - Eagle模型训练，线上推理框架的Eagle推理开发
- vLLM评测框架构建与维护
 - 以vLLM推理框架为中心构建评测框架，Minimax模型的vLLM适配，包括：文本、多模态评测支持、基于triton的linear decoding kernel开发，cuda graph支持，10M超长文评测支持，Pipeline Parallelism性能优化
 - 参与vLLM开源版本的Minimax-Text-01的代码开发
- 推理优化探索：投机解码方案、kv quant 方案、sparse attention方案的研究与探索

上海蜜度科技股份有限公司——高级算法工程师/专家	2020年08月 - 2023年11月 上海
--------------------------	---------------------------

- 蜜巢大语言模型
 - 预训练：全栈负责数据筛选、整理、去重、格式化、训练框架制定、环境配置、单机实验、多机实验与最终集群训练的整套流程。负责持续维护模型训练完成、故障重启、指标测试、业务测试
 - 指令微调:文稿通知识问答(RAG)与材料写作两个功能的pipeline制定与指令数据的标注标准制定、完成整个pipeline代码上线、完成语义检索模型的训练与精排模型的训练，精排后的hit@5指标相比召回提升12%
 - 蜜巢智能舆情分析大模型: 完成整个功能的pipeline制定与代码编写、配合公司业务部门完成语料收集并完成所有阶段的模型训练并上线，舆情分析结果公司内部专业评测有60%+的单次通过率
 - 国产化适配: 在华为昇腾运行环境中（mindspore，ascend910 * 16张）跑通大模型sft与推理

- 跨模态检索能力建设 蜜度索骥：
 - 预研/预训练: 2021年末开始，在中文跨模态生态还未开始的时候预研跨模态方法，初步使用对比学习loss与英翻中数据集进行预训练
 - 业务增强微调: 使用模型预标注+人工标注+模型再清洗的流程获取业务数据，再通过混合业务与通用数据构建更多的负例，在通用任务的MR指标接近Bing搜索, 在业务数据的MR (1,5,10) 指标约87%左右
- 蜜度文本校对能力建设 蜜度校对通、铤媒：
 - 使用深度学习模型进行文本校对能力的建设（多字、少字、乱序、标点、量词错误等），负责模型预训练、百亿句子级别的预训练语料清洗与构建，并提供api能力，公司内部构建的验证集约87%的F1，通用验证集（SigHan）也是sota水平。

达观数据有限公司——算法工程师

2019年06月 - 2020年07月

上海

- 不同证照的OCR与抽取（驾照、营业执照）
- 训练文本方向检测模型对图片\文本框方向进行检测预处理
- TensorRT模型推理加速

比赛经历

- 2022中国高校计算机大赛-微信大数据挑战赛（清华、微信）- 初赛第2名、复赛/总决赛第6名（总共3204队伍，4000多人参赛）
- 2022全国大数据与计算智能挑战赛-新闻文本的语义检索与智能问答- 二等奖（第三名，共400+队伍）
- 2022昇腾AI创新大赛，上海浙江赛区金奖晋级全国/全国铜奖
- CIEC-2021-中文文本纠错比赛，三等奖（第五名）

其他

- **技能：**熟练使用python、pytorch、triton，熟悉C++、CUDA、CUTE，熟悉Megatron、Deepspeed等训练框架，熟悉vLLM、sglang等推理框架