

文班

(+86)199-2182-7895 | hi496327606@126.com



教育背景

同济大学（车辆电子，工学学术硕士，第一名录取）

2018.09-2021.06

- 课程成绩：89（前 10%）
- 相关课程成绩：数值分析(A)，矩阵论(A)，现代自动控制原理(A)，系统动力学(A)
- 竞赛获奖：中国研究生数学建模国家级二等奖

哈尔滨工业大学（车辆工程，汽车电子方向，工学学士）

2014.09-2018.06

- 课程成绩：90（前 5%）
- 相关课程成绩：数学分析上下册(A)，线性代数(A)，概率论与数理统计(A)，自动控制原理(A)
- 所获奖项：第九届全国大学生数学竞赛（CMC）全省第一名，入选省队并在全中国决赛中获得银牌（排名全国前 0.1%）；美国大学生数学建模国际一等奖；校最具影响力优秀毕业生；全国高中数学联赛省一等奖

工作经历

北京字节跳动网络技术公司-AML-方舟

大模型推理系统工程师

2025.02-至今

- 方舟自研多模态 DiT 推理框架 veFuser 引擎侧核心作者：
- ✓ 负责 Seedream4 生图模型（模型参数超 23B）的推理优化及在方舟平台的上线部署工作，图片序列长度最大超过 50K，完成了 text encoder、image encoder、dit 的 4bit/8bit 量化，并使用 async CPU offload + all gather + PP2~PP4 方案解决了消费卡显存不足的问题，使用 encoder 并行推理 + 异步 PP + 分桶等优化方式将成本降低至 60%，在 16GB 显存的消费卡型上以超过 98% 的 GPU 利用率完成 Seedream4 模型推理，该方案成功支撑字节跳动 2026 年春晚“Z 计划”，稳定承载 4000 QPS 的峰值流量
- ✓ 参与 Seedance2.0 生视频模型（模型参数超 230B）的推理优化及在方舟平台的上线部署工作，视频序列最大长度超过 650K，使用 async CPU offload + all gather + 根据计算图异步释放显存等手段解决 H20 显存不足的问题，成功在 8 卡 H20 上完成推理；使用 async forward + 4bit/8bit 量化 + SP8 通算融合等优化手段在消费卡型上将速度提升了 1.8 倍；并参与开发了动态 40 级流水线并行项目，解决了静态流水线并行由于负载不均匀导致的 bubble 问题，在 16GB 显存的消费卡型上以超过 98% 的 GPU 利用率完成 Seedance2.0 模型推理，目前万卡 PP40 推理集群已经正式稳定承接线上流量
- 方舟自研模型训练加速方案 veFusionX 作者：
- ✓ 负责 veFusionX 项目，veFusionX 是一个基于 hook 机制的无侵入式训练加速解决方案，一行代码即可获取加速收益。对 PyTorch 的 DataLoader、Optimizer、DDP、GroupNorm、SyncBatchNorm 等组件做了深入优化，已经落地生产环境，助力顺利完成 4000 卡预训练任务，整体训练时间缩短 60%，目前在火山引擎上被客户广泛应用于自定义训练任务中

拼多多(上海)网络科技有限公司

高性能计算高级工程师

2024.03-2025.02

- 负责 diffusion 模型的推理和训练的优化，sdxl 和 sd1-5 等模型在 A800 显卡上训练的 MFU 达到了 55%以上，在 L20 上推理的 MFU 达到了 75%以上
- 负责 HFU（硬件算力利用率）和 MFU（模型算力利用率）模块的搭建：研发了高效计算 HFU 和 MFU 的工具，并首次在业务场景下推导并验证了 HFU 与 MFU 的准确换算关系，解决了 HFU 指标“黑盒”难以解释的问题，为资源优化提供了理论依据。基于此体系推进 DCGM 在线监控，半年内节省超 40% 的算力资源。
- 负责业内部分 Attention 算子的预研，完成了 FlashAttention 算子的启发式算法系数推导和开发，对于长上下文场景最高有 50% 的速度提升

上海稳博投资管理有限公司

核心系统加速工程师

2023.06-2024.03

- 优化模型训练，通过 `profile` 寻找模型激活值与速度热点，使用 `async CPU offload`、`kernel fuse` 等方式将显存降低了 60%；重写了部分 `kernel` 并使用 `DataLoader` 优化、多线程多流并行、`CUDA Graph`、异步日志、异步 `ckpt` 保存、减少 `sync` 点等方式将训练速度提升了 40%
- 重写 C++ 日志库，将调用打印日志的平均时间从 1.5 μ s 优化到 200ns 以内，将日志从调用到实际被写入的平均时间从 10 μ s 优化到 1 μ s 以内
- 使用 C++ 开发微秒级高性能高频交易系统，如订单系统、路由系统等

上海米哈游网络科技股份有限公司

低延迟游戏服务器研发工程师

2021.07-2023.05

- 作为“崩坏：星穹铁道”（TGA2023 年度全球最佳手游）项目组服务器核心开发人员，以 C++ 为主要编程语言搭建了游戏服务器基本框架并开发了低延迟游戏服务器：包括各类随机、短信、成就、对话、任务等游戏内玩法；开发并维护了包括在 AWS 上使用的 Redis 集群客户端、日志库等在内的基础功能模块

专业技能

- 常用工具链：熟练使用 `Nsight Compute`、`Nsight Systems`、`PyTorch Profiler`、`pyspy`、`snapshot` 等工具进行全链路剖析，拥有丰富的实战调优经验
- 常用编程语言：C++、Python、CUDA
- 核心理论与体系：深刻理解计算机体系结构、并行计算、编译优化、高速网络通信等知识；有扎实的数学功底，能从理论层面推导性能瓶颈
- 英语水平：CET-6 557 分；可高效阅读和理解英文论文文献
- 研究能力：硕士论文《车载 60GHz 毫米波雷达手势检测和识别算法的研究》使用 3DCNN 和 LSTM 算法以 99% 以上准确率区分 8 种常见手势，获优秀毕设称号，部分内容发表于 *Sensors* 及 SAE 顶会