

李懋林

常年从事 AI 基础设施建设相关工作

男 | 32 | 汉族 | 硕士 | 北京 | 7年经验 | 18810678685 | limaolin1108@126.com



工作经历

2025.01 - 至今

SandAI

Technical Staff

作为 AI infra 专家支撑公司视频大模型生产和部署上线，深入优化训练和推理性能，代表工作如下：

- 以 PyTorch DTensor 为基础建设后训练 Infra，分布式算法与模型实现解耦地支持 SFT、Lora、DPO 多种后训练场景，使算法工程师对 Infra code 的理解成本大大降低。
- 研发 kv cache offload 技术，使 24B Magi-1 模型消费级显卡部署可行；进一步研发 model weight 灵活 offload 和异步 offload 技术，有效规避频繁显存碎片整理等问题，使 24B Magi-1 模型消费级显卡部署不因显存墙产生任何性能损失。
- 结合自回归视频生成大模型以 chunk 为单位进行计算的特点，在 Ulysses 分布式并行算法的基础上改进出 Context Shuffle Overlap 方法，使计算和通信充分掩盖，并在 4090/5090 机器上分别达到 71%/82% 的推理 MFU。

参与公开作品：

- Magi-1 技术报告 <https://arxiv.org/abs/2505.13211>
- Magi-1 github <https://github.com/SandAI-org/Magi-1>

2022.11 - 2024.05

一流科技

技术合伙人

负责开源深度学习框架 OneFlow 相关技术演进、国家项目、研发管理工作，代表工作如下：

- 为增强 OneFlow 框架易用性，更好地从 PyTorch 生态引流。设计即时编译接口，可共享参数显存地将 PyTorch 的 Module 实例转化到 OneFlow 上，后续直接 Eager 执行或转化为静态图 nn.Graph 进一步使用 MLIR 编译加速。
- 为增强 OneFlow 框架完备性，支持更多领域和模型。扩展 Scalar、Tensor 等底层组件以支持复数数据类型，补充傅立叶变换等相关算子并改进 Tanh 等算子自动微分规则，实现对 PINNs，PINO 等 AI4S 模型从零到一的支持。
- 组建并维持 20 左右人的正式和实习混合的研发团队，通过整体例会和细分技术方向例会进行管理，有序支撑 OneFlow 技术演进和国家项目交付相关工作。
- 以即时编译，Eager 运行时重构，物理执行计划分布式编译，函数式自动微分作为核心特性完成 OneFlow 框架 v1.0.0 版本规划，带领团队完成版本研发和发布。
- 以多种分布式并行方式支持、多种国产加速卡适配、PyTorch 生态模型迁移等作为技术指标完成多个军科委、政府项目申报，并负责技术指标的实际执行和验收，国拨经费总计 2700+ 万元。

参与公开作品：

- OneFlow github <https://github.com/Oneflow-Inc/oneflow>

2021.05 - 2022.10

百度

高级研发工程师

作为核心骨干参与开源深度学习框架 PaddlePaddle 建设和 AI4S 领域探索，代表工作如下：

- 引入自动微分基础算子体系，基于自动微分基础算子体系设计前反向自动微分规则，并基于计算图变换实现前反向自动微分变换，在 PaddlePaddle 框架以张量为中心的架构设计上完成高阶自动微分模块设计开发。受益于基础算子体系对计算逻辑的最简表达和对接自研编译器后的算子融合优化，在 AI4S 领域模型上验证性能领先最优竞品 JAX 30%。

- 针对 AI4S 领域出现的以物理驱动神经网络为代表的典型算法，抽象出 Geometry、PDE、Network 等模块并作为最早贡献者之一参与开发科学计算工具组件 PaddleScience。
- 入选百度高潜人才计划——风雷计划。

参与公开作品：

- PaddlePaddle github <https://github.com/PaddlePaddle/Paddle>
- PaddleScience github <https://github.com/PaddlePaddle/PaddleScience>

2020.1 - 2021.04

技术 Leader

商汤

负责闭源深度学习框架 SenseParrots 技术演进相关工作，代表工作如下：

- 设计开发 JIT 模块，以用户模型表达中的单个 python 函数为目标对象，通过 trace 功能在函数首次执行时记录下框架中算子实际调用情况形成计算图，对接公司自研编译器进行算子融合优化并缓存生成的 kernel，后续执行过程中直接调用缓存的 kernel。使用该模块对目标检测模型后处理部分进行加速可使模型端到端性能提升 10%。
- 进行 CSE、DCE、显存释放时机调整等计算图优化 pass 开发，可对 trace 功能得到的计算图进行优化。
- 主导知乎专栏建设，组织团队输出深度学习编译、大规模训练、训推一体相关原创技术文章 10+ 篇。

参与公开作品：

- 知乎专栏 https://www.zhihu.com/column/c_1327617111376633856

2018.08 - 2019.12

研发工程师

华为

参与公司内部 Davinci 和 Manchester 项目研发，代表工作如下：

- 基于华为自研 SIMD 指令集进行 Davinci 系列芯片上高性能算子开发。根据计算单元处理能力、多计算单元之间传输带宽对数据进行合理分块，通过乒乓 buffer 技术使算子运行过程中核心计算单元利用率达 90%。
- 对开源图像处理编译器 Halide 调研学习，针对其中 compute 和 schedule 分离的设计思想，综合 parallelism、locality、vectorization 的 schedule 原语设计形成学习笔记本和内部分享。

专利

专利名称：模型生成方法、装置和电子设备

授权公告号：CN114897146B

对应 PCT 专利名称：MODEL GENERATION METHOD AND APPARATUS AND ELECTRONIC DEVICE

国际公布号：WO2023221407A1

简介：基于基础算子体系和程序变换实现高阶自动微分的机制

发明人：李懋林;胡晓光;白童心;刘红雨;于佃海;高铁柱;马艳军

专利名称：基于偏微分方程处理流场数据的方法、装置及电子设备

授权公告号：CN114139104B

简介：基于傅里叶变换进行偏微分方程组求解和流场数据处理的方法

发明人：郑筠陶; 向辉;马艳军;于佃海;毕然;胡晓光;高铁柱;赵乔;邢冯;李懋林;刘红雨;杨嘉彬;吴威龙;白童心

专利名称：深度学习模型的执行方法、装置、电子设备及存储介质

授权公告号：CN112862109B

简介：以函数为单元，基于一次程序执行和记录进行计算图获取，并且根据函数传参分析进行缓存的机制

发明人：李周洋;李懋林;张行程

专利名称：一种算子的执行方法、装置、计算机设备及存储介质

授权公告号：CN112947933B

简介：基于一次程序执行和记录进行计算图获取，并调用深度学习编译器生成融合算子并执行的机制

发明人：李懋林;李周洋;张行程;李秀红

专利名称：一种代码解析的方法、装置、电子设备及存储介质

授权公告号：CN112860262B

简介：基于纯函数来进行计算图划分的机制

发明人：李秀红;陈仁泽;李懋林;颜深根

教育背景

2015.09 - 2018.07

清华

仪器科学与技术，学术硕士，成绩排名 16/70，一篇SCI，一篇EI

2021.09-2015.06

北航

测控技术与仪器，学士，成绩排名 30/170

技能特长



其他

2010年全国高中数学联赛河南省一等奖
2010年全国高中物理联赛河南省二等奖