

李润

✉ lirunchh@gmail.com · ☎ (+86) 158-8028-9570 ·

🎓 教育背景

厦门大学, 福建, 厦门
工学硕士 计算机科学与技术

2018 年 9 月 – 2021 年 6 月

湖南科技大学, 湖南, 湘潭
工学学士 计算机科学与技术

2013 年 9 月 – 2017 年 6 月

📄 论文情况

- [1] Lin, Xianming and Li, Run, Zheng, Xiwu Peng, Pai Wu, Yongjian Huang, Feiyue and Ji, Rongrong “Aggregating Global and Local Visual Representation for Vehicle Re-IDentification,” in *Proceedings of the IEEE Transactions on Multimedia (SCI 一区)*, 2020
- [2] Deng, Youming and Lin, Xianming and Li, Run and Ji, Rongrong “Multi-scale Gem Pooling with N-Pair Center Loss for Fine-Grained Image Search,” in *Proceedings of the IEEE International Conference on Multimedia and Expo (CCF B 类)*, 2019
- 3] Chen, Ting and Liu, Jianxun and Cao, Buqing and Peng, Zhenlian and Wen, Yiping and Li, Run “Web Service Recommendation Based on Word Embedding and Topic Model,” in *Proceedings of the IEEE Intl Conf on Parallel Distributed Processing with Applications, Ubiquitous Computing Communications, Big Data Cloud Computing, Social Computing Networking, Sustainable Computing Communications (CCF C 类)*, 2018

🏢 工作经历

腾讯 上海, 徐汇

2021 年 7 月 – 至今

简介: 负责大模型分布式训练加速、训练框架研发、模型压缩与量化落地; 主导自研 Youtu Agentic RL 训练框架、Tillearn.llm 训练框架、TIACC 训练加速库、TIACC 模型压缩库、DeepSeek 推理优化; 支撑腾讯云公有云/私有云大模型平台, 负责头部客户 POC 与训练优化; 参与混元 3.0 训练优化与 YouTu2.0 训练优化。

🏠 项目经历

混元 3.0 训练 infra 优化

2025 年 12 月 – 至今

- Fuse Transformers。将 Transformer Layer 的 forward 切分为多个 function 模块, backward 计算融合进一个 torch.autograd.Function 中, 自定义的控制计算与通信, 使得通信 (DeepEP A2A dispatch/combine) 与计算 (attention、MLP、重算) 在不同 CUDA stream 上 overlap 执行, 同时跨层流水化激活 offload/prefetch (GPU<->CPU)。
- 大模型大规模训练稳定性。构建完整的慢节点监控与计算通信分析模块, 能够常驻训练任务中在极低性能损耗 (<1%) 的情况下自动检测慢节点, 并在其他组件的支持下, 完成训练任务剔除慢节点并重启; 参与 Bit-wise 对齐工作, 避免随机性带来的模型对齐问题; 解决千卡训练时的实际问题。

YouTu2.0 训练 infra 优化

2026 年 4 月 – 至今

MOE 动态自适应平衡。针对 H200 集群下 MoE 训练的专家热点平衡性带来的 Loss 尖刺问题, 主导设计了硬件感知型动态平衡策略。通过将 GPU Tile-size 引入辅助损失权重 w 的动态反馈回路, 在保障语义特化 (128 以内弱约束) 的同时, 精准拦截跨 Wave 计算气泡; 最终实现 MFU 提升约 5%, 达成 Zero-Drop 训练并显著增强了模型收敛稳定性。

Agentic RL 训练框架

2025 年 9 月 – 至今

与算法团队合作, 结合 Youtu-Agent 与 Agent Lightning 在实践中不断优化解决框架训练稳定性 (内存稳定性、超时机制等) 问题与算法稳定性 (离线策略过拟合、对齐 Verl 与 Agent Lightning 参数差异

等), 设计并实现 Client-Queue-Server 分布式 Agentic RL 训练架构, 通过 LLM Proxy 拦截技术实现完全黑盒化的 Agent 接入, 解决了训练与推理部署的算子/参数一致性对齐问题。

- 多轮轨迹聚合与 Response Mask。实现 Trajectory-level 训练数据构建, 将多轮 Agent 对话的 N 个 LLM call 压缩为 1 个训练样本。设计 resolve_response_mask 算法, 基于尾锚点串匹配与编辑距离验证, 在合并后的 token 序列中精确定位 LLM 输出与工具/环境输出的边界, 生成 response_mask (LLM 输出 =1, 工具输出 =0) 用于 RL 训练。支持 resolve 失败时自动降级到 Legacy 逐轮模式, 保障训练鲁棒性;
- 基于 openclaw 构建 RL 训练能力, 基于 Youtu Agentic RL 框架本身打磨框架完全黑盒的 Agentic RL。设计服务级黑盒模式, 使第三方 Agent 服务无需任何适配即可接入训练框架, 让 Agent 服务与训练框架之间做到解耦 (解决训练推理部署对齐问题);

大模型推理优化 · deepseek

2025 年 2 月 – 2025 年 8 月

在腾讯云 H20 机型上高效部署 Deepseek 相关模型, 支撑内外部业务, 在吐字率 20 tokens/s 的情况下提升服务并发; 快速学习开源方案, 并集成到内部定制版的推理框架中。

- 研究并实现 allreduce ep 并行推理方案, 通过 timeline 分析定位之前版本计算 kernel 效率过低的瓶颈, 在新版本中采用 int4 deepgemm 和 deeppep 技术, 同时支持 cuda graph 和 mtp, 最终实现 84% 的性能提升 (token/s 21.4 -> 38.9);
- 研究并实现 deepseek all2all ep 并行, 并结合 PD 分离推理方案, 运用 deeppep 的 normal 和 low_latency 接口、deepgemm、eplb 等开源组件, 完成 sglang 框架上的推理方案实现, 并结合 mtp 和 cudagraph 进行深度优化, 进一步提 QPM、降低推理延迟;
- 研究并实现 deepseek ep 负载均衡方案, 通过分析模型 ep 并行推理瓶颈, 发现推理速度受热点专家处理 token 数不均影响, 通过负载均衡策略平衡各专家 token 处理量, 使推理速度提升 3-5%。研究 Zigzag 技术, 后期开源到 vllm 仓库;
- dp 负载均衡。设计 vllm 调度策略, 平衡多个实例之间的负载均衡。分离 client 和 Engine 逻辑, 每个节点自己处理自己的 GPU 资源, 自己处理跨机通信逻辑, 缓解主节点负担。

大模型推理优化 · 模型量化

2023 年 12 月 – 2024 年 12 月

研究模型 4bit/8bit 量化技术。对于业务模型进行 8bit 量化, 4bit 均匀量化和 4bit 非均匀量化的研究, 优化知识引擎成本模型推理成本。参与大模型算法、工程、测试多方对齐工具的建设, 缩短大模型上线的耗时, 确保大模型在能够复现稳定的结果。与混元团队合作维护混元模型的量化算法工具库, 设计并支持 transformers-base 的开源模型, LayerwiseSearchSmoothQuant 与非均匀 4bit 量化算法, 并集成到混元一站式平台。

- int8 W8A16 量化降低原本 fp16 大模型一半的显存空间, 能够将大模型推理的成本大幅度压缩。8bit 量化模型的推理速度相比于 fp16 加速 30%, 同时保证精度几乎与 fp16 模型对齐。对于业务模型不同层的激活分布差异较大, 基于开源方法提出 LayerwiseSearchSmoothQuant, 细粒度的进行 int8 量化, 对于每一个 Linear 层独立搜索最优 α , 显著提升量化精度。多个子任务模型进行评估, 总体指标浮动在 0.5% 以内;
- 4bit W4A16 均匀量化技术降低原本 int8 大模型一半的显存空间, 推理速度对比于原本 INT8 模型加快 30%。多个子任务模型进行评估, 总体指标浮动在 2-5% 以内。同时优化 awq 开源方法量化速度慢问题, 70B 模型的量化时间缩短 10 倍以上, 加快模型上线需求;
- 非均匀 4bits W4A16 量化算法研究。针对于业务模型在均匀量化上效果不佳的问题, 提出非均匀 4bits 量化算法, 通过混合初始化, 并结合梯度来更新和模型训练的策略来优化量化的效果, 在模型指标上达到 77.32% 接近于原始结果的 fp16 数据格式的 78.31%, 指标损失在 1% 以内, 与 int8 量化齐平。推理速度也在单并发下比 INT8 加速 20%, 8 并发下比 INT8 加速 44%;

tilearn.llm 训练框架研发

2023 年 3 月 – 至今

构建大模型训练核心工具库 tilearn.llm (主要为大模型训练显存优化技术、并行优化技术、计算优化技术、peft 优化技术); 构建大模型训练加速核心工具库 tilearn.ops (cuda kernel 加速); 构建大模型训练中英文测试 baseline 及其分析工具; 建立 tilearn.llm 和 tilearn.ops 全流程工具链, 包含代码架构、接口设计、功能模块、代码加密、多版本 python whl 包自动编译、python whl 包外网内网发布流程、平台鉴权控制、文档。通过鉴权的方式, 能够使得客户直接使用 pip 命令安装 tilearn.llm 和 tilearn.ops, 并且只需要修改一行代码, 就可以便捷的使用 tilearn 训练框架的所有功能。完成多个版本 tilearn.llm 和 tilearn.ops 的分析报告, 成为为衡量 tilearn 训练框架与其他框架的对比标准。

- 显存优化技术研究。shard init 技术研究, 开发 load checkpoint TP, shard init 下支持模型读取。grad_checkpoint 技术研究, 支持 FlashAttention 模型结构格式下的 bloomz 和 llama 模型的 grad_checkpoint 功能;
- 并行优化技术研究。研发 tensor parallel 技术, 支持 bloomz、gpt2、chatglm 模型, 支持千亿模型的训练任务。Delta-Tuning 模块。研发 tilearn.llm.peft 模块, 兼容 huggingface peft 开源仓库, 支持 Prompt Tuning、Prefix-Tuning、LoRA、Adapter 等业内主流方案, 模型微调训练加速 1 倍以上, 指标下降 1% 以内。并使得 tilearn.llm.peft 支持 ColossalAI zero2/zero3 并行优化, 兼容 huggingface transformers grad_checkpoint 技术; 通过 monkey-patch HuggingFace Trainer + Accelerate + ColossalAI 实现零代码改动的透明 3D (TP/PP/EP) 并行。
- 计算优化技术研究。将 ALiBi 位置编码深度融合进 Flash Attention v2 的 Tiled CUDA Kernel 内部, 为 Bloomz、Baichuan、Aquila 定制了前向/反向 kernel;
- 参与各类腾讯云对外 POC 项目, 优化客户的算法训练效率与协助客户完成从 0 到 1 的模型训练, 同时将经验积累到内部训练框架大模型领域: 支撑荣耀 (训练加速 27%)、粉笔蓝天 (训练加速 17.8%)、猿辅导 (MFU 加速 2.92 倍) 等项目, 实现训练速度显著提升; 自动驾驶领域: 支撑长城 (训练加速 28.9%)、博世 (训练加速 3.57 倍)、毫末 (训练加速 2.1 倍) 等客户项目, 实现训练速度显著提升;

客服大模型研发

2023 年 3 月 – 2023 年 7 月

研究开源方案, 摸索到 transformers+ColossalAI+ 自研训练方案, 协助内部团队完成百亿/千亿级别模型训练, 构建训练 baseline。助力内部大模型的研究和平台大模型能力的建设。同时也参与到平台大模型的数据与模型安全性建设。助力 70B 业务模型实现 2 倍训练速度的提升。参与客服大模型 RLHF 步骤的训练工作, 在资源受限的情况下, 成功在内部太极平台 V100 计算集群上完成强化学习混合并行训练。

TIACC 训练工具库研发

2021 年 7 月 – 2023 年 3 月

- 模型压缩。开发实现了自动量化工具的黑名单功能; 开发 int8 量化训练策略; 开发基于 jit 的 pytorch 的图优化技术 (该技术是自动量化和自动剪枝的核心控件), 达到业界先进水平, 推动核心竞争力的形成。同步支持支持内部业务发展, 降本增效。在指标不受影响的前提下, 相比于 fp16, 提升 35% 速度落地内容审核业务, 提升 50% 速度落地人脸融合业务。
- 研发模型压缩 trace 图优化模块, 支持 timm、mmdet、det2 共 3 种框架, 每种框架 5+ 共 15+ 种 cv 或 nlp 模型正常 trace 通过, 建设完善 try-catch 机制确保量化、剪枝、蒸馏后续自动化图优化正确运行。在立恺项目中, 使用 tiacc-slim 蒸馏方案, 加速比达到 30%。

TI 平台自动机器学习与大模型市场

2021 年 7 月 – 2024 年 07 月

- TI 平台私/公有云自动机器学习建设。完成自动机器学习 CV 领域的图片分类场景和目标检测算法多个模型的自动机器学习算法建设, 开发平台算法, 完成对接平台的数据集和环境信息, 协同完成了平台预训练模型, 日志, 指标, 参数等功能的建设。支持内外部算法团队完成平台迁移。
- 主导大模型市场建设, 支持和上线内部 nlp 大模型到 TI 平台公有云。设计完善的模型加密方案保护内部知识产权, 构造自动化 ci 流程压缩模型上架 AI 市场人力成本, 使得单个模型上架 AI 市场人力成本控制在 2 周以内。适配 TEG 中文命名实体识别、中文情感分类和短文本匹配 NLP 混元大模型上架 TI 平台 AI 市场模块。适配优图自研内部大模型, 同程文旅客服场景大模型和客服大模型上架 TI 平台公有云 AI 市场模块。

技能

- 编程语言: Python、Java、Triton
- 框架: PyTorch、Transformers、DeepSpeed、ColossalAI、Megatron、vLLM、SGLang
- 研究领域: 大模型训练优化、Agentic RL 训练、CV 训练优化、自动驾驶训练优化、模型压缩

获奖情况

校级奖学金, 湖南科技大学
校级奖学金, 湖南科技大学
校级奖学金, 湖南科技大学
优秀毕业生, 厦门大学

2014 年 10 月
2015 年 10 月
2016 年 10 月
2021 年 6 月