

杨明

panandy1996@163.com | 19520375476

研究兴趣: 大模型强化学习后训练 (RL Post-Training), Agentic RL, 分布式训练系统优化

自我简介

深耕大模型强化学习后训练(RLHF/RLVR/Agentic RL)与分布式训练系统架构，精通大规模GPU集群训练优化，具备丰富的技术带队与从0-1落地经验：

- 开源RL训练框架ROLL创始人(3.2k stars)，主导架构设计、核心研发、业务落地、开源运营、学术合作全链路，驱动20+业务落地
- 主导训练范式从RLHF→RLVR→Agentic RL三度演进，提出Agent Native训练范式实现训练与agent框架解耦，支撑480B MoE模型跨2500+ GPU训练
- 推动算法工程co-design，产出RollPacker/RollArt/RollMux等NSDI/OSDI顶会论文；主导与港科大等高校合作，构建产学研闭环

工作经历

阿里巴巴 | 平台技术-智能引擎-大模型训练 | 2021.07 - 至今

- **技术带队**负责大规模强化学习训练框架ROLL架构设计与研发，从0到1构建分布式RLHF/RLVR/Agentic RL训练系统，支撑2500+ GPU规模训练，训练效率最高提升10×
- 主导异步训练架构、Tail Batching等核心优化，端到端训练耗时降低50%-60%，近线性Scale突破百卡规模
- 作为Infra Project Leader支撑ROME/Qwen-Qoder/Qwen BrainVL等20+业务落地，覆盖千亿MoE模型多模态训练、Agentic RL等全场景

项目经历

ROLL — 大规模Agentic强化学习训练框架

2023.10 - 至今 | 框架Leader | 开源: <https://github.com/alibaba/ROLL> (3.2k stars)

独立设计并构建ROLL框架(前身为ScaleAligner)，引领RL训练范式从RLHF→RLVR→Agentic RL三度演进，以技术Owner角色驱动20+业务落地，支撑480B MoE模型跨2500+ GPU的RL训练。

架构与范式

- 设计 Worker-Strategy + Single Controller 架构，统一 RLVR 与 Agentic RL 训练范式，将RL流程抽象为可插拔Pipeline
- 提出 Agent Native 训练范式，基于 ProxyServer 拦截 agent 请求实现训练与agent框架解耦，泛化支撑多类黑盒agent框架接入
- 定义 EnvManager 训练描述方案与 GEM 标准接口，统一抽象电商/Game/SWE agent/ToolUse等多类任务

性能优化

- 异步并行 Rollout：消除轨迹内长尾等待，加速 $2\times$ (576s→286s)；冗余 Env 机制加速 $1.4\times$ (267s→186s)
- 异步训练架构：消除轨迹间长尾瓶颈，SWE训练耗时 -38% (8.32h→6h)，近线性Scale
- ref logprobs剪枝+old_logprobs缓存，单阶段耗时 -47%；overlap step/reward，端到端耗时 -50%
- 设计动态采样调度加速 $2\times$ (190s→90s)；指导并review GPU partial overlap、PD分离、FSDP2、fp8等10+项Infra建设

前身 ScaleAligner (2024.04 - 2025.06)：独立从0到1构建分布式RLHF训练框架，设计训练推理分离架构突破显存瓶颈；三级分布式抽象(Role→Cluster→ClusterGroup)灵活支持任意GPU配比；Strategy抽象层实现DeepSpeed/Megatron/vLLM多Backend统一；70B模型参数同步16秒，支撑70B+ PPO/Online-DPO TBstars心流训练落地

RollPacker — 长尾Rollout优化 | NSDI 2026

2025.06 - 2025.09 | 技术mentor | [arXiv](#)

解决同步RL训练中长尾响应导致的GPU利用率低下问题，保持训练精度不变，实现 $2.03\times$ - $2.56\times$ 端到端加速(Qwen2.5 7B-32B, 128 GPU)。

- Tail Batching：投机执行($\eta=1.25$)将长尾响应整合到少数long rounds，short rounds加速 $2.1\times$ - $3.6\times$ ，平均rollout提升 $3.9\times$
- 动态TP：离线基准+在线选择的并行规划器，动态调整张量并行度，相比固定TP平均加速 $1.9\times$
- 流式训练器：响应立即流式传输训练+缓冲梯度延迟归一化，提供20%性能提升
- 奖励调度器：MPS并发执行judge/actor LLM，8k响应长度下71%性能提升

ROLL Flash — 异步训练架构

2025.07 - 2025.11 | ROLL Project Leader & 共同一作 | [arXiv](#)

原生异步设计解决同步RL训练的长尾延迟、环境阻塞、扩展性瓶颈，训练精度与同步训练相当，最高 $2.72\times$ 加速(Qwen3-8B)；百卡规模 $8\times$ GPU带来 $7.6\times$ 效率提升。

- 队列调度：独立采样任务专属队列消除同步等待，特定配置 $3.4\times$ 加速
- 候选生成并行化：跨GPU分发调度与结果聚合，最高 $1.95\times$ 提升
- 环境交互异步化：交互期间释放GPU，ALFWorld $1.58\times$ 加速
- 冗余环境部署：应对fail-slow/fail-stop，额外7%-16%吞吐提升
- 异步比(ρ)+Decoupled PPO/TOPR补偿陈旧样本，异步与同步最终性能相当

ROME — 端到端智能体学习生态系统

2025.09 - 2026.01 | ROLL Project Leader | [arXiv](#)

在90+人联合项目中作为ROLL训练方向Project Leader，基于ROLL异步Agentic RL训练与Agent Native范式，训练出SWE-bench Verified达57.4%的ROME模型(Qwen3-MoE)。

- ROLL-ROCK集成：直接开发训练框架与ROCK沙盒执行引擎的集成链路，打通训练到执行环境的端到端链路
- Async Agentic RL训练：基于细粒度rollout(三阶段样本级并行化)与异步训练(样本缓冲区解耦rollout与training)支撑ROME全流程RL训练
- Agent Native训练范式：设计ROLL侧rollout loop，通过ProxyServer拦截agent请求实现训练与agent框架解耦，支撑agent native训练范式在ROME中验证与落地
- 训练稳定性保障：构建agentic轨迹合成与落盘链路；实现rollout hang检测(超时阈值+心跳监控)；指导设计GroupFilter UDF异常轨迹过滤机制
- 大规模训练支撑：指导设计Train-Rollout时分复用与动态GPU分配方案消除资源气泡；配合算法完成235B MoE模型agentic RL训练

Qwen-Coder-Qoder — 智能编码模型

2025.08 - 2026.03 | ROLL Project Leader

通过大规模RL训练千亿参数MoE模型打造智能编码模型，超越Cursor Composer-1；ROLL多维度优化实现训练吞吐量提升 $10\times$ 。

- Async Agentic RL训练：Qoder为ROLL async agentic RL训练能力的首个需求来源，基于真实编码场景提取需求并实现首个版本，后续泛化为ROLL通用能力
- Rollout-Training协同设计：放宽策略约束支持跨版本采样、训练与rollout并行运行、动态资源调配，实现千亿参数MoE模型高效RL训练
- 训练性能优化：组合异步调度、前缀/KV缓存复用、冗余环境执行等优化，支撑训练吞吐量提升 $10\times$ ；排查定位torch 280上flash_infer sampler效果问题
- Infra方向管理：组织划分并review Checkpoint Engine(model update优化)、MOE Router Replay(R3)、FP8 Rollout、SGLang-router等4个子方向

ROLL生态应用与拓展

作为ROLL Project Leader支撑以下业务落地与生态共建，覆盖RLVR与Agentic RL全场景：

- **Qwen BrainVL**：397B多模态RL训练(27B-397B全系列)，设计LLM-Judge异步并发(Rollout+20%)，训推异步优化397B模型提速53%+，端到端提速60%+
- **HappyHorse/Oyster**：百B级视频多模态RL训练(PERL/CaptionRL)，解决MoE Checkpoint OOM(pin_memory复用消除内存峰值)
- **STAgent (高德)**：时空推理Agent，FastMCP协议统一10+工具调用接口，相比Verl训练效率提升80%
- **淘宝直播**：Multi-Agent RL协同优化工具调用与回复模型，事实正确性+4.1pt，帮助性+23.6pt
- **Qwen Agentic**：verl-ROCK对接，定位并推动解决TITO/校验失败/reward异常等跨系统隐蔽问题
- **LitePPO (ICLR 2026 Poster)**：在ROLL统一框架上系统化评估RL4LLM技巧，仅2项核心技巧(混合归一化+Token-level损失)即达/超越DAPO等5项堆叠方案
- **GEM (ICLR 2026 Poster)**：为LLM Agent提供标准化多轮交互环境框架，完成ROLL-GEM环境接口适配与跨框架验证

ODL — 实时样本与特征平台

2022.04 - 2023.10 | 核心开发者

负责ODL实时样本链路和Feature实时特征平台的性能优化与架构升级，支撑广告定向业务的实时训练需求。后接任定向业务负责人，承担双十一/618等大促接口人职责。

- **性能优化**：深入分析瓶颈，CPU使用率降低40%+，资源节省2w+ core；优化SampleWrap节点，资源降低50%+
- **架构升级**：完成Blink→VVP迁移，下线4.5w+ core；迁移AI Lake存储，数据存储延长至15天+

- **稳定性治理**: 解决数据倾斜问题, 延迟从数十分钟降至秒级, 保障大促零故障
- **特征SQL化**: 主导AIF特征生产SQL化, 资源降低50%, RT降低20%, 解决商品信息导入滞后问题
- **效率提升**: 优化定向CVR追数据性能, 耗吋从20h→3-5h; 明文特征传递使训练速度提升一倍

Nash — 强化学习策略调参统一框架

2021.10 - 2024.10 | 框架Owner

作为Nash方向Owner, 设计并开发策略调参统一SDK, 收拢强化学习(XRL)和超参寻优(XE)链路, 形成策略迭代统一表达方法, 负责框架演进与多业务落地。

- **框架统一**: 收拢XRL强化学习和XE超参寻优链路, 形成统一接口, 支撑多场景策略调参
- **性能突破**: 优化Nash IO能力, 数据读取速度提升10倍, 样本利用率5%→100%, 支撑bidding全量样本训练, BuyCnt+2%
- **模型上线**: 开发Nash serve服务, 支撑diffusion生成式bidding模型上线, BuyCnt提升2.09%, ROI提升3.36%
- **多业务支撑**: 落地定向USCB、万相台Bidding、飞猪、AE、直通车、淘特等7+场景
- **比赛支撑**: 独立构建天池RL比赛评测系统 (200+队伍) ; 独立承担NeurIPS 2024自动出价比赛评测系统, 稳定零异常

教育背景

中国科学院大学 | 计算机应用技术 | 硕士 | 北京市优秀毕业生 | 2019.09 - 2021.07

武汉理工大学 | 计算机科学与技术 | 本科 | 优秀毕业生 | 2014.09 - 2018.07

技术专长

- **算法工程Co-Design**: RLHF→RLVR→Agentic RL范式演进驱动系统设计, 产出NSDI/OSDI顶会论文
- **RL后训练算法**: PPO, GRPO, DAPO, Online-DPO, Decoupled PPO, TOPR, 混合归一化, Token-level损失
- **RL训练框架**: ROLL(作者), verl, slime, OpenRLHF, trl
- **分布式训练系统**: 训推分离架构, 异步训练, 5D并行策略, PD Disaggregation
- **训练优化**: 长尾优化(Tail Batching/动态TP), 异步训练, 冗余环境, FP8, Sequence Packing, KV Cache复用
- **训推后端**: vLLM, SGLang, DeepSpeed, Megatron-LM, FSDP2
- **Agent基础设施**: GEM环境框架,, ROCK沙盒, SWE-bench
- **工程基础**: Python, C++, Pytorch, Ray, Docker, Kubernetes, Flink

论文发表

顶会论文

- **RollPacker**: Mitigating Long-Tail Rollouts for Fast, Synchronous RL Post-Training | NSDI 2026 | [arXiv](#)
- **RollMux**: Phase-Level Multiplexing for Disaggregated RL Post-Training | OSDI 2026 | [arXiv](#)
- **RollArt**: Scaling Agentic RL Training via Disaggregated Infrastructure | OSDI 2026 | [arXiv](#)
- **GEM**: A Gym for Agentic LLMs | ICLR 2026 Poster | [arXiv](#)
- **Tricks or Tricks?** A Deep Dive into RL for LLM Reasoning | ICLR 2026 Poster | [arXiv](#)
- **Attention Illuminates LLM Reasoning**: The Preplan-and-Anchor Rhythm Enables Fine-Grained Policy Optimization | ICML 2026 Poster | [arXiv](#)
- **ShopSimulator**: Evaluating and Exploring RL-Driven LLM Agent for Shopping Assistants | ACL 2026 Main | [arXiv](#)
- **Complementary Reinforcement Learning** | COLM 2026 在投 | [arXiv](#)
- **Auto-Bidding in Large-Scale Auctions**: Learning Decision-Making in Uncertain and Competitive Games | NeurIPS 2024 Competition Track | [OpenReview](#)

技术报告

- **ROLL**: Reinforcement Learning Optimization for Large-Scale Learning | [arXiv](#)
- **ROLL Flash**: Accelerating RLVR and Agentic Training with Asynchrony | [arXiv](#)
- **ROME**: Let It Flow: Agentic Crafting on Rock and Roll | [arXiv](#)
- **ROSE**: Rollout On Serving GPUs via Cooperative Elasticity for Agentic RL | [arXiv](#)
- **AMAP Agentic Planning** Technical Report | [arXiv](#)
- **LiveThinking**: Enabling Real-Time Efficient Reasoning for AI-Powered Livestreaming via RL | [arXiv](#)
- **Adaptive Segment-level Reward**: Bridging the Gap Between Action and Reward Space in Alignment | [arXiv](#)