

柳泓鑫

📞 (+86) 180-8610-6723 · ✉️ lhx0217@gmail.com · 🌐 github.com/ver217

工作经历

携程	2025 年 6 月 – 至今
潞晨科技	2021 年 9 月 – 2025 年 4 月
腾讯 实习	2020 年 7 月 – 2020 年 8 月

教育背景

新加坡国立大学	计算机 (人工智能)	硕士	2020 年 8 月 – 2021 年 10 月
华中科技大学	计算机科学与技术	本科	2016 年 9 月 – 2020 年 6 月

专业技能

PyTorch / Tensorflow / Megatron-LM / Deepspeed、Python、C / C++、Git

项目经历

Peta-Training	携程	2025 年 6 月 – 至今
并行训练框架，主要贡献者		
基于 Swift 和 Megatron 的并行训练框架，聚焦于 SFT，继承了 Swift 的数据处理，训练后端可选 Swift(deepspeed) 和 Megatron。实现了 Sorted Packing 数据加载，两种后端通用。在 Megatron 后端上进行了深度优化：		
• 算子级选择性重计算，最大限度减少冗余重计算 • 基于 NVSHMEM 的变长数据 P2P 通信优化，VPP MFU 提升 8% • 基于 einops 的易维护易扩展的权重转换工具 • dataloader pin memory pool，消除多模态数据加载造成的指令气泡，提升多机性能 • grouped gemm 优化，消除 TE 实现的多次 kernel launch • autotune 工具，给定数据、模型和机器规模，分钟级搜索出最优并行训练配置 • fused linear cross entropy，兼容 TP，以 lm head 的 23% 计算时间换取降低 90% 内存消耗 • 数据均衡度、moe 负载均衡度监控工具 • TP 通信优化，移除 MAX_DEVICE_CONNECTIONS 依赖，tile 粒度通信计算折叠（进行中）		
在我们的场景 (VLM) 下，dense 模型实现比 Swift 1.55x 加速 (MFU 39.5% vs 61.2%)，比 Megatron 1.58x 加速 (MFU 44.5% vs 70.2%)；MoE 模型实现比 Swift 2.29x 加速 (MFU 2.4% vs 5.5%)，Megatron 2.95x 加速 (MFU 11.5% vs 33.9%)。		
ColossalAI	潞晨科技	2021 年 9 月 – 2025 年 4 月
并行训练框架，主要贡献者		
基于 PyTorch 的并行训练框架，负责设计并开发了 Gemini 并行 (Chunk-based Zero3)、PP、EP、Checkpoint、Lazy Init 模块，深度参与了 TP、Zero、SP、CP 模块。		
框架训练性能持平主流并行训练框架。适配了 Nvidia 和华为两个平台的硬件。		
OpenSora	潞晨科技	2024 年 02 月 – 2025 年 4 月
视频生成大模型训练，系统侧主要贡献者		
支持了 Vae 的 TP Conv 和 DiT 主体的 TP、CP。针对具体训练场景进行优化，包括异步 Checkpoint (将保存时间从 300s->10s)、dataloader pin memory cache (解决 dataloader 异步 pin memory 对 CUDA 阻塞的问题)、多线程 + 流水线加载 Checkpoint (大大降低了错误恢复时间)。		

TensorNVMe

潞晨科技

2022 年 6 月 – 2024 年 11 月

CPU Offload、异步保存，主要贡献者

使用 C++ 开发的张量 CPU Offload、异步 Checkpoint 保存库。支持 libaio、liburing、pthread 三种后端以应对不同场景。可降低 95% 以上的保存时间。

ColossalChat

潞晨科技

2023 年 5 月 – 2025 年 4 月

RLHF 训练 *pipeline*，系统侧主要贡献者

实现了 PPO、DPO、GRPO 等 RL 算法。早期使用训推一体架构，后受限于推理效率，采用训推分离架构。推理侧使用 VLLM，训练侧使用 ColossalAI，使用 Ray 进行衔接。使用流水线模式最大限度降低硬件等待时间。