



江林楠

男 | 32岁

- 17770363076
- jianglinnan001
- jianglinnan@gmail.com

求职信息 JOB INFOR

工作时长：3年
求职意向：大模型算法
期望薪资：60-90K
期望城市：深圳

个人优势 PERSONAL ADVANTAGES

熟悉大模型算法相关的知识，对CNN，Transfomer，Diffusion有深入了解，大模型实践经验丰富。计算机相关的基础技能扎实，英语阅读与写作能力优秀，同时具备良好的团队管理与沟通能力。

主要技术栈包括大模型训练、分布式计算，大模型精调，大模型推理，多模态大模型等。熟练使用linux系统, Python, Pytorch, Megatron-LM。能够使用Deepspeed, Vllm, Verl, Swift, Triton, TenserRT开展大模型相关工作。

工作经历 WORK EXPERIENCE

之江实验室 | 大模型算法 2022.09-至今

内容：

一、万卡集群建设

参与混合万卡集群建设，担任W64 2000 卡集群模型与算法总负责人。主导完成多型号国产显卡上的大模型适配、性能测试、精度对齐与分布式性能调优工作。同时协助排查与解决模型训练过程中的算法与系统问题，保障大规模集群的稳定运行与高效利用。

二、南湖Megatron开发

参与南湖megatron框架的核心研发与测试工作。南湖megatron 是之江实验室基于Megatron-LM 及多个国产芯片厂商软件栈自研整合的大模型训练框架，个人主要职责包括：

- W64 集群 nh-megatron 的整体代码开发
- 构建独立的 nh-megatron 仓库并完成系统化提测
- 参与 V5000 与 X10000 集群 Megatron 多项功能的开发与验证

三、国产显卡大模型分布式训练与性能调优

负责国产型号显卡平台上主流 Dense 与 MoE 架构大模型的分布式训练与系统级性能优化。通过对 Megatron 核心代码的深度开发与改造，构建 nh-megatron 训练体系，并实现多项关键优化策略，包括 Pai-Megatron上MoE Grouped GEMM正确性修复，FLash Fusion, QKV Flash Attention, Permute Fusion, MoE All-to-All Communication Overlap, YaRN RoPE Fusion等。

四、千卡规模021-MoE-32B模型长周期训练实践

在 960 卡国产算力集群（单卡标称 280 TFLOPS）规模下，负责并完成 021-MoE-32B (类DeepSeek V2)模型的长周期预训练任务。

1. 训练数据与规模

总数据规模8.1T tokens

2. 训前准备

数据集构建与预处理流程搭建、模型结构与超参数配置对齐、国产显卡与 NVIDIA GPU 的 1 万步精度对比测试

3. 训练过程控制与稳定性保障

开发钉钉机器人，在整个训练过程中，实时跟踪 LM Loss 与 Grad Norm 曲线，对异常波动与跑偏曲线进行系统分析与策略调整，必要时执行局部重训，保障训练收敛质量

4. 模型转换与评测验证

开发模型转换脚本，实现Megatron-Torch 格式 → HuggingFace 格式转换，基于转换模型进行 MMLU 评测。

五、大模型全栈流程构建与平台能力沉淀

以 Qwen3 8B / A3B 为基座模型，构建并打通完整大模型工程链路，包括：

1. Megatron 预训练
2. CPT 续训练
3. SFT 精调
4. 模型格式转换
5. vLLM 推理部署
6. OpenCompass 模型评测
7. Verl 强化学习

六、重点业务与生态支撑工作

1. 天玄·千河大模型项目

参与之江实验室与中国航天科技体系及创新研究院合作的“天玄·千河”大模型训练任务，本人负责模型续训练、模型格式转换、全量精调。通过模型适配、分布式并行优化与精度对齐工作，保障项目高质量交付。航天院发来正式感谢信，对工作给予高度认可。

2. 之江实验室材料种子班教学支撑

适配 Qwen3 与 OLMo2 小模型训练流程，构建教学案例：镜像制作、环境适配、数据预处理、分布式训练脚本。同时协助排查多项集群问题（如小于 8 卡规模虚拟环境切割时的固定报错问题），保障教学顺利开展。

3. 制造院视觉与多模态模型支撑

支撑制造院视觉与多模态小模型在 W64 集群上的训练工作。协助解决环境依赖问题，排查模型结构适配问题，解决算法与训练稳定性相关问题，保障多业务方向顺利落地。

4. 阶跃星辰多模态模型训练优化

参与阶跃星辰多模态模型（Qwen3-VL+DiT）训练任务。该项目未使用 Megatron-LM，而是基于原生 PyTorch 自主实现。本人重点负责：

- a). 算法层面有效训练时间优化
- b). 代码缺陷排查与修复
- c). 通过系统分析有效训练时间构成：修复 TP Gloo Group 相关 bug, 修复异步存储 checkpoint 占用同步训练资源问题, 优化千卡规模 checkpoint 存储流程
显著降低 checkpoint 存储时间占比，大幅提升有效训练时间比例，帮助客户节省大量算力成本。

5. 华为超节点生态支撑

面向华为 910-B 与 MindSpeed 生态，完成了公版 Megatron-LM v0.8 / v0.12 下 DeepSeek-V2 16B / 236B 在 16 机 256 卡规模下的适配，并进行性能测试、精度对齐与调优。

七、DeepSeek-V2 / V3 技术调研与核心功能开发

在 2025 年初 DeepSeek-V3 发布后，我第一时间对 DeepSeek 相关论文进行系统研读与技术拆解，输出专项性能分析报告，对各关键优化技术对 MFU 与吞吐的贡献拆分。同时在组内开展专题汇报，对 DeepSeek 的核心算法创新进行系统讲解，尤其围绕：MLA 机制优化和 MTP 训练策略等算法难点，对其原理、计算图结构变化、通信影响及系统侧收益进行深入解析。我还担任 MTP 功能开发与验证负责人，围绕构建之江 MoE 科学基础大模型的核心目标，在英伟达平台 zj-megatron 上完成了 MTP 功能的

代码实现与效果验证。

八、公式识别模型研究。根据公式识别中注意力分布情况，自主设计了HV-Attention和双编码器模型（Contrastive Dual-Encoder Framework），构建了从公式图片到LaTeX文本输出的多模态模型。独立完成了从数据预处理、模型结构与算法、模型训练、推理评测等全部torch代码的编写。

九、大模型参数高效精调。个人负责开发与完善peft框架，构建主流数据集与数据预处理流程，为混合万卡级集群上的大模型精调提供技术支撑，另一方面系统调研精调算法，总结大模型基础知识、精调及强化学习基础研究、多模态大模型及其精调方法等内容。

十、GeoGPT推理优化。在GeoGPT攻关中，负责GeoGPT推理服务的整体构建。同时使用TensorRT LLM对GeoGPT表格识别推理进行加速。

十一、数字反应堆项目算法任务。在数字反应堆项目中，负责材料、制药、育种等多类算法的适配、测试与部署工作。同时参与浙江中烟项目知识库建设及数字反应堆向量数据库的搭建，完成了数字反应堆首次在线推理服务的开发与部署，实现了系统的稳定对外服务。

十二、开展多项探索研究工作，包括低代码生成，后训练模型的扩散量化方法，长文本建模，高效能瓶颈分析，大模型有效训练时间优化与路径搜索等。

十三、技术探索与团队分享。我负责组织院内三个小组的技术分享组会工作，并作为讲师参与了X10000大模型种子班的授课。个人在之江实验室的技术分享内容包括：从机器学习到大模型，视觉神经网络，DeepSeek技术调研，大模型基础知识及评测方法，Diffusion扩散模型。

十四、参与多个项目申请书的撰写工作，包括天地一体大模型、中国烟草知识库模型、国家智能与创新算力牌照。

业绩：

2025年绩效A（最高档），高级研究专员，获得助理研究员职称。具体工作业绩如下：

一、混合万卡集群建设

完成Llama 2 7B/70B、Llama 3 8B/70B、Qwen2.5 7B/72B、Qwen3 8B/14B/A3B、Qwen-Image-Edit-2509、DeepSeek-V2 16B/32B/236B在混合万卡集群的适配，组织并完成 1536卡规模48 小时稳定性压测，通过集群验收及点亮上云。

二、国产显卡大模型分布式训练与性能调优

通过调优显著提升了多款主流大模型在大规模训练场3景下的算力利用率（MFU）：

Llama2 7B（32 卡）：MFU 从 71.32% 提升至 74.89%

Llama2 70B（128 卡）：MFU 从 66.46% 提升至 69.93%

DeepSeek-V2 32B（128 卡）：MFU 从 18.5% 提升至 37.8%

DeepSeek-V2 236B（960 卡）：MFU 从 24.4% 提升至 33.4%

Qwen3 A3B（32K 长序列，512 卡）：MFU 从 10.7% 提升至 18.3%

三、千卡规模 021-MoE-32B 长周期训练

完成了实际4T tokens的训练，有效缓解了Megatron训练过程中内存逐步上涨导致溢出的问题。有效训练时间占比93.7%。在每 1T 数据ckpt上的评测结果显示，MMLU 对比H100基本一致。

四、大模型全栈流程构建

成功构建覆盖训练—对齐—部署—评测—强化学习的完整闭环能力，并沉淀为平台级基础能力。

五、重点业务支撑

多项业务顺利开展，工作成果得到了甲方的充分肯定。

六、南湖Megatron DeepSeek核心功能开发

在英伟达A100 128 卡规模下，个人在南湖Megatron中开发的MTP功能使训练阶段的MFU至接近1.1倍，单层MTP token生成速度1.8倍，与论文所述一致。

七、公式识别模型研究

形成论文，并训练得到模型权重。通过一系列对比与消融实验，验证了方法的有效性（达到小模型SOTA，高于nougat和unimernet）。

八、大模型参数高效精调

形成综述论文和精调框架。

九、GeoGPT推理优化

为文档版面分析、文本提取、表格与公式解析等环节提供了高可靠的Triton推理服务，实现了 GeoGPT 训练数据集的自动化构建。基于TensorRT-LLM 的推理优化，使GPU 利用率提升约 3 倍，整体推理速度相比之前提升约13倍。

十、研究成果。发表论文3篇（三作）。

1) Parameter-Efficient Fine-Tuning in Large Models: A Survey of Methodologies, Artificial Intelligence Review 2025

2) Language Generation in Low-code Platforms Using Large Language Models, ICIC 2025

3) PQD: POST-TRAINING QUANTIZATION FOR EFFICIENT DIFFUSION MODELS, WACVW 2025

项目经历 PROJECT EXPERIENCE

混合万卡联合攻关 | 模型与算法负责人

2025.02-2025.12

内容:

1.项目概况

该项目为英伟达集群+3个国产算力集群的混合万卡大模型训练项目，旨在调动庞大的算力资源研发与训练业界领先的大模型与垂直领域模型。主要分为430攻关，730攻关，930攻关等。

2.人员分工

人员规模200人左右，主要分工为分布式训练，模型与算法，系统与调度，算子开发与优化等

3.我的责任

个人参加了全部的攻关任务，负责南湖Megatron的代码开发，DeepSeek技术调研，MTP开发与验证，一系列业界主流模型(DeepSeek, Qwen, Llama) 的系统性调优、精度比对、ckpt存储优化等，并负责DeepSeek-V2 32B MoE大模型持续3个月在8.1T数据集上的训练任务。此外，我还负责整个W64集群（某国产算力集群）上的所有业务需求模型与算法部分。

业绩:

项目产出了南湖megatron，并训练得到021科学基座大模型。个人全程作为核心成员负责W64这个国产集群上所有模型与算法以及分布式训练的相关工作，通过一系列的实践，使集群与平台具备大模型从预训练到强化学习的全生态链，能够服务不同业务方的多样化需求。

内容:

1. 项目概况

该项目聚焦于3个国产芯片GPU算力集群的建设，涵盖从机器组装，硬件/网络通信调试，生软件栈搭建，主流模型适配与大模型生态构建，旨在建成一个高效能高可靠的国产算力万卡集群。

2. 人员分工

人员规模200人以上。分工涵盖硬件，网络通信，软件栈，模型与算法，分布式训练，系统调度，前端平台搭建，算子与编译等。

3. 我的责任

个人担任W64这个国产集群模型与算法及分布式训练的主要负责人。

业绩:

成功完成之江实验室3个不同国产厂商的混合万卡集群建设。个人全程负责W64集群的模型与算法软件栈相关工作，解决了集群的诸多问题。该集群成功通过主流Llama2/3, Qwen2.5等的适配，性能测试，精度比对，稳定性压测等环节。最后顺利完成2000卡点亮上云，投入正式使用。

教育经历 EDUCATIONAL EXPERIENCE

香港科技大学 硕士 | 计算机科学与技术

2015-2021

2015从清华直博到港科，并获得HKPF（香港政府奖学金），后因毕业论文压力太大转工学硕士毕业。

2018年在数据库领域顶会ICDE (CCF A)发表论文KNOWLEDGE BASE ENHANCEMENT VIA DATA FACTS AND CROWDSOURCING

其他研究

Status confirmation for confident and noisy data

Iterative learning between knowledge source and crowdsourcing workers

清华大学 本科 | 计算机软件

2011-2015

清华大学 2011-2015学分绩 90.6 (6/55)

2013-2014 担任清华大学软件学院12班团支部书记

2014夏 担任清华大学web前端课程助教

2014-2015 担任清华大学软件工程课程助教

获清华大学优秀奖学金（2011-2012，2012-2013，2013-2014）

获清华大学优秀毕业论文（2015）

资格证书 QUALIFICATION

托福91-100分

大学英语六级

助理研究员

志愿者经历 VOLUNTEER EXPERIENCE

1. 该项目旨在连接清华学子与社会弱势群体，深入最基层了解与关爱残障与被遗弃儿童的生活，提升社会责任感。
2. 个人担任项目总负责人，完成了团队人员组织，前期物资准备，行程制定与执行，后期总结与汇报等工作。
3. 在这个项目中，我们团队一行人通过与孩子们的接触，带给他们快乐与温暖，给予他们在这个年龄段所需要的引导。同时，我们深切感受到了社会弱势群体所处的现状，反思自己能为社会做些什么。