

王启鹏

☎ / 📠 (+86)158-1155-3886

✉ 861026685@qq.com



♥ 兴趣方向

深度学习系统，以 LLM 为主

- 边缘智能：端侧 AI
- LLM 基础设施：推理引擎优化

🎓 教育背景

北京大学	博士研究生	计算机软件与理论	2020.9 ~ 2025.6
• 导师：刘让哲			
北京航空航天大学	学士		2016.9 ~ 2020.6
• 软件工程（主修）			2016.9 ~ 2020.6
• 数学（辅修）			2017.9 ~ 2020.6

🏢 工作经历

快手	2025.7 ~ 现在
• LLM 推理优化工程师	2025.7 ~ 现在

🏆 主要项目

LLM 推理优化

- 优化场景：MaaS 平台 LLM 推理优化，主要包括 Deepseek、Qwen 等系列模型
- 优化手段和效果：
 - 通过时分 PD（DP-Attn 各 rank 执行相同类型计算）和在线调度（开启 Chunked-prefill 下 PD 交替执行）等调度手段，优化单机部署场景下的推理性能，在 SLO 约束下提升 Deepseek 和 Qwen 系列多款模型平均 $6.2\times$ QPS 吞吐。
 - 通过冗余专家和启发式搜索，优化静态专家放置策略，解决 EP 场景下专家负载不均衡的问题，提升 Deepseek 系列模型至多 11% QPS 吞吐
 - 通过最短队列优先调度请求，解决 DP-Attn 场景下不同 rank 负载不均衡的问题，提升了 Deepseek 系列模型至多 14% QPS 吞吐
 - 通过 mrope 位置计算前置重构调度策略，实现 CPU-GPU 并行，减少 GPU 空泡，提升 Qwen-Omni 系列至多 20% QPS 吞吐
 - 算子优化：优化了 TopK、FusedMoE、SliceRepeatCat、JVPAtn 等算子，在多个模型推理任务上取得收益

多模型混部

进行中

- 目标：使用有限的机器部署多个模型推理实例，通过模型/请求调度切换实现高效推理
- 关键技术：
 - 推理引擎快速冷启动：利用远程种子进程，本地中空进程通过 RDMA 和 CUDA VMM，实现权重快速拉取和 KVcache 的快速分配。引擎通过 Torch-memory-saver 保留权重、KVcache 和 CUDA Graph 虚拟地址，释放物理显存，切换为中空状态；启动时通过 RDMA 快速拉取远程权重，利用 CUDA VMM 绑定物理显存，实现 5s 内快速启动 470GB 模型推理服务
 - SLO 感知的请求调度：(1) Decode 节点根据 SLO、请求长度、预度量的批次执行时间动态选择解码请求，实现 SLO 感知的请求调度，解决长尾请求导致的 Straggler 问题（同 batch 内短请求等长请求），在满足 TPOT SLO 的前提下相比朴素 Continuous batching 方法至多提高 94.0% 吞吐，在相同 QPS 下至多提高 69.4% TPOT 达标率；(2) Prefill 节点设计了 Chunked-RR 调度算法，解决长尾分布请求导致的队头阻塞问题（先到达的长请求阻塞后续短请求），相比于 FCFS 方法提高至多 10.8% TTFT 达标率；(3) 端到端相同 QPS 下提升至多 55.4% SLO 达标率。（Qwen3.5-397B 验证）
 - 进行中：(1) 虚拟 KVcache 管理与 GPU 共享；(2) 请求缓存与跨实例热迁移

△ 在校经历

《端侧深度学习系统内存优化关键技术研究》

博士论文

- [MobiSys'22] 基于张量图不变性的训练内存优化技术。根据训练周期性设计了不同内存预算下的内存管理优化策略。至多提升了 $6.5\times$ 训练批大小，同等批大小训练下提升了 $1.89\times$ 吞吐。
 - 唯一获得全部代码评估 (Artifact Evaluation) 徽章的论文 ([GitHub](#))
 - 部分经验在工业场景落地：通过预热信息指导后续迭代的显存分配。在 TF@2.7.4 完成实现，在广告推荐业务场景中节约 8.1% 训练显存。
- [TMC'25] 基于免训练查找表的本地应用推理内存优化技术。通过免训练的方式快速生成查找表，根据可用内存搜索最佳查表推理策略，利用特定的硬件指令完成高效推理。至多提高 9.1 倍推理速度，至多减少 80.5% 推理内存占用。
 - 微软实习期间完成，获得「明日之星 Star of Tomorrow」，导师 [姜世琦](#)
- [TOSEM'24] 基于在线量化的 Web 应用推理内存优化技术。构建多尺度量化模型，通过参数共享的方式压缩存储，根据可用内存选择最优量化策略，设计了内置于浏览器的推理引擎以完成高效的模型推理。节约至多 87.5% 模型内存占用，提升至多 $12.82\times$ 模型推理速度，提升至多 $14.61\times$ 算子计算速度。
 - 微软实习期间完成，获得「明日之星 Star of Tomorrow」，导师 [姜世琦](#)

机器学习平台研发

- 深度学习任务部署管理平台 ([Demo](#)):
 - 特色包括：(1) 基于 K8S 自动化训练任务部署 (2) 自动化任务完成时间 (JCT) 评估，实现基于 JCT 的任务调度。
 - 北大校内 HPC 中心部署使用。
- 异构性可行的联邦学习平台 ([GitHub](#))
 - 基于十多万量级用户轨迹数据，开源异构性可行的联邦学习平台，已被清华、MIT、MSRA 等机构使用。
 - 论文发表于 WWW'21

📄 论文

- [MobiSys'2022] **Qipeng Wang**, Mengwei Xu, Chao Jin, Xinran Dong, Jinliang Yuan, Xin Jin, Gang Huang, Yunxin Liu, Xuanzhe Liu. Melon: Breaking the memory wall for resource-efficient on-device machine learning. [CCF-B; CSRanking] [唯一获得全部代码评估 (Artifact Evaluation) 徽章的论文]
- [TOSEM'2024] **Qipeng Wang**, Shiqi Jiang, Zhenpeng Chen, Xu Cao, Yuanchun Li, Aoyu Li, Ying Zhang, Yun Ma, Ting Cao, Xuanzhe Liu. Anatomizing Deep Learning Inference in Web Browsers. [CCF-A]
- [TMC'2025] **Qipeng Wang**, et al. Lookup Table Optimized Efficient On-Device Diffusion Model Inference. [CCF-A]
- [WWW'2021] Chengxu Yang, **Qipeng Wang**, Mengwei Xu, Zhenpeng Chen, Kaigui Bian, Yunxin Liu, Xuanzhe Liu. Characterizing Impacts of Heterogeneity in Federated Learning upon Large-Scale Smartphone Data. [CCF-A; CSRanking]
- [TMC'2022] Chengxu Yang, Mengwei Xu, **Qipeng Wang**, Zhenpeng Chen, Kang Huang, Yun Ma, Kaigui Bian, Gang Huang, Yunxin Liu, Xin Jin, Xuanzhe Liu. FLASH: Heterogeneity-aware Federated Learning at Scale. [CCF-A]
- [EMDL'2021] Dongqi Cai, **Qipeng Wang**, Yuanqiang Liu, Yunxin Liu, Shangguang Wang, Mengwei Xu. Towards Ubiquitous Learning: A First Measurement of On-Device Training Performance. [EMDL@MobiSys]
- [MobiCom'2022] Daliang Xu, Mengwei Xu, **Qipeng Wang**, Shangguang Wang, Yun Ma, Kang Huang, Gang Huang, Xin Jin, Xuanzhe Liu. Mandheling: Mixed-Precision On-Device DNN Training with DSP Offloading. [CCF-A; CSRanking]
- [arXiv:2401.08092] Mengwei Xu, Wangsong Yin, Dongqi Cai, Rongjie Yi, Daliang Xu, **Qipeng Wang**, et al. A Survey of Resource-efficient LLM and Multimodal Foundation Models.
- [MobiSys'2024] Fucheng Jia, Shiqi Jiang, Ting Cao, Wei Cui, Tianrui Xia, Xu Cao, Yuanchun Li, **Qipeng Wang**, et al. Empowering In-Browser Deep Learning Inference on Edge Through Just-In-Time Kernel Optimization.

👨 学生工作

课程助教	北京大学计算概论 A 本科生 120 人	2020, 2021
课程助教 (负责人/leader)	北京大学计算概论 A 本科生 120 人	2022, 2023