

王国腾

(+86) 137-8058-1591 · wangguoteng925@qq.com · 分布式训练系统工程师

个人总结

本人自我驱动力强、热爱尝试新事物，从研究生开始到工作至今，一直在系统与体系结构和高性能计算方向学习和工作。研究生期间专业方向为 RDMA 高性能网络；工作后主要从事大语言模型的分布式训练场景的性能优化。现任职于奇绩智峰，一家以 Agent 为核心的大模型初创：<https://nex-agi.com/>

教育背景

华中科技大学, 计算机技术, 硕士研究生 2020.9 - 2022.6

排名 15/225(前 10%), 服务计算技术与系统教育部重点实验室 (CGCL), 华中科技大学学业奖学金 (2 次), 华中科技大学新生奖学金 (1 次), 知行三等奖学金 (1 次), 优秀学生 (1 次), 华为杯 “第十七届中国研究生数学建模竞赛二等奖 (2020)

东北大学, 计算机科学与技术, 工学学士 2016.9 - 2020.6

排名 23/278(前 10%), 东北大学校级奖学金 (4 次), 数学建模竞赛校级获奖 (2 次), 优秀团员/优秀学生 (3 次), 全国大学数学建模竞赛省二等奖 (2017); 美国大学生数学建模竞赛二等奖 (2018)

工作经历

奇绩智峰, 后训练系统工程师 2024.8-至今

- **训练框架开发**, 基于 Megatron 框架, 定制化支持算法团队的训练需求, 包括基于 Hopper 架构的 FP8 低精度训练; 多模态模型训练; 针对后训练长序列场景的效率优化, 实现诸如 FlexSP/Zero-Bubble Pipeline 等; 使用 triton 进行融合算子优化。在千卡规模集群稳定支持团队训练 Nex 系列模型。(24 年 8 月至今)
- **FP8 混合精度训练支持**, 基于 triton 算子和 DeepGEMM/DeepEP, 在内部版本 Megatron 框架实现了 MoE 模型原生 FP8 训练。包括 FP8 AlltoAll 通信, Blockwise ZeRO 优化器, 以及低精度 AdamW 优化器和量化融合算子等功能或优化。端到端跑通 DeepSeek 模型原生 FP8 混合精度训练, 资源需求相比 BF16 减少一半/训练速度提高约 10%, 且精度和 BF16 训练高度对齐, 已应用到 Nex-N1 模型训练。(25 年 5 月-11 月)
- **强化学习框架开发**, 基于 verl 接入内部训练框架支持 DeepSeek 等模型的强化学习训练, 负责开发了训推分离的 RL 训练框架支持 off-policy 训练; 实现基于 RDMA 的高性能权重同步机制; 支持原生 FP8 精度 RL 训练; 实现基于 LoRA 的 RL 训练等功能; 并参与探索基于投机采样算法的 RL 长尾推理加速工作, 实现端到端 RL 训练 1.5x-1.8x 的加速。(25 年 1 月至今)
- **专家即服务 (EaaS) 的推理系统**, 基于 SGLang 开发 AF 分离架构的 MoE 模型推理系统, 负责基于 IBGDA 的 P2P 通信算子开发, 实现无需建组的 EP-AlltoAll 通信, 支持实现细粒度弹性扩缩容与负载均衡策略。在大规模 MoE 推理中将故障吞吐损失控制在 2% 以内并节省最高 37.5% 计算资源。(25 年 3 月-9 月)
- **团队日常 Infra 需求支持**, 完整参与 Nex 系列模型的训练。支持算法团队对于训练/推理 Infra 的大部分需求, 包括日常任务的性能瓶颈分析, 故障排查和功能开发。以及训练/推理中台的搭建和维护, 包括大模型推理服务转发系统, 基于 NewAPI 的推理渠道管理系统, 基于 Kubeflow 的训练工作流等组件。(24 年 8 月至今)

上海人工智能实验室 | 商汤科技, 分布式训练系统工程师 2022.7-2024.8

- **LLM 大模型训练支持**, 完整参与 InternLM 系列模型的训练。解决预训练/微调/评测等算法团队对于训练系统方面的需求/问题, 包括日常任务的性能瓶颈分析, 故障排查和功能开发。在大模型训练效率的扩展性, 长序列训练支持以及训练负载与故障分析方向参与产出四篇学术论文。(23 年 1 月至今)
- **分布式训练框架 InternEvo 核心开发**, 开发功能包括分布式优化器 AMSP, 3D 混合并行, 异步容错的检查点存取, 自动重启机制, 自动化故障排查, Packed/Streaming/KV 数据集开发, 最佳并行策略求解器, 超长序列训练支持以及国产芯片的适配和兼容。在 3000 卡的 GPU 集群稳定支撑了实验室 7B/20B/100B 模型的训练。(23 年 1 月至今)
- **1M 长序列训练支持**, 支持 InternLM2 的超长序列训练, 集成 Megatron-SP/DeepSpeed-Ulysses/Ring Attention 等序列并行方式。工作亮点为 2D 序列并行方案设计, Ring Attention 负载均衡以及 All2All 通信和 P2P 带宽通信效率优化, 目前 7B 模型 1M 序列长度 MFU 可达到 76%。(24 年 3 月-至今)
- **华为昇腾 LLM 训练支持**, 尝试基于 DeepLink/TorchNPU/MindSpore 框架适配 InternLM 训练, 适配后三种方案均可对齐 GPU 和 NPU 上的训练精度; 在适配关键融合算子后, 910B 的 A+X 机型上

InternLM2-100B 模型训练性能可以达到 A800 性能的 80%-90%。同时参与设计了异构芯片混训的方案设计，负责混训算力建模，负载均衡设计及最优化求解。(23 年 11 月-24 年 4 月)

- 强化学习通信优化, 针对开源 RL 框架 DI-Engine, 引入支持异构数据的 TensorPipe RPC 通信库实现高性能通信, 并在 K8S 生产环境部署 IB/GPUDirect-RDMA 环境。优化后 DI-engine 在 RL 负载 Atari 下相较基于 TCP 通信库的实现加速 4.83x。(22 年 7 月-22 年 12 月)

在校经历

新型内存和存储技术 (No. 2017YFB1001603), 国家重点研发计划课题 2020.10-2022.3

在实验室期间负责基于 Reactor 模式的 RDMA 的异构内存池开发, 通过对 RDMA 底层通信过程和内存池管理接口的封装, 可以达到微秒级别的传输延迟, 并进一步利用内存池开发了异构内存文件系统和链式 RDMA 智能网卡复制中间件。

实习经历

阿里云计算有限公司 | Alibaba Cloud, 数据库内核开发工程师 2021.5-2021.10

科研成果

- *Expert-as-a-Service: Towards Efficient, Scalable, and Robust Large-scale MoE Serving.* (2025). Ziming Liu and Boyu Tian and **Guoteng Wang** and Jiang., Sun., Han., Tang., Hu., Jia., Zhang., Liu., Zhang., Zhang., Chen., Cheng., Gao., You., Feng..
- *ReSpec: Towards Optimizing Speculative Decoding in Reinforcement Learning Systems.* (2025). Qiaoling Chen and Zijun Liu and Peng Sun and Shenggui Li and **Guoteng Wang** and Liu. and Wen. and Feng. and Zhang..
- *Nex-NI: Agentic Models Trained via a Unified Ecosystem for Large-Scale Environment Construction.* (2025). Nex-AGI Team.
- *Characterization of Large Language Model Development in the Datacenter.* (2024). Qinghao Hu, Zhisheng YE, Zerui Wang, **Guoteng Wang**, Zhang., Chen., Sun., Lin., Wang., Luo., Luo., Wen., Zhang.. NSDI '24 Fall.
- *AMSP: Super-Scaling LLM Training via Advanced Model States Partitioning.* (2024). Qiaoling Chen, Qinghao Hu, **Guoteng Wang**, Xiong., Huang., Chen., Gao., Yan., Wen., Zhang., Sun.. IWQoS 2024.
- *LoongTrain: Efficient Training of Long-Sequence LLMs with Head-Context Parallelism.* (2024). Diandian Gu, Peng Sun, Qinghao Hu, Ting Huang, Xun Chen, Yingtong Xiong, **Guoteng Wang**, Qiaoling Chen, Shangchun Zhao, Jiarui Fang, Yonggang Wen, Tianwei Zhang, Xin Jin, Xuanzhe Liu.
- *InternEvo: Efficient Long-sequence Large Language Model Training via Hybrid Parallelism and Redundant Sharding.* (2024). Qiaoling Chen, Diandian Gu, **Guoteng Wang**, Chen., Xiong., Huang., Hu., Jin., Wen., Zhang., Sun..
- *InternLM2 Technical Report.* (2024). InternLM Development Team.

开源经历

我的 Github 主页: <https://github.com/SolenoidWGT>

我的知乎主页: <https://zhihu.com/people/wang-guo-teng-9>

参与贡献的开源项目有:

- 训练框架 InternEvo(Core Developer), <https://github.com/InternLM/InternEvo>
- 推理框架 llama.cpp (InternLM2 Support), <https://github.com/ggerganov/llama.cpp>
- 强化学习框架 DI-engine(RDMA P2P), <https://github.com/opendilab/DI-engine>
- 通信库 TensorPipe(Bug Fix), <https://github.com/pytorch/tensorpipe>
- 算子库 DeepGEMM(Bug Fix), <https://github.com/deepseek-ai/DeepGEMM/pull/226>