

田科琅

手机: 130-0618-0227 | 邮箱: kelang.tkl@infotech.ai | 性别: 男 | 出生年份: 1995

AI 基础工程 - 大模型推理方向专家

4年+ AI推理系统研发经验，专注于LLM推理系统架构设计、引擎优化与工程落地。**核心能力**：分布式推理平台从0到1架构设计、推理引擎（vLLM/SGLang）深度定制与性能优化、Serverless推理系统、在线量化。

教育背景

中国科学技术大学 硕士·软件工程（2018.09-2021.07）| 华中科技大学 本科·工程管理（2013.09-2017.07）

工作经历

无限光年（INF）| 2023.10-至今 | 大模型推理工程专家·基础工程团队

无限光年是一家专注于大模型领域的创业公司（to B业务），提供金融/医疗行业解决方案及 AI 平台（启智 AIStudio）

- 负责推理引擎（vLLM/SGLang）的维护与优化，设计并实现Serverless大模型推理平台
- 推理性能调优与显存优化方案落地，实现72B模型10秒内冷启动，显著提升GPU利用率
- 关键词**：vLLM-SGLang-Kubernetes-RDMA-Serverless-在线量化

蚂蚁金服 | 2021.08-2023.10 | AI基础工程师·计算智能部

支付宝母公司，参与 Maya 推理平台研发，负责自研推理引擎 Noao 的开发与优化

- 参与自研推理引擎Noao的架构设计与开发，统一多框架模型推理，支持80%平台模型需求
- 实现早期LLM推理优化（Continuous Batching等），针对重点业务模型进行定制化性能调优
- 关键词**：ONNXRuntime-ONNX-PyTorch-TensorFlow

项目经验

Serverless大模型推理平台 | 无限光年

解决显卡资源紧张场景下的模型部署难题，用有限资源支持无限推理服务，应对稀疏请求场景下的资源利用率问题

- 社区分享**：vLLM meetup public 分享
- 云原生架构**：基于Kubernetes构建自动扩缩容体系，设计智能模型驱逐与Swap机制，实现存储位置感知的调度算法
- 多层存储优化**：构建四层缓存体系（显存→内存→本地磁盘→分布式存储），实现10秒内冷启动72B模型，支持RDMA高速传输
- 引擎定制**：深度改造vLLM/SGLang，支持显存动态Offload，解耦为独立三方库，兼容多推理后端
- 在线量化**：开发vLLM在线量化功能，实现高精度INT8 CUDA算子，省去离线量化环节，简化部署流程
- 项目成果**：72B模型冷启动<10秒，显著提升GPU利用率，降低运营成本

Maya推理平台-Noao引擎 | 蚂蚁金服

蚂蚁 AI 应用场景多样化，模型种类繁多，统一推理引擎覆盖80%模型推理需求，降低维护成本

- 将PyTorch/TensorFlow模型统一转换为ONNX表示，基于ONNX实现跨框架图优化，提升推理性能
- 基于ONNXRuntime实现深度定制优化，实现早期LLM推理优化（Continuous Batching等）
- 项目成果**：Noao承接Maya平台50%模型推理需求，为后续LLM推理优化奠定技术基础

核心竞争力

系统架构能力：从0到1构建生产级分布式推理平台的完整经验，深刻理解Serverless架构、云原生技术栈（Kubernetes），擅长多层存储优化、智能调度算法设计

底层优化能力：深度熟悉主流推理引擎内核（vLLM/SGLang/ONNXRuntime），能进行底层性能调优，掌握在线量化、显存优化等前沿技术

工程实践能力：解决真实业务痛点（资源紧张、冷启动慢等），注重代码模块化设计与工程价值，具备大厂（蚂蚁金服）与创业公司（无限光年）双重视角

技术栈总结：推理引擎 vLLM-SGLang-ONNXRuntime | 云原生 Kubernetes-Docker-Serverless | 优化方向 模型量化·显存优化