

芊海

电话：18811550730 | 邮箱：2323748178@qq.com



教育经历

北京邮电大学	2021年09月 - 2024年06月
计算机科学与技术 硕士 计算机学院	
北京邮电大学	2017年09月 - 2021年06月
计算机科学与技术 本科 计算机学院	

工作经历

上海寻梦信息技术有限公司	2024年07月 - 至今
后端开发 跨境搜索推荐	上海
本人在搜索推荐-GPU训练平台组工作，小组职责是给搜推业务算法提供训练框架与训练服务。本人先后负责了算子性能分析与优化、根据算法需求对新模型架构的调研支持、分布式训练框架开发、训练平台模型上线系统设计与开发等工作。	

项目经历

算子性能分析与优化	2024年07月 - 2024年12月
- rms算子优化，实现了基于triton的算子融合的rms，相较于pytorch非原生rms，fwd有30%提升，bwd持平。后续pytorch支持了原生rms，nsys分析发现pytorch的rms能在torch.compile的情况下，带来整体更好的性能。 - sparse算子优化，搜推业务中会对商品id或用户行为等单机无法容纳的数据嵌入进行排序池化等，通过ncu分析，对不同类型算子分别使用了算子融合，向量化访存、nvshmem优化，部分算子时间节省达50%。	
大模型训练框架开发	2025年01月 - 2025年08月
- 模型加载优化，通过meta device，缩短模型加载与初始化时间。 - 分布式模型ckpt，通过元信息支持各机器各自save/load，async copy+pinned memory优化。6.5Bpp2tp2模型save时间减少到原来的20%，每batch都保存ckpt测试情况下，mfu有4%的提升。 - pipeline parallel适配到框架中，并对dataloader进行封装适配pp。 - 框架与megatron计算结果对齐，对齐模型输入、结构、optimizer，MMLU较基准从对齐前-0.008提升到+0.003、Hellaswag值较基准从-0.008到+0.008。	
训练平台模型上线系统	2025年09月 - 至今
- 训练平台hdfs数据读写慢原因排查，与infra沟通多副本支持，内部划分不同组的数据分区，数据读写耗时平均减少50%+。 - 模型离在线对分工具开发，与算法沟通判断逻辑，支持上报和自动检测；tensorboard服务部署，wandb服务扩容；在不影响性能情况下，框架中插入diff功能，有diff时可自动检查输入、fwd、grad是否存在异常，辅助自动化对分，减少oncall问题。 - 训练平台成本控制，设计调度分数和利用率监控，过低的任务降低优先级&自动挂起机制，提供耗时统计给框架侧进行优化。	

证书/技能

- 技能：C++/Python/Go开发、Linux基本命令、MySQL与ORM框架
- 证书：CET-6

荣誉奖项

研究生曾获校级一等奖学金

个人总结

本人学习过计算机基础知识课程，积极在项目和工作中进行巩固与实践，能根据工作需要快速学习模型训练框架与性能分析等内容，锻炼了发现问题和解决问题的能力，培养了良好的合作和沟通能力。