

刘超杰

15601239633 | liuchaojie@bupt.cn | 北京

教育经历

北京邮电大学	2015年09月 - 2019年06月
通信工程 本科 信息与通信工程学院	北京
北京邮电大学	2019年09月 - 2022年06月
信息与通信工程 硕士 模式识别实验室	北京

工作经历

阿里巴巴（北京）软件服务有限公司	2022年06月 - 至今
研发工程师 千问C端事业群	北京
- 支持文本/多模态预训练大模型语料的日常生产，迭代相关处理链路，优化算力性能，提高语料质量并减少资源消耗 - 参与数据平台的开发，提供对数据与任务的管控能力	

项目经历

海量文本去重	2023年03月 - 至今
在大模型预训练中，进行文本相似度层面的语料去重，在提升训练效率的同时，也能优化数据分布，提高模型的泛化能力	
- 将Minhash+LSH作为去重的基础算法，分别借助索引检索、Spark、Hive+Graph、纯Hive等方式实现了不同版本的去重系统 - 用Hive实现了large-small-star算法，通过连通分量的不断合并来提高去重的召回能力；并对超大分量内部的笛卡尔积相似度计算、数据倾斜、字段溢出等性能问题进行优化，使得系统可支撑百亿级文本的去重 - 对系统进行通用化模块改造和中间结果缓存，将整体环节拆解为不同阶段并固定相应的数据协议，可接入多种特征计算、相似度衡量、保留优先级等策略，降低后续的开发成本以及运行成本 - 开发片段（段落）去重链路并验证其在模型侧的收益，同时参与去重评测标准的制定，最终在全文和片段去重的准召上都达到了单侧85%+80%的效果	

分布式预训练样本生成	2023年03月 - 至今
能够稳定的将原始语料转换为训练样本，全自动的实现分词、shuffle、packing、上传等阶段，降低人工干预并加速生成过程	
- 梳理整体链路，将算法侧提供的耦合单机逻辑拆解为多个原子阶段，便于分布式改造 - 以工厂模式来封装分词器，利用docker配置通用的分词依赖环境，最终通过Hive UDF来调用；同时将packing时大量for循环内逻辑分裂为MapReduce任务，通过多实例并行与后接单实例串行来处理前后数据的依赖关系 - 不断迭代新的分词器和样本格式，支持首尾相连和Longest-pack-first histogram-packing（LPFHP）的packing策略 - 减少异构数据IO与网络传输次数，在关键节点增加校验机制，减少failover的概率与运行时间，保障数据的正常交付与链路运维	

内容平台数据管理	2024年11月 - 2025年01月
保证每一次数据生产与应用任务都可追溯，将数据版本的流转记录在平台上，并提供基础的表结构操作	
- 梳理数据应用的业务逻辑，构建通过Hive分区来表征数据集、批次、版本的管理体系 - 基于calcite进行开发，抽象出统一的DDL来操作不同物理表的表结构，并提供记录、回溯、刷新等能力	

视频语料生产链路	2025年10月 - 至今
从零搭建视频pretrain语料的生产链路，流程化执行各处理节点，保障纯CPU任务不再成为交付卡点	
- 基于内部平台提供的Flink基础镜像，同平台侧合作建设自定义镜像运行flink的能力 - 开发场景切分、抽帧、音频抽取等算子，并在资源受限的情况下优化CPU上ASR的性能卡点 - 提供增量合成captain的解决方案，在平台能力不足的情况下保证处理性能和最终效果	

专业技能

- 熟悉Hive、Spark等大数据生态以及性能调优
- 熟悉大模型预训练的数据流转链路以及相关数据策略
- 熟悉Python、C++等编程语言与Linux系统的使用