

张瑜

AI数据研发工程师 | 181-9419-9868 | 18817318768@163.com



工作经历

阿里控股集团 数据技术及产品部 - 采集&流量数据 数据研发工程师 2023.07 - 至今

- 多模态数据生产与交付：**参与算法侧多模态数据生产任务建设，负责部分任务的优化与交付支持，围绕音频、视频、模型日志和用户交互数据，提升训练/蒸馏/评测数据链路的吞吐、稳定性与可观测性。
- AI 智能化应用落地：**参与流量域 AI 智能化应用建设，负责流量知识库构建、统一指标口径体系设计与 RAG 检索链路适配，推动数据分析场景智能化升级。
- 数据公共层：**负责直播/内容/流量及海外流量公共层治理与需求交付，主导跨境合规与多业务接入。构建流量反作弊过滤体系，负责 PB 级存储生命周期治理与成本优化，支撑流量链路安全治理与数据资产精细化运营。

项目经历

面向算法训练的多模态数据生产任务优化与工程适配 2025.10 - 至今

项目背景：面向音频、视频等多模态训练、蒸馏和评测数据生产需求，原有任务链路在多卡型适配、资源利用率、吞吐效率和可观测性方面存在瓶颈。

项目成果：支撑日均 700 万小时音频 + 50 亿视频标注数据稳定交付；308 卡 MMS 模型性能提升 2.55 倍，N 卡并行优化后 GPU 利用率由 35% 优化至 69%；显著提升多模态数据生产任务的吞吐、稳定性与可观测性。

- 音频链路性能优化：**优化音频 ASR 生产任务，针对音频推理全链路构建可观测体系，定位并解决核心瓶颈。
- 异构资源适配与分布式架构重构：**面向 308/PPU/N 卡等多卡型完成任务适配与性能优化。优化视频快慢检测任务，迁移至 Ray 并通过两阶段 map_batches 解耦 CPU 预处理与 GPU 推理。
- 视频质量评估与自动标注体系：**构建图片质量分、美学分、方向识别、动态性评估、AI 音频检测、图片异常检测等多维算子，完成视频拆条和自动标注，辅助算法团队进行训练样本预筛选。
- 数据回流支持：**采集 OpenCode、IDEATalk 等平台的模型输出与用户交互数据，支持算法团队进行蒸馏、问题排查和效果迭代。

流量分析 Agent 系统构建 2025.01 - 2025.09

项目背景：流量数据产品长期基于传统数仓分层提供分析能力，限制了灵活下钻与复杂组合分析能力。

项目成果：支持 88 个浏览/转化/引导指标分析，支持召回 23 个维度进行下钻分析、13 个用户标签及正确值识别，覆累计发起提问任务 2700+ 次，整体任务完成率 75%。

- 多维知识库构建：**整合埋点元数据、流量公共层、流量指标体系等多个知识源，建设覆盖指标、维度、人群、应用、页面、业务等核心领域的流量知识库，针对核心业务场景深度梳理订正。
- 统一指标口径体系设计：**提出指标口径知识库方案，完成流量相关指标全链路口径梳理并覆盖多端场景，构建统一指标视图；固定指标查询路由至 ADS 聚合层，设计动态路由策略。
- RAG 检索链路构建与优化：**调研并实现基于 OpenSearch 的多维检索链路；调研 smolagents 框架完成原型验证，搭建"意图识别→知识检索→代码生成"核心链路；配合后端团队完成 LangGraph 框架迁移。

直播公共层核心链路治理与实时离线一致性保障 2024.02 - 至今

项目背景：直播公共层承载交易、流量、商业化、归因等核心链路，需长期保障实时/离线及主备数据一致性，并持续支持直播业务高频迭代与大促稳定性。

项目成果：实时离线差异率由 5.22% 下降至 0.36%，成交链路差异率稳定在 0.1% 以内，流批公共层部分归因链路差异率压降至 0.2% 以内，核心品类链路差异率稳定在 <0.05%；主备差异率长期稳定在 <0.001%。

- 一致性治理：**持续迭代直播公共层模型，围绕成交、IPV、商业化、核心品类等链路进行实时离线及主备一致性治理；通过订单补偿、字段补全、口径统一和链路排查等手段保障数据一致性。
- 业务迭代支持：**持续支撑直播公共层高频需求开发，覆盖交易、流量、互动、商业化和归因等场景。
- 稳定性保障：**负责直播&内容实时公共层日常及大促稳定性保障，构建源头蓄洪与施压体系，大促期间高效响应内容与直播紧急问题，保障流量与交易链路稳定运行。

专业技能

- AI 工程：**Ray、GPU 推理调优、LangGraph、RAG、OpenSearch
- 数据工程：**Python、SQL、Flink、MaxCompute

教育背景

武汉大学 - 管理科学与工程 - 硕士 2020.09 - 2023.07
同济大学 - 信息管理与信息系统 - 本科 2016.09 - 2020.07