

曾孟麒

ZENG MENG QI

联系电话: 18169335476

邮箱: zmengqi@126.com

工作年限: 两年七个月

求职意向: 大模型数据工程/AI 数据平台



教育背景

2020.09 - 2023.06	上海科技大学	双一流/中科院	物理学(系统控制与数据处理方向) 硕士
2015.09 - 2019.06	华中科技大学	双一流/985	化学工程与工艺(辅修金融学) 本科

专业技能

- 熟练使用 **Python**、**C++** 语言, 了解 **C**、**Go** 等编程语言, 熟悉基本的数据结构、常用算法和设计模式等
- 熟悉 **Spark**、**Ray** 分布式计算框架和 **HDFS / YARN / Hive / MapReduce** 等大数据核心组件
- 熟悉计算机网络、操作系统等基础知识, 熟悉 **Linux** 系统常用命令及工具, 了解 **Docker** 的容器化部署
- 掌握基本的深度学习和**大模型基础**知识, 了解 **Pytorch** 框架下的开发, 有**模型微调**经验
- 了解 **MySQL** 和 **Doris** 数据库, 熟悉 **Iceberg** 和**数据湖仓**构建, 了解缓存数据库 **Redis** 相关知识

工作经历

百度	大模型算法部	大模型数据研发	2023.07 - Now
工作职责: 负责 文心一言 预训练数据湖仓基座和生产加工平台的构建, 包括数据处理和提质全链路开发设计, 支持千亿级 token 清洗; 负责 自动驾驶端到端大模型 数据 Pipeline, 包括数据策略、自动化标签工具和可视化质检系统的开发和构建。			
理想汽车	算力单元	软件开发实习生	2022.07 - 2022.09
工作职责: 负责在研 NPU 架构下算子优化, 调研图算融合优化框架, 分析 算子拆分/融合 过程, 参与 CModel 相关模块的搭建。			

项目经历

2024 年 7 月 - 至今 **文心一言大模型预训练数据湖仓基座和生产加工链路**

项目介绍: 为文心一言千亿级多模态训练数据构建高效数据处理 Pipeline, 构建数据处理平台, 集成湖仓一体架构, 实现文本/图像/音视频数据的统一存储、自动化清洗、算子标注、质检筛选和交付, 支撑模型快速迭代。

主要工作:

- (1) 负责大模型训练数据生产加工 Pipeline 全链路建设, 包括**数据入仓**、**数据解析**、**算子打标**、**抽样质检**和**规则过滤**等阶段的分布式计算任务的设计和开发, 提升数据处理的效率和质量, 保证交付的数据高质量;
- (2) 负责质量分析打标算子的开发和工程化, 如文本分析类算子: **文本审核**、**PPL**、**文本低质**、**Benchmark 去污**、**竞品人设**等算子的工程化; 多模态分析算子: **图片审核**、**视频基础特征**等算子的工程化; 去重类算子: 基于 **MD5** 的精准去重算子、基于 **Top3** 子句的签名去重和 **MinHash** 模糊去重算子的设计开发;
- (3) 负责多模态数据处理的算子开发, 从而支持多模态数据的数据合成。如: **音视频切分**、**视频转音频**、**视频抽帧**、**音视频 ASR 文本**算子的开发集成;
- (4) 负责大规模数据计算架构的优化: 通过数据分块和类流失分页策略实现大语料集计算任务的流水线并行、设计算子打标框架, 通过抽象接口和分表策略实现算子纳管; 抽象解耦湖仓库表 Schema 模块, 建立全链路 Schema 标准协同体系; 基于 **Ray** 框架适配文档解析等 GPU 算子等;
- (5) 探索**新一代预训练数据存储组织**方式, 设计合理的 meta 索引信息, 提供高效方便的标签数据检索能力, 灵活支持数据训练策略和数据算法策略。

技术栈: Spark、HDFS、BOS、Doris、Ray、Iceberg、MySQL、Python、PaddlePaddle、PyTorch、MapReduce 等

成果：构建的预训练数据湖仓和生产加工平台已经支持了千亿级 token 多模态预训练数据的清洗和加工合成以及数据资产存储，作为文心一言重要基建支撑了 EB4.5 和 EB5 的迭代训练。项目获得 NLP 2024 Q4 部门奖-巧夺天工奖、2025 年度小赞项目奖。

2023 年 7 月 – 2024 年 6 月 AD2.0 自动驾驶端到端大模型数据飞轮体系

项目介绍：针对端到端自动驾驶大模型，驱动模型性能提升的核心在于构建多源、高质的海量驾驶数据体系。本项目搭建了数据 Pipeline，涵盖数据挖掘筛选、场景标签体系构建、数据质检及可视化模块，并通过闭环仿真与实车测试持续优化数据配比策略与筛选机制，形成自我迭代的数据驱动闭环。

主要工作：

- （1）开发基于**聚类**的数据挖掘算法优化车端数据落盘策略，参与构建数据初筛和精筛流水线，实现 **Protobuf** 流式数据到结构化数据再到模型友好的数据集的自动化生成；
- （2）负责**多维度正交场景分类标签体系**的设计、开发和迭代，基于 MR 实现标签流水线，基于此标签体系以 KLD 为指标构建数据采样和均衡模块，进行**数据降维和场景均衡**；
- （3）基于接管数据的场景标签使用 **Llama2** 推理得到润色的自然语言文本作为 Prompt 进行自驾模型 FT；构造图文场景数据集 LoRA FT **Qwen-VL**，用于推理输出自然语言文本作为 Prompt 进行自驾模型 FT；
- （4）构建**数据质检**模块，基于 MR 针对感知模块得到的 PKL 数据和 RL 生成的 TFRecord数据进行自动化质检。设计开发**数据可视化**模块，服务于数据检查和评估；
- （5）基于 Badcase 和长尾场景生成 Embedding 进行**余弦相似度搜索**的方案，实现场景搜索召回；基于 **Dagger** 算法实现数据增强，从而构建专项数据集。

技术栈：Python、C++、PyTorch、MapReduce、Hadoop、Doris、常用深度学习算法等

成果：构建数据挖掘-标签-筛选的闭环飞轮体系，实现多源数据自动标注与智能筛选，驱动模型持续迭代；通过均衡算法将预训练数据从 11E 帧压缩至 1E 帧，在保持多样性的同时完成数据蒸馏；结合质检可视化模块形成质量监控飞轮，最终产出专项 FT 数据集，极大提升了模型在交互场景的表现。

2021 年 9 月 – 2023 年 6 月 基于 EPICS 的 SHINE 束线站定时系统管理软件设计与开发

项目介绍：基于实验物理与工业控制系统和 TCP/IP 协议，完成来自 FPGA 处理后的束团编码数据和来自探测器的图像数据的匹配、存储以及监测。

主要工作：

- （1）基于 **SNMP 协议**开发了相应的 IOC 软件，实现定时设备参数的远程采集与指令下发（兼容 Modbus/TCP 协议），通过 **PyQt** 开发的上位机 OPI 界面进行设备状态的实时监测和控制；
- （2）基于 **Tomcat** 容器部署分布式 **ETL** 服务，实现 JSON 数据的 **Protobuf 序列化**压缩，结合 **MySQL** 实现数据持久化存储；
- （3）通过 **ResNet** 对通过 GCN 和 LCN 预处理过的 X 射线衍射图片进行分类，并通过**迁移学习**得到了较高准确率的衍射图片分类模型。

技术栈：Python、PyQt、C++、PyTorch、SNMP、MySQL 等

项目成果：已发表论文：曾孟麒,尹亮,尹聪聪,等.基于 EPICS 的 SHINE 束线站定时设备控制系统[J].核技术,2023,46(07):25-33.。

获奖情况

- 华中科技大学优秀毕业生
- 上海科技大学学业奖学金
- 百度 2025Q1 百度小赞
- 英语等级证书 CET-4, CET-6
- 计算机等级考试二级(C++)、三级(网络技术)证书
- 百度 2025Q4 百度小赞