

朱彤彤

年龄：28
工作年限：7
电话：13311529610
邮箱：zhutongcloud@163.com

求职意向

求职类型：社招 岗位： 容器研发工程师、AI 平台工程师

工作经历

2023.11-至今 中国电信 容器研发工程师

- 任职于大数据研发中心，专注于 AI 平台与算力基础设施建设，负责大规模集群架构设计与性能优化
- **AI 平台架构设计:** 参与集团万卡级 AI 集群及多省 AI 平台建设，主导训推平台 TAP 架构设计与后端接口开发，基于 Envoy 开发 AI 推理网关，实现多策略负载调度与性能优化
 - **资源虚拟化调度:** 主导 H100 集群 InfiniBand SR-IOV 虚拟化方案落地，实现网络资源池化与多租户隔离，基于 Volcano 实现算力与网络资源统一申请与调度
 - **平台稳定性提升:** 开发 AI 平台运维诊断工具 Tapadm，覆盖 20+高频故障场景，提升一线问题处理效率 30%，减少研发运维投入 10%
 - **技术社区贡献:** Volcano 社区贡献者，获得"华彩杯"北区一等奖，负责多省 AIPAAS 平台稳定性保障与问题治理

2019.11-2023.10 赞同科技 容器云研发工程师

- 专注于容器平台后端开发与运维优化，负责容器平台开发、Kubernetes 生态组件定制化开发与平台稳定性保障
- **平台开发:** 负责容器平台后端接口与 Operator 开发(Go)，基于业务需求对 kubeadm、Flannel 等组件进行定制化开发与优化
 - **自动化部署:** 编写 Ansible 自动化部署脚本，提升平台交付效率 40%，显著缩短部署时间
 - **架构设计:** 参与新项目架构设计与落地实施，负责技术方案评审与实现
 - **生产运维:** 负责生产环境巡检、故障定位与稳定性优化，保障平台 99.95%的可用性

2019.5-2019.10 敏特昭阳 系统工程师

- **系统优化:** 参与系统架构优化项目，通过性能调优提升系统处理能力
- **环境部署:** 负责生产环境部署与配置管理，确保系统稳定运行
- **故障处理:** 参与系统故障排查与修复，积累系统运维实践经验

项目经历

2025.7-2026.2

爱音乐推理平台提效

项目背景

- 参与 AI 推理平台 TAP/智教管家 的整体设计与核心能力开发，完成系统调研、架构设计及后端 RESTful 接口实现。

主要工作：

- 设计并实现 AI 推理平台核心功能，完成服务管理、发布流程与接口开发；
- 针对原有基于 Kubernetes Service 的负载不均问题，设计并开发基于 Envoy 的自研推理网关；
- 实现多种自定义负载策略：PD 分离、最小连接（Least-Connection）、基于 GPU 利用率的动态负载调度
- 主导大模型镜像分发优化：解决历史架构中模型权重随镜像打包导致单镜像体积 60GB+ 的问题，在百副本规模发布场景下，将更新时间从小时级缩短至分钟级

项目成果：

- 大模型服务发布效率提升 10 倍以上；推理流量分布更加均衡，GPU 利用率显著提升；构建可扩展的 AI 网关架构，支持后续负载策略扩展与性能优化

2024.3-2024.12

万卡级 NPU 训练集群建设

项目背景

- 负责公司大规模训练基础设施从 0 到 1 的建设与稳定性治理，需要构建可支持分布式训练的高性能计算集群

核心贡献

- 高可用架构设计:** 设计并实现训练集群整体高可用架构，包括控制面容灾与服务冗余、任务调度稳定性优化、异常自动恢复机制
- 性能优化:** 主导镜像分发加速方案落地，将训练启动等待时间从 1 小时缩短至 10 分钟，大幅提升资源利用率
- 环境适配:** 完成训练脚本与运行环境适配，保障多类型模型稳定运行，支持 6000+训练任务
- 可观测性建设:** 参与开发断点续训组件，实现 vcjob 训练任务异常自动节点隔离及拉起，建立完善的监控告警体系对接企微

项目成果

- 成功落地并稳定运行 1500+NPU 节点的分布式训练集群，任务异常恢复时间缩短至分钟级
- 显著提升训练资源利用率与系统可用性，支撑大规模模型训练任务稳定运行

2024.8-2024.10

H100 集群 IB 虚拟化项目

项目背景

- 解决大规模 GPU 集群高性能网络资源虚拟化问题，满足多租户场景下网络隔离与资源池化需求

核心贡献

- 虚拟化方案设计:** 主导 500+节点 InfiniBand SR-IOV 虚拟化方案设计与实施，实现 RDMA 网络资源池化
- 调度系统集成:** 打通调度链路，基于 Volcano 实现 GPU 算力与网卡资源的联合申请与统一调度
- 自动化部署:** 完成网络配置自动化与资源分配策略设计，提升集群资源利用率与运维效率
- 性能验证:** 通过 NCCL 测试及实际训练任务进行性能验证与稳定性评估，确保方案可靠性

项目成果

- 实现高性能网络资源可调度与可隔离，RDMA 通信性能接近裸机水平，基本无性能损耗
- 建立可规模化复制的 IB 虚拟化落地方案，显著提升网络资源利用率与集群整体资源调度能力

 教育经历

2014.9-2018.6

兰州大学(985、211)

微电子科学与工程 | 本科

相关技能

- **容器与云原生:** Kubernetes、Docker、Envoy、Operator 开发
- **编程语言:** Go、Shell
- **基础设施:** AI 平台架构、分布式系统、高性能计算、网络虚拟化
- **调度系统:** Volcano
- **运维工具:** Ansible、Prometheus、Grafana
- **网络技术:** Rdma、flannel、calico、SR-IOV、网络性能优化

自我评价

AI 基础设施与平台工程师，7 年云计算与分布式系统研发经验。专注于大规模训练与推理平台架构设计，具备万卡级 GPU/NPU 集群建设与稳定性治理能力。在容器技术、资源调度、性能优化领域有深厚积累，擅长从系统瓶颈出发进行架构级优化。曾主导多个大型 AI 基础设施项目，显著提升平台效率与稳定性，具备从 0 到 1 平台建设与规模化生产支撑能力。