

李腾飞

☎ 188-1043-4524
✉ tengfei_2017@sina.com

<<< 教育背景

2017-2020	硕士	北京邮电大学	电子与通信工程
2013-2017	本科	西安邮电大学	电子信息科学与技术

<<< 技能

Docker、Golang、Kubernetes、GRPC

<<< 项目

字节云服务平台/2025. 5-至今

●内存容量治理

内存峰值利用率45%→50%

根据业务容器的内存历史峰值利用率，进行定时缩容（天级任务），同时根据metrics的实时数据进行快速扩容（分钟级任务），业务配置治理规则，自动触发自动化治理任务，减少了人工运维的成本，同时将回收的资源释放到资源池供其它业务线使用。

●GPU容量治理

GPU峰值利用率43%→50%，接入22w卡

根据GPU利用率和QPS，对常规的推理服务进行扩缩容，同时将多机房作为一个分组，支持多机房联合扩缩容。在大模型推理的场景，根据TPS对服务进行扩缩容，支持池化和副本模式，同时支持定时扩缩容。在多机多卡推理的场景下，支持拓扑资源的Quota，保证实时扩容的资源Quota。

百度智能云容器计算组/ 2024. 4-2025. 5

●GPU 潮汐调度

1w+GPU 卡实现潮汐调度，资源复用率提升30%

分析在线任务的流量接入，发现1/3 的低频访问时间，可以把闲置的算力分配可抢占的离线任务，同时要保证在线任务的100%返场，因此需要解决返场资源调度问题。在线任务删除时，会生成预留资源，同时在应用编排侧支持退整卡的删除策略，提高离线任务调度的装箱率，在scheduler 层调度感知预留资源来保证100%返场。

●GPU虚拟化

5k+GPU 卡上实现分卡调度，将硬件成本降低了20%

CUDA 劫持方案由于适配的CUDA 版本无法满足GPU卡要求，需要在K8S集群内引入内核劫持的虚拟化方案，在节点侧实现资源上报（device-plugin），容器创建挂载虚拟设备和共享内存等，在调度侧做优化提高资源的装箱率，最终实现降本目

腾讯云云原生产品中心/2020.7-2024.4

● 公有云

1. 全网30w+节点规模的k8s 节点管理，公有云托管集群采用k8sonk8s模式集中管理，云原生后Reconcile 的耗时会比较长，这样就会导致新建集群和特性开启慢的问题，通过参数调优（增加Resync 的时间间隔、调大worker 数）和优先级队列等方式进行了流程优化。
- 2 集群2k+节点弱网环境下pod 运维稳定性保障，采用agent+server+长链接来解决弱网环的问题，节点数多，server 多副本情况，社区方案需要保证agent 与所有server 保持链接，在断开重连的耗时就会被放大，在此期间服务是不可用的，为了减少耗时，采用了dns 劫持+节点注册的方法，agent 只需和多个server 中的一个保持长连接，从而减少耗时

● 容器网络

全网2w+托管集群网络组件版本的统一，集群升级到1.22 后，低版本的组件会出现token过期，无法watch 到新增资源，导致服务异常。以coredns 为例，无法解析新增的headless service，同时升级需要解决配置不前向兼容、自定义配置和平滑升级等问题，为了保障集群的稳定性，针对配置添加预检，让用户能感知升级的影响，同时修改Kube-Proxy 的启动参数保障平滑升级。

● 开源社区

CNCF Sandbox项目的maintainer，参与开源项目的对外宣讲和pr