



温瀚林

15172270858 | whl3411@qq.com | 上海

个人总结

- 熟练使用Pandas、PyTorch等数据处理和深度学习框架，具备构建及优化训练数据Dataloader的实际经验
- 深入理解多模态数据的特性及处理技术，具备丰富的数据建模和数据架构经验，能够设计统一、高效的数据处理抽象
- 有使用Ray分布式框架进行大规模数据处理的实战经验

教育经历

华中科技大学	2021年08月 - 2024年06月
人工智能 硕士 人工智能与自动化学院	武汉
华中科技大学	2017年09月 - 2021年05月
自动化 本科 人工智能与自动化学院	武汉

工作经历

上海任意门科技	2024年07月 - 至今
大模型算法 SoulAI	上海

- 主导构建并完善了涵盖站内用户私聊、语音通话、播客、有声书、影视剧，唱歌音乐等多种模态数据源的**数据 Schema 与元数据体系**，有效管理和整合了来自内部及第三方爬取的海量数据。
- 设计并实现了一套覆盖私聊语音、语音通话、播客、方言及有声书等多种数据类型的高效**多源音频数据处理管线**，确保了数据处理流程的自动化与标准化。
- 开发并部署了数据处理管线中的核心处理算子，包含降噪、增强、识别等模块，成功实现了对数据的**清洗、过滤和质量校验**，显著提升了数据处理的准确性和可靠性。
- 针对长音频处理的场景，开发了音频加载和处理分离的异步处理方法，缓解IO瓶颈，综合提升20%效率
- 建设了基于 Lance 打包的**高性能DataLoader**，为后续大规模模型训练提供了稳定、高效的数据支撑，缩短了模型迭代周期。
- 建立并优化了系统性的 **badcase 分析机制**，能够快速定位并解决数据质量问题，确保了数据的一致性与可靠性，累计产出高质量处理后数据：私聊语音 **200 万小时**、播客数据 **100 万小时**、有声书数据 **50 万小时**。
- 创新性构建了基于多说话人 TTS 的 **synthetic data**，有效支撑了内部说话人识别工具的迭代与升级，提升了工具的性能和适用性。
- 设计了虚拟人对话质量评估体系，培训标注人员对对话质量进行评估，搭建了基于三方模型的对话质量自动化标注体系
- 主导优化了虚拟人对话模型，采用 **Multi-Stream Transformer** 结构，通过深入分析模型瓶颈并重新设计结构，使其更适应虚拟人对话场景，将生成效率**提升了 60%**，显著改善了对话体验。