

肖德山

31岁 | 男 | 8年经验 | WeChat deshanshan1994  
(+86)15072399494 | deshanshanxiao@qq.com



技能特长

- 熟练掌握Java/Scala/Python等编程语言
- 熟悉Spark, Ray等计算引擎，对Spark源码有一定了解，并有相应的开源贡献。
- 熟悉Spark SQL查询优化及执行引擎执行流程，并具备相关调优经验
- 熟练掌握AI预训练数据处理技术，对多模态数据去重，过滤有一定的了解
- 熟悉ORC列式存储格式，Apache ORC Committer
- 熟悉Linux系统，熟练掌握Cursor/Claude Code等开发工具，对Agent技术有一定了解。
- 英语六级

教育背景

|                           |                   |
|---------------------------|-------------------|
| 华中科技大学（推荐免试） - 计算机技术 - 硕士 | 2016-09 ~ 2018-06 |
| 三峡大学 - 计算机科学与技术 - 本科      | 2012-09 ~ 2016-06 |

工作经验

|                  |              |
|------------------|--------------|
| 小米科技 - 高级软件开发工程师 | 2025-09 ~ 至今 |
|------------------|--------------|

部门：计算平台大模型ETL组

- 负责小米MiMo系列大模型预训练多模态数据的处理。
- 主导小米MiMo视频大模型数据处理，使用基于MinHash+Phash的算法实现亿级别视频去重。
- 参与MiMo audio模型中人声活动检测（VAD）和音频标签模型（PANNs）的开发。

|                                     |                   |
|-------------------------------------|-------------------|
| 微软中国（北京） - Senior Software Engineer | 2022-04 ~ 2025-09 |
|-------------------------------------|-------------------|

部门：Azure C+AI

- 负责Power BI及Synapse Data Engineering的大数据开发套件如Spark Notebook/Pipeline等的后台开发，池化集群资源，提高用户session的启动速度。
- 从无到有主导小数据集的Python Notebook项目落地，负责全链路的流程设计与功能实现。
- 基于Jupyter Notebook/Apache Livy进行二次开发，设计并实现包管理、Session/Kernel管理等新功能。
- 解决用户Spark Notebook/Python Notebook执行过程中遇到的各类问题。

|                  |                   |
|------------------|-------------------|
| 蚂蚁集团 - 高级软件开发工程师 | 2020-05 ~ 2022-04 |
|------------------|-------------------|

部门：数字金融部

- 负责资产管理部门离线数据的开发。基于ODPS/Spark为机构资产提供机构侧会计日余额，计提，拨备等数据，为机构侧金融资产交易与转让决策提供高效、高质量的数据支持。根据查询的执行计划，调整ODPS计算引擎参数，并优化UDF逻辑，提升离线数据集产生时效。根据业务查询范式，建立与之对应的分区表，z-order规则，提高查询效率。为数据产出设定一系列业务、字段级别的校验规则，避免因业务修改导致的数据异常。
- 主导机构资产池估值项目，基于Flink SQL，为资产池实时估值提供实时余额，实时计提利息等实时指标，为业务资产池清算提供数据支持。

|                |                   |
|----------------|-------------------|
| 小米集团 - 软件开发工程师 | 2018-07 ~ 2020-04 |
|----------------|-------------------|

部门：小米云平台离线计算组

- 负责小米内部Spark版本的迭代与升级，跟踪社区最新特性，调研新版本功能并推动内部落地实施。负责了从Spark2.1升级到2.3和spark3.0的调研工作。
- 负责维护小米内部SparkSQL Thrift Server服务，优化查询引擎，分析并调优用户慢查询。
- 排查并解决用户在使用Spark过程中遇到的作业卡顿、报错及性能瓶颈等问题。熟练掌握常见问题排查方法，快速定位问题根因。对框架本身的问题，深入分析源码，精准定位作业执行缓慢或失败的根本原因。

开源贡献

Spark:

- <https://github.com/apache/spark/pull/23486>
- <https://github.com/apache/spark/pull/26714>

- <https://github.com/apache/spark/pull/23637>

ORC:

- <https://github.com/apache/orc/pull/1714>
- <https://github.com/apache/orc/pull/2076>