

基本信息

姓名：范礼阳

性别：男

出生年月：1988 年 6 月

学历：硕士

现居：北京

邮箱：edenbuaa@outlook.com

电话：18810075241

综合评估

【经历简述】

2022/09-至今	阿里巴巴及蚂蚁集团	AI Infra	高级技术专家
2018/09-2022/09	平安科技		技术专家
2015/06-2018/09	HST, Healthcare Systems & Technologies Co., Ltd.		senior engineer
2013/05-2015/05	中国农业新闻网		高级软件工程师
2011/08-2013/05	北大方正（实习）		高级软件工程师

【核心优势】

- 3+年团队管理(>10 人)、技术管理和项目管理经验，有多个大型完整的 0 到 1 的产品设计、架构设计、技术研发、商业化进程和解决方案架构的成功落地经验
- 良好的系统分析能力和架构经验, 具有多年大型分布式系统及 AI 场景平台、中台及优化经验，熟练 k8s, docker 等虚拟化技术，并在 k8s, kubeflow 等社区有所贡献。
- 具有丰富的超万卡算力规模的 AI Infra & AI Platform 建设经验及全栈项目经历，构建了多个大规模多元异构算力中心、智能数据及算法平台。
- 具有金融、医疗、互联网、制造业、能源电力、自动驾驶等多个行业和领域的大模型落地解决方案及技术架构经验，包括大模型训推构建及 kv 加速、RAG 及微调、智能体构建等全生命周期。
- 专注于高性能计算、异构计算及大规模分布式计算，熟练使用 TensorFlow, Caffe, PyTorch, deepspeed 等深度学习开发框架，并评估优化硬件平台和算法的整体性能。

工作经历

2022/09-至今	阿里巴巴及蚂蚁集团	AI Infra	技术专家（级别）
------------	-----------	----------	----------

工作职责：

- 负责 AI infra 基础平台架构的 GPU 集群调度、容量管理及 GPU 虚拟化产品建设等
- 负责蚂蚁集团 GPU 国产化的产品适配，可行性、兼容性评估，以及相应工具链对接与集成。

-
3. 优化超万卡 GPU 集群的调度策略，设计并实现新型 GPU 容量 buffer 管理模式，使得资源的分配率提升 25%，整体利用率提升 18%
 4. 优化 AI Infra 的软硬协同能力，提升 GPU 平台化效能，解决显存墙和传输墙问题；提升 GPU 池化和虚拟化能力，支撑训推、在离线混部以及潮汐算力调度场景
 5. 支撑大模型稳定训练、长周期训练作业保障及高效集群调优；实现面向高吞吐的显存优化，提高大模型的推理 batch 性能；优化聚合多路通信，提升吞吐 30%以上。
 6. 负责 Foundation model 训推优化，MaaS 平台建设，大模型在金融、交通、保险、军事等领域的应用落地

2018/09-2022/09

平安科技

技术专家（级别）

工作职责：平安科技深度学习平台负责人，负责平台建设，技术实施和项目落地等工作。

1. 参与研发面向 AutoML 的深度学习框架，支持 AI 领域建模的定制化和深度调优，加快 AI 模型建立的速度和质量。针对模型压缩，量化剪枝进行优化。
2. 主导基于 Docker, k8s, hadoop yarn 的大规模深度学习模型训练平台的搭建及优化，支撑数千异构 GPU 规模的调度和训练任务。针对不同硬件平台实现任务调度算法，使单卡加速比提升 7 倍；并支撑团队在 cv, nlp 领域等多个国际性顶会比赛中取得多项冠军。
3. 主导搭建基于 TensorRT, CUDA c/c++分布式高性能推断引擎
4. 应用部署 ich(脑出血)，青光眼等检测模型
5. 主导建设 AI 推理平台，从作坊式到平台式演进，实现上百个模型推理服务上线，对外输出产品级服务。
6. 与销售、BD 部门紧密合作，共同推进产品及解决方案的售卖及私有化部署和超卖方案的落地实施，及时反馈市场需求，推动产品及解决方案的不断迭代
7. 参与了多个集群管理，人工智能领域开源社区的贡献，并成为 contributor，通过 google developer 认证
8. 从 0 到 1 进行平台建设和人员团队组建，异地团队管理等

2015/06-2018/09

HST, Healthcare Systems & Technologies Co., Ltd.

senior

engineer

工作职责：

1. 与美国团队合作，研发基于 js-konckout, typescript, Bootstrap, .net signalR, wcf 等框架结构的实时 web 医疗系统。
2. 带领团队研发基于 React Native 的 Mobile App 业务系统
3. 作为高级工程师负责软件的整个开发生命周期，把控产品进度与产品质量。

-
4. 作为北京开发团队负责人，负责团队的技术培训、敏捷开发实践和综合管理，研发过程跟进、任务验收、代码 review、质量控制以及解决项目研发进程中的关键技术及事务。
 5. 负责公司产品/项目的整体技术架构设计工作，包括系统的总体规划、架构设计、系统分析与设计、核心代码编写；
 6. 协调各个部门，把控与跟进产品从需求、设计、开发、测试、验收、发布和运营的整个过程；
 7. 其他团队管理工作，招聘，团建及绩效考核等等

2013/05-2015/05

中国农业新闻网

高级软件工程师

工作职责：

1. 负责项目整体需求分析，系统功能架构设计，参与核心代码及模块编写；
2. 负责协调各有关部门的前期业务需求及后期人员培训；
3. 完成对下级程序员的任务分配、协调及制定详细的任务计划表；
4. 解决研发过程中的技术难题，指导团队成员进行相关技术方案研发；
5. 配合完成日常行政事务。
6. 研发基于微信平台的站点系统及业务系统

2011/08-2013/05

北大方正

高级软件工程师

工作职责：

1. 使用 UML 进行系统设计和需求分析，visio，EA 等工具对项目文档进行设计和编写；
2. 协助项目的日常管理工作，参与项目前期调研、制定项目计划，控制项目进度、产品质量，有效保障项目的有效实施；
3. 参与系统平台的架构搭建，负责系统核心代码的编写，系统集成，项目部署和测试；
4. 参与设计和开发基于 ActiveMQ 的中间件的通信系统。
5. 参与开发基于 C++ 的核心任务采集系统。
6. 设计并架构基于 .net SOAP 的 Monitor Client & Server。
7. 优化基于 .net 的信号通信系统的传输性能和系统稳定性。
8. 基于 WPF 的通信客户端的性能调优（memory&cpu）。
7. 参与部署 HP 服务器设备的虚拟机部署。
8. 协调用户的开发需求。

项目经历

2022/10-至今

AI Infra 及智算平台

高级技术专家/项目负责人

职责业绩:

1. 针对内部算力集群的管理、调度, 支撑集团业务, 对利用率、分配率、碎片化率及 MFU 负责。
2. 构建 GPU 平台化生态, 优化传输层和显存墙, 支撑业务模型高效落地。
3. 构建大模型加速库, 加速大模型训推、kv cache 优化和支持大模型在数十种智能应用中的落地。
4. 针对训推场景的故障隔离与恢复, 保障长周期训练作业的稳定性和可用性。
5. 适配主流国产 GPU 厂商, 构建异构集群, 在计算、集群和业务层面进行深入协同。

2022/10-至今

大模型平台建设

高级技术专家/项目负责人

职责业绩:

1. 主导平台整体架构设计, 包括数据处理、分布式训练、高性能推理、MLOps、应用服务等核心模块, 确保系统的高可用、高扩展性。
2. 构建分布式训练与微调框架, 深度集成 DeepSpeed、Megatron-LM 等, 支持百亿/千亿级模型的稳定高效训练。统一适配多种微调范式 (如 LoRA, P-Tuning, Full-tuning), 通过简单的配置一键启动微调任务, 将模型适配效率提升一个数量级。
3. 构建高性能推理服务引擎, 整合 vLLM、sgLang、TensorRT-LLM 等前沿推理加速框架, 优化 kv cache 与通信, 实现增大 batch 2-3x 的加速性能。
4. 落地了完整的模型、数据、知识库、Prompt 全生命周期管理方案, 实现了版本控制、血缘追溯与自动化评估流水线。

2022/10-至今

智算算力中心建设

高级技术专家/项目负责人

职责业绩:

1. 主导参与多个 5000P+智算算力中心建设, 包括软硬件选型、部署及可行性评估。
2. 主导构建统一的异构资源调度平台, 实现对 GPU、CPU、内存等资源的精细化管理和调度策略。
3. 设计并部署了三级存储架构: 热数据层采用 Lustre/GPFS 并行文件系统, 提供 TB/s 级的聚合读写带宽, 满足大规模训练数据吞吐需求; 温数据层和冷数据层采用对象存储, 平衡了性能与成本。
4. 完善平台工具链, 包括容器化方案、环境管理模块、统一开发门户等, 提升了用户易用性。建立了覆盖计算、网络、存储全链路的立体化监控告警体系 (基于 DCGM, Prometheus, Grafana), 实现了故障的秒级发现与根因分析。

2022/10-至今

智能体应用构建

高级技术专家/项目负责人

职责业绩:

1. 基于 LangChain、Transformers Agent 和自研框架, 构建可扩展的智能体执行框架, 支持多工具调用、任务分解和记忆管理。。
2. 设计企业知识库与大模型结合的检索增强生成流程 (RAG), 提升问答准确率和领域适配度。
3. 集成语音识别 (ASR)、图像识别 (OCR/CV) 与大语言模型, 构建跨模态任务处理智能体。
4. 业务场景落地
 - 1) (金融/企业) 代码助手, 适配多种模型和 IDE, 实现代码补全、注释、压测、调试及 UI 布局能力; 基于 RAG, 对私有代码库、API 文档、技术 Wiki 进行向量化索引。通过优化 Embedding 模型和检索策略, 实现对私有代码上下文的精准理解。
 - 2) (能源领域) 工作票生成, 基于微调模型和知识图谱, 建立企业内方案生成智能体, 包括内部知

识库、大小模型协同等，并抑制幻觉和保证模型安全。

3) 其他领域（军工、电力）的智能体应用落地。

2018/09-2022

深度学习平台/AI 平台

技术专家/项目负责人

职责业绩:

1. 研发大规模 GPU 集群算力调度平台，及针对 AI 任务场景的深度学习平台。
2. 构建平安科技深度学习平台生态，服务于各 BU 的 AI 场景和业务
3. 针对训练和推理场景的平台建设和功能研发，训练场景下的 AI 任务调度、调试及资源管理和超卖功能研发；推理场景下，支持 GPU 虚拟化，auto scaling、灰度发布等特性
4. 针对 AI 业务的全生命周期的 pipeline 流程设计与研发，研发基于 airflow, argo, kubeflow 等流程化调度平台。

2016/08-2017/08

基于 Deep-Learning 的智能 AI 内容生成器

职责业绩:

1. 搭建基于 tensorflow, opencv 和 keras 的 RNN 模型环境
2. 搭建网络爬虫系统，用于对目标内容的训练数据搜集与修正
3. 使用基于搭建的 RNN, LSTM 模型结构对内容产生模型进行数据训练

2015/02-2016/7

全国山洪灾害分布式水文模型并行分析模拟系统

项目描述:

vs, xmlspy, ea, mockplus, viso(开发工具)开发基于全国水文模型的分布式并行模拟分析系统，并整合 ArcGIS 相关资源服务，进行实时雨水情的并行分析与实时模拟，给出山洪灾害的实时预警信息。

项目职责:

1. 负责根据分布式水文模型整理应用解决方案；
2. 参与编写业务需求分析文档，完成软件项目的设计、系统模块划分、功能设计、代码编写等工作；
3. 参与软件架构设计和新技术研究及论证；
4. 编写产品技术手册、功能及操作手册，管理项目产品的技术文档；

2012/10-2013/10

“核高基”科技重大专项

项目描述

1. “核高基”科技重大专项分课题中对 Dalvik 虚拟机，Android C 运行库和其他函数 库的分析及安全性评估。
2. 对 Android 系统整体架构及运行原理进行深入分析；对 Dalvik GC, zygote 机制，Dalvik 中的 JIT 编译及 C 运行库等核心模块进行深入的分析和阐述；
3. 对 Android 系统架构及 Dalvik 虚拟机的移植研究；Dalvik 虚拟机与主流 Java 虚拟机的对比分析与测试等；
4. 对 Android 系统 Bionic C 库，SQLite，Webcore 等核心模块的分析研究及与其标准库的对比测试 等；
4. 采用专业的测评工具针对 Dalvik 内部模块性能与平台依赖关系进行相关测评；
5. 在分析研究的基础上取得多项科研成果和发明专利。

项目职责

-
1. 对专项任务的调研分析与研究；
 2. 对各子任务进行模块划分和任务分配；
 3. 负责关键技术攻关和关键问题解决；
 4. 负责对团队成员的相关系统知识培训和相关技能分享；
 5. 负责相关研究成果的收集与发表。

教育经历

2011/09-2014/06	北京航空航天大学	软件工程	硕士
2007/06-2011/06	河南大学	计算机科学与技术	本科