

褚泽方简历

手机: +86 18058753597 邮箱: zefangchu@gmail.com 现居: 北京

工作经历

小红书 | 稠密平台 | 机器学习平台工程师 (调度方向)

2025 年 10 月 - 2026 年 05 月

负责机器学习平台 GPU 调度系统建设, 主导推理 Quota / 弹性 Quota 体系搭建、训推一体化统一调度架构演进及训推弹性并池能力落地, 管理数万卡规模异构集群 (包括 910C、H20 等主流算力卡型), 统一承接训练 / 推理 / 弹性三类负载的调度。

字节跳动 | Seed-Infra & Data-AML | 机器学习系统工程师

2022 年 07 月 - 2025 年 08 月

Seed-Infra 推理调度

参与豆包大模型推理 PD 分离联邦预调度、集群智能扩缩容全流程架构设计与生产落地, 服务数万卡级大模型推理集群, 实现跨 RDMA 网络拓扑亲和性资源分发与全局动态调度; 搭建专为自动评估、离线批推供给资源的弹性平台, 实现评估、批推任务的高效分发, 大幅提升闲时资源整体使用效率。

Data-AML MLSys 方向

落地反潮汐调度链路 with 自动化工单体系, 支撑多业务算力快速调配、Quota 迁移、SRE 资源交付等核心场景; 参与在线推理平台、模型仓库全栈开发, 保障搜索、内容审核等核心业务推理服务稳定高效部署运行。

核心重点项目

1. 机器学习平台 GPU 调度系统

2025 年 10 月 - 2026 年 05 月

项目简介

自研机器学习平台 GPU 调度器, 沿"稳态 Quota → 弹性 Quota → 训推统一调度"路径完整演进, 统一承接训练 / 推理 / 弹性三类负载的调度, 服务数万卡规模异构集群 (910C / H20 等主流算力卡型)。

工作成果

- 设计落地大规模异构集群**推理 Quota 管控体系**, 实现跨集群、跨卡型精细化资源配额分配; 主导昇腾 910C 超节点预调度系统搭建, 具备拓扑亲和感知调度、资源抢占调度、碎片资源治理能力, 降低集群资源碎片率
- 落地**弹性 Quota 交付机制与分时段定时使用功能**, 配合 HPA 缩容释放资源, 将夜间"数千卡"闲置算力以弹性资源形式分发至 MaaS、训练、离线批推等高价值场景
- 推进**训推一体化统一调度架构**: 推理调度器作为弹性资源准入网关, 承接训练任务的弹性 Quota 检查、DryRun 准入模拟与抢占管理, 训练调度器独立负责任务生命周期, 实现训练 / 推理调度链路解耦但资源池统一纳管
- 基于 **Virtual Kubelet** 打通训练平台与推理平台的跨平台资源借调链路, 使训练任务可直接调度至推理集群闲置算力, 构建跨平台统一资源视图
- 设计落地 **2-Tier 优先级抢占机制** (弹性 Quota 内任务优先, Quota 外任务低优可抢占), 配合 Checkpoint 断点续训能力, 在保障推理 SLA 的前提下让训练任务充分利用低峰闲置算力

2. 扩缩容 + 推理 PD 分离预调度系统

2025 年 02 月 - 2025 年 08 月

项目简介

面向大模型推理服务搭建自动化扩缩容组件 + 自研联邦预调度器, 构建完整 PD 分离调度体系。依托线上吞吐、服务可用性等指标自动弹性伸缩, 结合 RDMA 多级网络拓扑、异构算力需求, 完成跨集群联邦式资源统一分发调度。

工作成果

- 共同第一作者发布预印本论文: *Taming the Chaos: Coordinated Autoscaling for Heterogeneous and Disaggregated LLM Inference* — arxiv.org/abs/2508.19559
- 从零完成豆包 PD 分离推理服务扩缩容架构设计与线上落地, 覆盖数万卡算力集群, 全上线周期零线上故障
- 自研联邦预调度器, 解决原生 HPA 无法适配跨集群复杂拓扑、异构算力调度的痛点, 实现 PD 分离场景多集群统一资源视图
- 设计并实现基于 **TPS、SM 利用率、负反馈指标** 的多维扩缩容机制及分时段调度策略, 核心服务 SM 利用率峰均比降至 **1.08**
- 构建带网络拓扑亲和性的资源出让流程, 在保障在线服务水位的前提下, 向弹性资源池**日均稳定出让万卡级算力**, 支撑在离线混部业务
- 搭建灰度发布、全维度告警监控、一主多备高可用架构, 完善单测与端到端测试流水线, 系统满足大规模生产级稳定运行标准

3. GPU 弹性资源分发平台

2024 年 05 月 – 2025 年 02 月

项目简介

基于 K8s 底层调度与 Quota 管控体系，打造面向在离线混合场景的 GPU 弹性算力分发平台，统一感知集群实时资源水位，智能调度离线弹性任务，推动算力资源从抢占式（Spot）向高稳定分时（Schedule）资源升级，实现弹性算力规模化商用落地。

工作成果

- 自研资源智能分发核心模块，核心集群抢占式算力全天分配率从 30% 提升至 80%（有排队时达 95%），高优任务平均排队时长由 60 分钟压缩至 10 分钟
- 搭建全维度算力资源可视化监控大盘，实现集群资源状态实时监控、统一运维管理
- 完成 Ray 集群架构轻量化改造，迁移为 Single Job 运行模式，强化算力隔离能力，大幅降低资源抢占引发的任务运行故障
- 完成华为云外部弹性算力接入，构建任务分发、模型上传至云上 HDFS、模型加解密的端到端 Pipeline
- 落地分时稳定算力出让自动化方案，将临时抢占资源转为长期稳定分时算力，为内部业务稳定供给万卡级弹性算力

4. 在线推理和资源调转平台

2022 年 07 月 – 2023 年 04 月

项目简介

基于 Kubernetes 搭建标准化 GPU 在线推理部署平台，同时研发独立 GPU 资源拆借交付平台，满足业务临时算力借用、大促活动算力保障、机房资源腾挪、SRE 算力交付等多样化资源流转场景。

工作成果

- 参与推理平台前后端开发，负责服务部署、Volcano (VCJob) 调度、后端核心 API 迭代维护，参与模型仓库、算力计量计费模块建设
- 独立负责资源借调平台全流程功能设计与开发，落地反潮汐算力调度全链路，完成物理机筛选、闲置作业清理自动化流程
- 设计标准化算力借调工单流水线，实现跨业务、跨机房物理资源腾挪与 Quota 权限自动转移

专业技能

- **编程语言**：擅长 Python、Go，了解 Java、JavaScript、C
- **云原生 & 容器**：熟悉 Kubernetes 概念与原理，熟悉 CRD / Operator 实现，熟悉 Volcano (VCJob)、Docker、HPA、Virtual Kubelet
- **调度系统**：联邦预调度、潮汐 / 反潮汐调度、在离线混部调度、拓扑亲和（RDMA 多级网络）、资源抢占 & 碎片治理
- **LLM 推理**：理解 PD 分离架构，了解 Transformer，熟悉 Ray 架构及用法
- **后端技术**：框架熟悉 Flask、FastAPI、Gin，具备微服务架构设计能力；数据库熟悉 MySQL、Redis；消息队列 / 中间件熟悉 Kafka、Consul、流程引擎

教育背景

就读院校	学历	专业	就读时间
美国南加州大学（USC）	硕士	计算机科学	2020.12 – 2022.05
美国宾夕法尼亚州立大学（PSU）	本科	计算机科学	2016.08 – 2020.05