

许伟科 - 大模型数据工程师

男/31岁

莆田学院/2013.9-2017.7

计算机科学与技术/本科

18565699344

xuweike0917@126.com

vipider

介绍

具备多年 Python 数据开发与基建落地经验，近年来专注于大语言模型（LLM）与 Video 多模态模型的数据采集及预处理工程。

熟悉从分布式抓取到海量数据清洗、去重与存储调优的完整流程，能够熟练使用 Spark、Ray 等计算框架处理数据。

具备独立主导复杂系统从 0 到 1 建设的经历，对所负责业务有较强的 Owner 意识，能适应并推动跨团队协作与需求落地。

技能

- 熟练掌握 Python 开发，熟悉 Pyenv、Conda 环境管理及 uv 等依赖构建工具
- 熟悉分布式计算框架 Ray、Spark (PySpark)
- 熟练使用 Requests、Scrapy、HTTPX，熟悉 Scrapy-Redis 分布式爬虫框架与常见消息队列，了解 Bloom Filter
- 熟悉 HTTP/HTTPS 协议栈，了解双向认证、证书固定及 HTTP/2
- 熟悉 HTML、CSS、XPath、Re，熟练使用 Selenium、Playwright、DrissionPage 等自动化工具
- 熟练掌握 MongoDB、MySQL、Redis，具备海量数据场景下的 MongoDB 调优与架构设计
- 熟悉 Git 代码管理及 Git Flow 协作流程
- 掌握常见反爬对抗方案（JS 逆向、混淆、CSS 反爬等）
- 了解常见 Android 逆向、抓包与自动化工具（JADX、Charles、Appium），了解 Frida、Objection 等 Hook 框架

工作

上海米哈游网络科技股份有限公司 - 爬虫开发工程师 / 大模型数据研发（2021.9-至今）

平台-算法工程组、大模型研发部

- 负责面向大语言模型预训练及 Midtrain 阶段的文本、代码、论文等语料采集与清洗
- 参与音视频管线模型所需的多源音视频数据采集、处理、质量检测与打标
- 负责国内外各游戏舆情站点的反爬对抗、数据抓取与入库
- 探索并落地海外平台社媒官号（FB、Ins 等）的运营指标接入方案与数据清洗工作
- 负责创作者平台数据基建，实现每日百万级 KOL 数据的抓取与更新

深圳市前海房极客网络科技有限公司 - 爬虫开发工程师（2018.7-2021.7）

工程化 基建搭建

技术部-数据组

- 担任数据组副组长，负责基础数据方向的工作规划、项目版本迭代，定期向管理层汇报进度

- 主导爬虫数据管理平台的系统设计与开发，完成该平台从 0 到 1 的上线
- 负责多个存量爬虫项目的常规维护、抓取策略优化与数据清洗调度
- 担任数据迁移服务项目负责人，主导需求分析、技术调研并制定业务流程，推动项目落地

深圳市本地在线技术有限公司 - Python爬虫工程师（2017.7-2018.6）

技术部

- 负责微信公众号项目的数据抓取、爬虫架构设计与反爬策略绕过，以及相关后台服务开发
- 维护并处理上万个公众号及百万级文章数据的增量更新与清洗

项目

大模型数据采集与处理2024.10-至今

FFmpeg Gemini/GPT Ray Spark Scrapy-Redis MongoDB

- 参与大模型数据研发，主要负责多模态 Video 管线的数据采集与质量检测，以及 LLM 文本模型海量语料的抓取与预处理
- 完成跨平台（YouTube、抖音、Bilibili、Twitch 等）音视频数据的自动化抓取与入库
 - 负责外部采购视频数据的元数据管理与去重；基于 FFmpeg 完成大规模视频文件的完整性校验与抽帧质量检测
 - 参与 Video 管线数据预处理，结合 Prompt 工程与大模型（如 Gemini 2.5 Pro 等），实现视频素材的自动化质量打分与分类
 - 基于 Scrapy-Redis 完成各类文本类数据（书籍、影视元数据、论文、网页等）的分布式抓取；负责 ArXiv 与 OpenReview 论文数据的全量获取
 - 依托 Spark/Ray 分布式计算框架，负责 TB 级海量多源文本（如 Web 网页、Code、Agent 轨迹数据）的预处理清洗；并在 Spark 集群上实现基于 MinHash 的大规模数据去重
 - 针对书籍类数据的前置获取与采购需求，将约 20 亿条书籍 JSON 数据接入 MongoDB 进行存储与查询优化；设计并搭建了书籍元数据的精确与模糊去重 Pipeline，有效规避了重复采购与冗余抓取

舆情平台、创作者平台、运营看板数据基建2021.9-2024.10

Scrapy-Redis Playwright PyExecJS JADX Charles Docker Rancher Crawlba Kafka

- 负责外部舆情抓取、KOL 数据建设及海外社媒运营指标的接入落地
- 统一采用 Scrapy-Redis 框架，通过自定义 Extension 组件实现任务定时启动与分布式一致性
 - 引入 Twisted 线程池处理特定耗时任务，保障异步请求的原子性
 - 通过 JS 逆向与 App 抓包完成主流站点反爬分析，利用 Playwright 解决复杂动态渲染与自动登录问题
 - 实时抓取海内外各大游戏社区（X、FB、Ins、NGA、微博等）数据并对接到内部舆情系统
 - 追踪 KOL 动态与稿件更新，保障增量与存量数据日均百万级体量的稳定产出
 - 探索海外社媒多平台运营指标接入方案，完成数据开发、指标清洗并上线数据看板

各类房产网数据抓取 (Web/App)2018.8-2020.10

Scrapy Selenium Appium Mitmproxy PyExecJS Frida Objection JADX Charles

- 负责各房地产平台 Web 端与 App 端的数据抓取、解析、清洗及反爬对抗
- 编写 Scrapy 中间件（代理池、Cookie 池等），对现有爬虫进行性能分析并重构优化，提升抓取成功率
 - 逆向分析链家网 JS 逻辑，提取接口请求中的 MD5 加密算法并使用 Python 重写
 - 结合 Appium 与 Mitmproxy 自动化抓取微信小程序及某房产 App 数据

- 使用 Frida + Objection 分析 APK，绕过部分 Android 端的 SSL Pinning 与双向证书校验
- 逆向某看房 App 接口，还原 Headers 中的 RSA 签名生成逻辑及响应数据的 AES 解密过程
- 借助 FRIDA-DEXDump、FART 等工具辅助完成常见 App 的脱壳与逻辑分析

爬虫数据管理平台

2018.9-2020.10

Tornado MongoDB MongoEngine APScheduler MySQL RocketMQ Docker Jenkins

作为项目负责人，从零搭建内部数据分发与管理中心，保障多系统间的数据同步

- 引入 MongoEngine (ODM) 建立数据校验规范，确保生产环境底层数据结构的统一
- 基于 APScheduler 开发定时任务模块，对接 RocketMQ 消息队列并处理数据同步失败的重传逻辑
- 利用 MongoDB 地理空间索引搭建空间检索系统，实现基于经纬度及指定范围的数据高效检索
- 优化小区名称的中文搜索逻辑，兼容拼音模糊检索，将查询响应效率提升 10 倍以上
- 搭建底层数据版本控制逻辑，实现数据的快速回滚与恢复，定期进行慢查询分析与调优

爬虫自动化调度服务

2020.12-2021.7

Scrapy Scrapy-Redis Twisted RocketMQ APScheduler Tornado MongoDB Docker Jenkins

作为项目负责人，设计并开发涵盖“爬虫触发-数据清洗-业务上线”全流程的自动化调度服务

- 实现了基于事件 (Event) 的作业流程调度器开发，作业流：爬虫 -> 清洗 -> 上线
- 封装 APScheduler 定时器模块，支持业务侧动态调整爬虫作业的调度频率
- 集成 RocketMQ，实现调度器对多个子模块（爬虫、清洗、上线）的任务派发
- 基于 Twisted 的 Deferred 延迟调用链，实现节点状态监控与任务执行结果的实时回调通知

订阅一下 (微信小程序服务)

2017.7-2018.6

负责微信小程序端公众号内容分发平台的数据抓取（微信公众号及文章）与后台服务开发

- 基于 multiprocessing + requests 实现多进程多线程并发采集，最大化代理池利用率
- 使用 PyMySQL + DBUtils 建立数据库连接池，保证高并发下的数据库连接稳定
- 分析并突破搜狗微信反爬虫策略，通过 IP + Cookie 轮换逻辑绕过验证码限制，将单 IP 访问量提升近 10 倍
- 逆向分析新榜 (newrank.cn) 页面 JS 加密参数，使用 PyV8 动态执行 JS，自动化生成全站接口请求参数
- 针对 wxb.com 接口的访问频率限制，搭建并维护高可用 Cookie 池，大幅提升公众号文章抓取效率
- 基于 Django + Celery 搭建后台异步任务处理框架，实现文章的后台下载与公众号数据的实时检索更新