

郭艾家

电话: 13262908189 | 邮箱: guofan1991@outlook.com | 所在地: 上海

教育背景

北京邮电大学 | 计算机科学与技术 | 硕士 | 2013.09 - 2016.06

燕山大学 | 计算机科学与技术 | 本科 | 2009.09 - 2013.06

专业技能

- 编程语言: Python, Go, C++, Scala, Shell, SQL
- 大数据生态: Hadoop, Spark, Ray, ElasticSearch, Hive, Iceberg, DolphinScheduler
- 数据库/存储: MySQL, PostgreSQL, TiDB, Milvus, Redis, 对象存储
- 云平台/基建: K8s, AWS EMR
- AI数据工程: PB级文本预训练数据处理流水线, 千卡国产NPU推理, 自动化数据标注, 亿级PDF/视频解析, 百亿级 vlm训练数据管理

工作经历

上海人工智能实验室 | 数据平台中心 | 大数据/后端开发工程师

2021.12 - 至今

负责AI数据生产自动化链路搭建、大模型训练数据交付、大数据基础设施规划与优化, 核心支撑实验室多项重大模型训练任务

大数据基础设施建设

- 计算集群硬件规划与搭建: 协助制定集群硬件采购, 制定硬件规格 (CPU, 内存, 网卡, 磁盘等) 及采购数量
- 计算集群容器化部署管理: 从公司提供的裸机出发, 完成500+台机器 **超10万CU** 的大数据集群部署与优化, 基于K8s完成Hadoop/Spark等所有组件的容器化改造。该项目与AI agent深度结合, 运维效率得到极大提升。
- 存储集群验收: 协助制定存储集群性能指标(存储容量, 最大并发, 大文件吞吐, 小文件IOPS等), 完成 **超100PB** 存储集群性能验收, 制定存储集群标准化使用流程
- 监控体系搭建: 实现硬件级别, 应用级别丰富监控体系(例如某个spark任务占用了某个存储集群多少连接数, 每个executor实际使用了多少CPU, 内存等), 极大的方便了问题排查和性能提升
- 底层软件库的封装: 封装基础软件库, 方便团队成员方便的调用S3, Spark, Kafka等应用
- 向量数据库体系: 调研并Milvus构建向量数据库体系, 实现 **十亿级** 向量高效写入与查询, 支撑数据高效召回与统计

AI数据生产自动化链路

- 流式数据处理框架:
 - 设计与搭建基于s3文件的流水线数据处理框架, 基于spark streaming和kafka, 解决大规模文本类数据处理中的断点处理, 版本控制等问题, 实现CPU/GPU任务跨集群高效流式处理
 - 利用该流水线, 处理过CC, huggingface等10PB量级数据集的多轮迭代, 累计交付约60T tokens预训练数据。
 - 通过监控统计, 分析流水线各阶段留存率, 协助分析各阶段优化方向, 制定数据储备计划
- PDF文档处理自动化:

- 基于国产NPU算力平台，实验室内部大模型推理引擎LmDeploy，以及部门内部自研文档解析模型Mineru，开发PDF文档解析流水线，结合内部数仓平台，实现全流程自动化无人值守
- 完成 **2亿** PDF文档处理，交付 **3T tokens** 高价值数据；优化批量PDF推理逻辑，处理速度提升 **1倍**
- **MinerUOps平台(数据，训练，推理，评测自动化平台):**
 - MinerU(<https://github.com/opencv/MinerU>)为部门自研文档解析模型(1.2B vlm)，MineruOps平台旨在通过将数据集管理，模型管理，GPU调度，模型训练，模型评测等全流程串联起来，终极目标是在无人干预下，通过大模型+Agent的方式，让模型开发全部自动完成
 - 主要完成百亿级训练数据的管理部分，引入TiDB实现HTAP能力
 - 目前正在从算法同学接手模型训练部分工作
- **AIGC-Video项目支撑:** 支撑AIGC-Video项目 **亿级** 视频文件处理，包括长视频场景切割，镜头移动检测，分辨率resize，光流估计等任务

数据平台开发

- **OpenDataLab(<https://opendatalab.com/>):** 从零开始搭建公开数据集平台OpenDataLab，使用Go语言，开发完成用户端系统，内部管理系统，对接实验室统一账号系统等

妙盈科技| 后端/大数据开发工程师

2018.06 - 2021.12

开源数据管理调度平台 - Kun-Scheduler

- 设计并开发企业级数据管理调度平台（已开源），满足日均 **1000+** 任务调度
- 二次开发Spline实现数据血缘自动解析

大数据集群性能优化与成本控制

- 打通KUN平台与YARN资源监控，实现任务级成本核算
- 通过参数调优与AWS EMR弹性伸缩能力整合，优化集群默认参数使资源利用率提升 **20%**

实时新闻流处理系统

- 主导构建基于Spark Streaming的Lambda架构实时处理Pipeline
- 解耦输入/处理/存储模块，通过优化业务调用链路，系统性能提升 **2倍** 以上

金融计算系统重构

- 带领3人团队主导技术选型与系统重构
- 将原有 Python(Pandas)/MySQL 架构迁移至 Java/PostgreSQL，优化代码结构与数据库管理，实现 **10倍** 性能提升
- 拆解巨型API为轻量级微服务，提升多服务并发执行能力

摩根士丹利 (Morgan Stanley) | C++开发工程师

2016.04 - 2018.06

- 负责高频交易平台核心组件开发，实现与亚/欧多家交易所的稳定低延迟连接
- 开发并维护 FIX、OMNI、OUCH 等金融协议转换模块
- 支持 ASX DarkLimit、Sweep 等新型交易订单类型开发
- 负责交易所技术对接、灾备演练与系统升级测试